

Análisis crítico de la tesis

Algoritmo híbrido de Machine Learning aplicado al mercado eléctrico

Edward Benjamín Mitchell García

Magíster en Matemáticas Aplicadas / Ingeniería Civil Matemática — DIM, FCFM, U. de Chile

2 de septiembre de 2026

1. Veredicto general

El trabajo tiene volumen de ingeniería considerable (8 barras $\times$ 2 arquitecturas $\times$ 2 ramas de *features*, 5 variantes de *Conformal Prediction*, 3 granularidades, ablaciones y extensiones), está bien escrito, y muestra una honestidad metodológica poco común: documenta un *bug*, el doble rol del conjunto de validación, la inestabilidad de $\hat{\sigma}_h$ a 15 minutos, el *confound* de período en el estudio de granularidad, y reporta hipótesis propias que fueron refutadas (H+C, S+H+C). El hallazgo central — que la estrategia *simple* (S+C) supera a la propuesta original y más elaborada (P+C con Prophet y *Stacking*) — es un resultado negativo respecto de la propia hipótesis de partida, y está reportado sin maquillaje. Eso habla bien del autor.

Dicho eso, el estado actual del documento **no permite sostener sus afirmaciones cuantitativas principales**, por cuatro razones que son independientes entre sí y todas corregibles:

1. El problema resuelto ($h = 1$ hora) no es el problema declarado (programación del despacho, valorización de contratos), y **no existe ninguna línea base ingenua** contra la cual interpretar un MAE de 6,4–8,4 USD/MWh o un R^2 de 0,89.
2. La selección de estrategia, de método de optimización de pesos y de variante de CP se hace **sobre el conjunto de prueba**, en contradicción explícita con lo declarado en la Sección 3.2.2.
3. La evaluación se realiza sobre una serie a la que se le **eliminaron los spikes también en validación y prueba**, que son precisamente los eventos que motivan todo el trabajo.
4. La inferencia estadística (Wilcoxon sobre 8.298 errores horarios autocorrelacionados, una sola semilla) no puede sustentar las conclusiones de significancia que se extraen de ella.

Ninguna de las cuatro exige reentrenar el modelo desde cero. Las correcciones P0 de la Sección 6 son, en su mayor parte, re-análisis sobre predicciones ya almacenadas más 2–3 experimentos nuevos baratos. Con esas correcciones y un Capítulo de Conclusiones escrito, el trabajo es defendible con holgura.

Estado formal del documento

Faltan: **Resumen** (dice literalmente “FALTA HACER UN RESUMEN”), *abstract* en inglés, dedicatoria, nombres de la comisión (“NOMBRE COMPLETO UNO/DOS/TRES”), y sobre todo **el capítulo de Conclusiones**: el índice pasa del Capítulo 4 directamente a Bibliografía, pese a que la Sección 1.5 lo anuncia. El Anexo A contiene *lorem ipsum*. La bibliografía tiene 23 entradas, varias con errores (Sección 5).

2. Fortalezas que conviene preservar

1. **Análisis de errores extremos (§4.5.8)**. Es la mejor sección del trabajo. El criterio de clasificación es cuantitativo y reproducible (desplazar la predicción en $[-3, +3]$ h y quedarse

con el desplazamiento que minimiza el error; si la reducción supera 60 %, es “desfase de fase”). Concluye que 17 de los 20 mayores errores son desfases y no *spikes*, y conecta ese hallazgo con la brecha entre MAE (6,89) y semiancho del intervalo (32,72). Es exactamente el tipo de diagnóstico que separa un trabajo descriptivo de uno analítico.

2. **Refutación honesta de hipótesis propias.** H+C y S+H+C se introducen con una hipótesis explícita para Puerto Montt, no funcionan, y se reporta que no funcionan, con test pareado incluido (Tabla 4.26). Idem el resultado S+C > P+C, que desmonta la arquitectura híbrida original.
3. **Control parcial del *confound* en granularidad (Tabla 4.31).** Detectar que los tres pilotos cubren períodos distintos y construir un modelo horario restringido a la ventana calendario del piloto de 15 minutos es un buen reflejo experimental.
4. **Verificación del mecanismo, no sólo del resultado.** El análisis de la *Variable Selection Network* (Tablas 4.22–4.23) muestra que el *decoder* efectivamente se apoya en `elevacion_solar/cos_elevacion` (42–77 % del peso en 6 de 8 barras), lo que respalda internamente la hipótesis de S+C en lugar de sólo constatar que S+C gana.
5. **Marco teórico correcto y bien construido.** La derivación de por qué $\alpha \rightarrow 1/\sigma$ en DyT (§2.4.3), la caracterización del *squashing* y la exposición del linaje de CP están bien hechas. El análisis empírico de los α aprendidos (Figura 3.6, rango $[-0,13, 1,81]$ desde $\alpha_0 = 0,5$) es una validación no trivial de la teoría de Zhu et al.
6. **Transparencia sobre limitaciones.** Doble rol del conjunto de validación (§3.7.1, §4.5.7), colapso de $\hat{\sigma}_h$ a 15 minutos (§4.7.2), *bug* en `Stacking_Optimization_TFT.py`. Nada de esto estaba obligado a aparecer.

3. Objeciones mayores

3.1. O1. El horizonte $h = 1$ y la ausencia total de línea base ingenua

Esta es la objeción central y de ella dependen casi todas las cifras del Capítulo 4.

(a) **Desalineamiento entre el problema declarado y el problema resuelto.** La motivación (§1.1) es la “programación del despacho eléctrico y el diseño de contratos de suministro de mediano y largo plazo”. La propia §2.1.4 reconoce que “en mercados eléctricos, el horizonte más relevante operacionalmente es el *day-ahead*, es decir, $h = 24$ horas” — y a continuación fija $h = 1$. Una predicción del CMg de la hora siguiente no informa ninguna de las dos decisiones citadas. El TFT fue diseñado para MIMO multihorizonte y el *pipeline* ya está construido; usar $H = 1$ desperdicia la arquitectura (la §2.3.4 lo admite: “la distinción *encoder/decoder* colapsa a una única pasada”).

(b) **No hay ningún *benchmark* ingenuo en todo el documento.** No aparece persistencia ($\hat{y}_{t+1} = y_t$), ni *naive* estacional (y_{t-24} , y_{t-168}), ni AR(p)/SARIMAX, ni un modelo de *gradient boosting* sobre *lags*, ni LEAR. El único punto de comparación es Prophet, que **por construcción no puede usar y_t** : es una descomposición determinista en tendencia + Fourier + feriados, sin memoria de corto plazo. Comparar un modelo autorregresivo contra un modelo sin autorregresión en un problema de un paso adelante es un *straw man*. Las mejoras reportadas de “65,4 %–71,2 % sobre Prophet” (Tabla 4.6) no son informativas; el $R^2 = -0,016$ de Prophet en Puerto Montt (Tabla 4.1) muestra que la referencia es peor que la media muestral.

(c) **Hay evidencia *interna* de que el modelo opera cerca de la persistencia.** Esto es lo más serio. La §4.5.8 reporta que **17 de los 20 mayores errores** corresponden a “desfase de fase”: desplazar la predicción entre 1 y 2 horas (mediana ≈ 1 hora) reduce el error entre 67 % y 99 % (mediana ≈ 89 %), y **en 16 de esos 17 casos el desplazamiento óptimo es positivo**, es decir, el modelo va *retrasado* respecto de la transición real. Un retraso sistemático de un paso es la firma exacta de $\hat{y}_{t+1} \approx y_t$. El autor interpreta esto como una limitación en la anticipación de transiciones solares; la lectura alternativa — que el modelo aprendió mayoritariamente a copiar el último valor observado — es al menos igual de compatible con la evidencia, y sólo se puede descartar con la línea base ausente.

(d) **El estudio de granularidad refuerza la sospecha.** La Tabla 4.28 muestra R^2 creciendo monótonamente Día $\rightarrow$ Hora $\rightarrow$ 15 min (0,30–0,45 $\rightarrow$ 0,89 $\rightarrow$ 0,93) y el MAE de 15 minutos cae a 2,30–3,58 USD/MWh en la ventana pareada (Tabla 4.31). El texto concluye que “una mayor resolución temporal mejora la capacidad predictiva del modelo”. **Esa conclusión no se sostiene con este diseño:** al mantener $h = 1$ *paso* y variar Δt , se están comparando tres problemas distintos — predecir a 24 h, a 1 h y a 15 min de anticipación. Cuando $\Delta t \rightarrow 0$, $y_{t+\Delta t} \rightarrow y_t$ y el R^2 de *cualquier* modelo con memoria tiende a 1. La Tabla 4.31 controla el *confound* de ventana calendario, que era el *confound* secundario; el primario (distinto *lead time* físico) queda sin controlar.

Remedio (barato).

1. Calcular, sobre el mismo conjunto de prueba y sin reentrenar nada: MAE de persistencia, de *naive* 24 h y 168 h, y de un AR(24)/AR(168) con OLS. Reportar **MASE** = $\text{MAE}_{\text{modelo}}/\text{MAE}_{\text{naive}}$ y un *skill score*. Es media jornada de trabajo y cambia la lectura de todo el Capítulo 4.
2. Repetir el *pipeline* S+C a $h = 24$ (MIMO) para al menos tres barras. Ahí la persistencia deja de ser competitiva y el valor del TFT debería aparecer con claridad.
3. En el estudio de granularidad, fijar el *lead time* físico (p. ej. 1 hora = 4 pasos a 15 min, 1 paso a 1 h, 1/24 de paso a 1 día no es viable $\Rightarrow$ comparar sólo 15 min vs. horario a 1 hora de anticipación).

3.2. O2. Selección de modelo sobre el conjunto de prueba

La §3.2.2 afirma: “El conjunto de prueba . . . se reserva exclusivamente para la evaluación final del modelo . . . y **no es accedido en ninguna etapa del entrenamiento ni de la selección de modelos**”. El Capítulo 4 lo contradice cuatro veces:

- **Tabla 4.5:** “presenta el método con mejor MAE en el conjunto de prueba para cada combinación de barra y estrategia”.
- **Tablas 4.6 y 4.10:** “mejor estrategia por barra según el MAE en el conjunto de prueba” (6 estrategias $\times$ 8 barras).
- **Tabla 4.30:** método de CP con menor ancho entre los que cumplen cobertura ≥ 94 %, evaluado en prueba.
- **§4.5.7:** LW-ACP se selecciona como método final por su desempeño en prueba; y $\gamma = 0,01$ se elige igualmente por resultado en prueba (§4.5.2–4.5.5).

Los *pesos* sí se estiman en validación (§3.5.1, correcto), pero el *ganador* se elige mirando el test. Con 6 estrategias por barra, el máximo de 6 realizaciones ruidosas está sesgado a la baja en MAE por construcción; los márgenes reportados (1,1–4,2 %) son del mismo orden que ese sesgo.

Atenuante importante — y que conviene explicitar en la defensa

El sesgo opera **a favor de P+C**, porque es la rama que recibe selección sobre test (S+C es una única predicción, sin estrategia que elegir). Que S+C gane igualmente en 14 de 16 combinaciones (Tabla 4.14) hace que **el hallazgo central sea más robusto, no menos**: sobrevive *a fortiori* a la corrección. Vale la pena decirlo así, en vez de esperar que la comisión lo detecte.

Remedio: rehacer toda la selección en validación (los datos ya están calculados; es reordenar tablas) y reportar el test una sola vez, para el ganador elegido en validación. Coste: un día, sin GPU.

3.3. O3. La evaluación se hace sobre una serie recortada

La §3.2.1 aplica un umbral de $\hat{\mu} + 4\hat{\sigma}$ y reemplaza por **interpolación lineal** las observaciones que lo superan; el umbral se estima en *train* pero “se aplica sin reestimación al resto de los conjuntos”. La Tabla 4.24 confirma el efecto: los máximos caen de 576,82 a 321–464 USD/MWh en todas las barras y de 1588,95 a 464,13 en Puerto Montt. Consecuencias:

1. **Las métricas de error no se calculan contra el CMg real**, sino contra una serie modificada en validación y prueba. Un MAE de 6,4 USD/MWh sobre la serie recortada no es el MAE que el modelo tendría en operación.
2. **Las garantías de cobertura de *Conformal Prediction* son sobre la serie recortada.** Esto vacía en buena medida el aporte: se cuantifica la incertidumbre de un proceso al que se le quitaron los eventos que generan incertidumbre. Todo el Capítulo 2.6 se motiva por “la volatilidad estructural en el SEN” y por “*spikes* que superan los \$300 USD/MWh”.
3. **Contradice la justificación de DyT.** La §2.4.5 argumenta que DyT se adopta porque comprime mejor los *spikes* que LayerNorm; los *spikes* más grandes fueron borrados antes de entrenar. Y la §3.2.1 dice que el umbral “preserva los *spikes* estructurales del mercado ... que deben ser aprendidos por el modelo”, lo cual es exactamente lo que la interpolación impide para el 4σ superior.
4. **Fuga menor hacia adelante en el propio *target*:** la interpolación lineal en t usa y_{t+1} ; dentro de validación y prueba, eso inyecta información futura en la variable objetivo.

Remedio: limpiar únicamente el conjunto de entrenamiento; evaluar contra la serie cruda; reportar adicionalmente métricas condicionales al régimen (horas con y_t por sobre el percentil 95, horas con $y_t = 0$). Si al hacerlo el MAE se degrada, ese es el número honesto y hay que discutirlo, no evitarlo.

3.4. O4. La inferencia estadística no soporta las conclusiones de significancia

(a) **Wilcoxon sobre errores serialmente correlacionados.** Las Tablas 4.12 y 4.26 aplican el test de rangos con signo sobre $N \approx 8.298$ errores absolutos horarios pareados. El test supone **independencia de las diferencias pareadas**. Los errores horarios de un modelo de series de tiempo están fuertemente autocorrelacionados (la propia §4.5.8 muestra que los errores grandes se agrupan en las ventanas 07:00–08:00 y 19:00–21:00). Con dependencia positiva, el tamaño muestral efectivo puede ser uno o dos órdenes de magnitud menor; los valores $p \sim 10^{-42}$ que se reportan carecen de interpretación. Además, significancia estadística con $N = 8.298$ no implica relevancia: las diferencias son de 0,03–0,44 USD/MWh sobre un MAE de 6–14.

(b) **Una sola semilla.** La §4.4.4 afirma que las diferencias LN vs. DyT “ya no son atribuibles únicamente a la variabilidad de inicialización, dado lo mostrado en la Tabla 4.12”. **La Tabla**

4.12 no puede sustentar eso: compara dos corridas únicas a lo largo del tiempo, no a lo largo de semillas. Un test temporal no separa el efecto de la arquitectura del efecto de la inicialización, porque la inicialización está confundida con la arquitectura (una realización cada una). La conclusión “LayerNorm es la opción mejor respaldada por la evidencia” es, con este diseño, indistinguible de ruido de entrenamiento. Los objetivos específicos 3 y 5 prometen exactamente esta distinción.

Remedio:

- Sustituir Wilcoxon por **Diebold–Mariano** con varianza HAC (Newey–West, $\text{lag} \sim h + 1$ o seleccionado por regla de Andrews), o por un *bootstrap* por bloques móviles. Es la práctica estándar en *electricity price forecasting*.
- Entrenar ≥ 5 semillas por arquitectura, al menos en 3 barras representativas (norte / centro / Puerto Montt), y reportar media $\pm$ desviación estándar. Si el intervalo de ± 1 sd se solapa, la conclusión correcta es “LN y DyT son equivalentes”, que además coincide con Zhu et al. y es perfectamente publicable.

3.5. O5. La comparación entre métodos de CP está confundida por el predictor puntual

La Tabla 4.20 y la §4.5.6 presentan un “linaje $\text{SCP} \rightarrow \text{ACP} \rightarrow \text{LW-ACP}$ ” en el que “cada paso aporta una mejora medible y acumulativa”. Pero los métodos **no envuelven el mismo predictor**:

Método	Predictor puntual $\hat{y}$	MAE Atacama	MAE P. Montt
Split CP (Tabla 4.15)	S+C-LN crudo	6,38	13,68
LW Split CP (Tabla 4.18)	S+C-LN crudo	6,38	13,68
LW-ACP (Tabla 4.19)	S+C-LN crudo	6,38	13,68
ACI <i>offline</i> (Tabla 4.16)	meta-modelo Ridge	6,79	15,09
ACI <i>online</i> (Tabla 4.17)	meta-modelo Ridge	6,72	14,85

El paso intermedio del “linaje” cambia el modelo base, y lo cambia **a peor** (en Puerto Montt, $13,68 \rightarrow 15,09$, un $+10,3\%$). Comparar anchos de intervalo entre métodos construidos alrededor de predictores puntuales distintos no mide el método de CP. La afirmación “ACP ya reduce el ancho medio en $11,0\%$ ” mezcla dos efectos de signo opuesto.

Remedio: fijar un único $\hat{y}$ (el crudo de S+C-LN) y aplicar las cinco variantes sobre él. Si se quiere evaluar el meta-modelo Ridge, hacerlo como una comparación separada de predictores puntuales.

3.6. O6. Métricas de intervalo insuficientes y validez sólo marginal

1. **Sólo se reportan cobertura marginal y ancho medio.** Faltan: *Winkler / interval score* (que penaliza conjuntamente ancho y no-cobertura y es la métrica correcta para ordenar métodos), *pinball loss*, y **cobertura condicional** por hora del día, por mes y por régimen de precio. Esto último es especialmente necesario dado que el aporte propuesto (LW-ACP) es precisamente una corrección *local por hora*: la evidencia natural de que funciona sería mostrar que la cobertura condicional por hora se acerca a 0,95 uniformemente, no sólo que la marginal lo hace.
2. **La cobertura casi exacta de LW-ACP está sobre-interpretada.** Que las ocho barras caigan en $[0,9497, 0,9506]$ se presenta como “un resultado infrecuente en la literatura” donde “cobertura y eficiencia compiten entre sí”. En rigor, la recursión de ACI (2.43) **fuerza** la frecuencia de no-cobertura a converger a α (ecuación 2.45, resultado de Gibbs & Candès):

la cobertura marginal casi exacta es una propiedad mecánica del mecanismo, no un logro empírico del método. Lo que sí es un logro es lograrla *con el menor ancho*, y eso debería sostenerse con un *interval score*, no con la cobertura.

3. **Intervalos simétricos para una variable con piso duro y masa puntual en cero.** El CMg tiene mínimo 0 en todas las barras (Tabla 3.1) y, a 15 minutos, es exactamente 0 en el 100 % de las observaciones de calibración de ciertas horas (§4.7.2). Una construcción $[\hat{y}-q, \hat{y}+q]$ es estructuralmente inadecuada: el límite inferior sólo se trunca en CQR (§3.7.7), no en Split CP, LW Split CP ni LW-ACP. Corresponde truncar en todos, y considerar un *score* asimétrico o un modelo tipo *hurdle* para la masa en cero.
4. **Falta el competidor natural.** AgACI (Zaffran et al., ICML 2022) — agregación en línea sobre múltiples γ — es el estado del arte directo para CP en *electricity price forecasting* y aparece en la propia tesis doctoral que la memoria cita como [21]. Es la comparación que un evaluador externo pedirá primero.
5. **El descarte de EnbPI es incorrecto** (§2.6.3): se argumenta que S+C-LN “es una única predicción del TFT sin ensamble subyacente que *bootstrapear*”. EnbPI *construye* el ensamble por *bootstrap* del propio modelo; no requiere uno preexistente. El argumento correcto es el costo computacional de entrenar B réplicas del TFT, y basta decirlo así.

3.7. O7. Ausencia del capítulo de conclusiones

El índice va de “4. Resultados y Análisis” a “Bibliografía”, pese a que la §1.5 anuncia “las conclusiones del trabajo, sintetizando los hallazgos principales y proponiendo líneas de trabajo futuro”. Como el encargo incluye evaluar las conclusiones, la Tabla 1 valora las que están dispersas en el Capítulo 4.

4. Objeciones de segundo orden

4.1. Esfuerzo de ajuste asimétrico entre modelos comparados

Prophet recibe una búsqueda en grilla de `changepoint_prior_scale` y `seasonality_prior_scale` por barra (Tabla 3.4). El TFT usa hiperparámetros fijos y no justificados (Tabla 3.5: `hidden_size=32`, 4 cabezas, `dropout` 0.2), sin ninguna búsqueda. Esto sesga dos comparaciones a la vez: (i) TFT vs. Prophet, y (ii) LN vs. DyT, que se comparan bajo una configuración que no fue optimizada para ninguna de las dos. La restricción de cómputo (12 h por modelo en PC, 3:30 h en NLHPC) es legítima y está declarada, pero debe aparecer como limitación explícita de la comparación, no sólo como dato operativo.

4.2. Inconsistencias entre marco teórico e implementación del *Stacking*

- La ecuación (2.32) minimiza **MSE**; la §3.5.1 dice que los pesos “se estiman minimizando el **MAE** sobre el conjunto de validación”. Son objetivos distintos y la ecuación (2.34) (Ridge en forma cerrada) sólo resuelve el primero.
- La ecuación (2.35) define un ensamble de **tres** modelos con $\alpha \in \mathbb{R}^3$ y regularización Ridge; la implementación (§3.5.1) sólo usa combinaciones convexas de **dos** términos con $w_1 + w_2 = 1$. La formulación de tres componentes nunca se evalúa.
- “Regresión Ridge” aparece como uno de nueve *métodos de optimización* de un problema con un grado de libertad y restricción de simplex. Ridge no resuelve ese problema: es un estimador distinto, no un optimizador alternativo del mismo objetivo. La §3.5.2 y la §4.3.1 dedican dos páginas y una tabla a mostrar que nueve métodos convergen al mismo mínimo de una función convexa unimodal en una variable; eso es esperable y se resuelve en una frase.

Tabla 1: Estado de las conclusiones sostenidas en el Capítulo 4.

Conclusión	Evidencia presentada	Estado
S+C > P+C: la estrategia simple con posición solar supera a Prophet + <i>Stacking</i> (§4.4.5)	Tabla 4.14, gana 14/16; corroborado por importancia de variables (Tablas 4.22–4.23)	Sólida. El sesgo de selección en test favorecía a P+C y aun así pierde. Es el resultado más defendible del trabajo
LayerNorm > DyT de forma sistemática (§4.4.4)	Wilcoxon 14/16 significativo; ensamble final LN gana 7/8	No establecida. Una sola semilla; test inválido por autocorrelación; $\Delta\text{MAE} \in [0,03; 0,44]$
LW-ACP domina en cobertura y eficiencia (§4.5.7)	Tablas 4.19–4.20	Parcial. Cobertura exacta es mecánica de ACI; comparación de anchos confundida por el predictor (O5); falta <i>interval score</i> y cobertura condicional
Mayor resolución temporal mejora la capacidad predictiva (§4.7.2)	Tablas 4.28, 4.31	No establecida. Confunde resolución con <i>lead time</i> ; la Tabla 4.31 controla el período pero no la anticipación
Variables hídricas no resuelven Puerto Montt (§4.7.1)	Tabla 4.25–4.26, S+H+C nunca mejor, indistinguible de H+C	Sólida como resultado negativo, dentro del alcance declarado
El TFT supera a los modelos clásicos de León et al. (§4.7.4)	Tabla 4.33	Sugerente, no concluyente. Ventanas de test distintas; el propio texto reconoce que R^2 no es comparable
El ensamble mejora a Prophet en 65–71 % (§4.3.2)	Tabla 4.6	No informativa. Prophet no usa y_t ; falta línea base ingenua (O1)

- La §2.5.2 describe con detalle el protocolo correcto de meta-features fuera de muestra por *expanding window* (Figura 2.8) — que **no es el implementado**: §3.5.1 usa un único *split* de validación. Hay que corregir el marco teórico o el *pipeline*, no dejar ambos.
- La §2.5.3 afirma que las covarianzas pequeñas “garantiza[n] que el *Stacking* produce ganancias de predicción medibles respecto a cualquiera de los modelos base por separado”. Es falso como garantía: (2.33) acota la varianza del error del ensamble, no su error total (hay sesgo), y α se estima en muestra finita. La propia Tabla 4.6 lo desmiente: en Atacama y Puerto Montt el mejor resultado es el TFT solo, con peso nulo a Prophet.

4.3. Interpretación incorrecta de ADF/KPSS (§3.1.3)

Del rechazo simultáneo de ADF ($p < 0,001$) y KPSS ($p < 0,01$) se concluye que “ambas pruebas caracterizan las series como procesos estacionarios en media pero no en varianza”. Esto es incorrecto en dos sentidos: (i) el rechazo de KPSS es precisamente el rechazo de la estacionariedad *en nivel*, de modo que no puede concluirse estacionariedad en media; (ii) ninguno de los dos tests informa sobre la varianza. Además, con $n \approx 55.000$ ambos tests tienen potencia prácticamente infinita y rechazan ante desviaciones irrelevantes; y se aplican sobre la serie completa, incluyendo el test. Por último, el análisis es **decorativo**: ni Prophet ni el TFT requieren estacionariedad, no se diferencia la serie, y ninguna decisión metodológica se deriva realmente de él (la estandarización z y los *change points* de Prophet se habrían usado igual). Conviene reescribirlo con la lectura correcta — “series con cambio estructural de nivel y heterocedasticidad,

incompatibles con un modelo lineal estacionario” — o eliminarlo.

4.4. Viabilidad operacional de las covariables

Las cinco variables climáticas provienen del **reanálisis ERA5** vía Open-Meteo. ERA5 se publica con un rezago del orden de días: en operación no está disponible para la hora actual. Como entran en **unknown_reals**, el modelo es causalmente correcto *dentro del esquema*, pero el sistema no sería implementable tal cual: requeriría *pronóstico* meteorológico, cuyo error degradaría el desempeño. Análogamente, en H+C las variables **cota_chapo** y **agua_caida_hora** son diarias y se expanden repitiendo el valor del día en sus 24 horas; si el valor del día d se usa desde las 00:00 de d , se está usando información que no está disponible a esa hora. Ambos puntos deben declararse; idealmente, repetir S+C con pronósticos meteorológicos (GFS/ECMWF operacional) para al menos una barra.

4.5. Modelos independientes por barra

La decisión (§2.1.5) es razonable, pero la justificación es más débil de lo que el propio documento muestra: la Tabla 1.1 indica que 5 de los 6 corredores permanecen acoplados más del 90 % del tiempo. Es decir, la heterogeneidad estructural que justifica separar es la excepción (Charrúa–Puerto Montt), no la regla. Además, ya se usa **serie_id** como covariable estática y la §2.3.4 explica que el enriquecimiento estático permite “aprender dinámicas temporales distintas para cada nodo **sin necesidad de entrenar instancias separadas**” — que es exactamente lo contrario de lo que se hace. Un modelo global con **serie_id** es la ablación obvia y barata (1 entrenamiento en vez de 8).

4.6. Falta la línea base institucional

El CEN publica el **costo marginal programado**. Es el *benchmark* operativo real del sector en Chile y el más persuasivo para un lector del rubro: la pregunta que importa no es “¿el TFT le gana a Prophet?” sino “¿le gana a lo que el Coordinador ya publica?”. Incorporarlo, aunque sea para una barra y un período, elevaría sustancialmente el valor aplicado del trabajo.

4.7. Ablación P+C vs. S+C no es limpia

La comparación central mezcla dos cambios simultáneos: (i) sustituir las componentes de Prophet por posición solar en **known_reals**, y (ii) eliminar el modelo de residuos y el *Stacking*. Faltan las dos celdas cruzadas del diseño 2×2 : “componentes de Prophet + TFT único sin *stacking*” y “posición solar + *stacking*”. Sin ellas no se puede atribuir la ventaja de S+C a la señal solar, que es la interpretación que se defiende.

4.8. Otros

- **Predicciones negativas de Prophet** (§3.3.3): se detectan, se explican, y no se corrigen. Prophet entra al ensamble arrastrando ese sesgo. Un *clipping* a 0, o modelar $\log(1 + y)$, o `growth='logistic'` con `floor=0`, resuelve el problema.
- **Sin evaluación económica**. El costo del error en el mercado spot es asimétrico y depende de la posición (generador vs. comercializador). Un análisis de sensibilidad con una función de pérdida asimétrica daría al trabajo su cierre aplicado.
- **Reproducibilidad**. No se declaran semillas, versiones de librerías, *commit* del repositorio ni disponibilidad del código. Dado que hubo un *bug* corregido a mitad de camino, esto es especialmente necesario.

5. Errores puntuales y consistencia numérica

5.1. Contradicción numérica entre las Tablas 4.5 y 4.6

La Tabla 4.5 declara contener, para cada barra y estrategia, el **mejor** MAE de prueba entre los nueve optimizadores. La Tabla 4.6 reporta valores **menores** para la misma estrategia (P+R)+TFT precios, con pesos distintos:

Barra	MAE Tabla 4.5	pesos T4.5	MAE Tabla 4.6	pesos T4.6
Cardones	6,71	0,400/0,600	6,50	0,598/0,402
Charrúa	8,30	0,450/0,550	8,07	0,427/0,573
Crucero	6,92	0,490/0,510	6,55	0,549/0,451
Tarapacá	6,94	0,500/0,500	6,72	0,427/0,573
Pan de Azúcar	6,84	0,405/0,595	6,92	0,206/0,794
Quillota	8,16	0,400/0,600	8,30	0,402/0,598
Puerto Montt	14,32 (TFT solo)	—	13,94 (TFT solo)	—

La Tabla 4.6 *sí* es internamente consistente con la Tabla 4.2 vía la columna Δ TFT (p. ej. Cardones: $6,78 \times (1 - 0,0424) = 6,49 \approx 6,50$), y la Tabla 4.10 lo es con la Tabla 4.7. Todo indica que **la Tabla 4.5 quedó en una versión anterior a la corrección del *bug* documentado en la nota al pie de §4.2**. Hay que regenerarla o eliminarla; tal como está, un evaluador que cruce ambas tablas encuentra una contradicción en el resultado principal del capítulo.

5.2. Otros puntos verificables

- **Tabla 3.1:** el máximo es exactamente 576,82 USD/MWh en 7 de las 8 barras. Requiere explicación (¿mismo evento sistémico? ¿tope administrativo?). Si es un tope, corresponde tratarlo como censura, no como dato.
- **Tabla 4.16:** para Charrúa el ancho no es monótono en γ (63,55 / 64,13 / 61,68 para $\gamma = 0,01/0,05/0,10$). Conviene verificar o comentar.
- **§4.7.2,** colapso de $\hat{\sigma}_h$ a 15 minutos (ancho 197,21): se documenta bien y no se corrige. Un piso de varianza, $\hat{\sigma}_h \leftarrow \max(\hat{\sigma}_h, \varepsilon \hat{\sigma}_{\text{global}})$ con $\varepsilon \sim 0,1$, es una línea de código en la ecuación (2.47).
- **Citas:** el Teorema 2.6.1 y la §3.7.2 atribuyen a Lei et al. el año 2005, pero la entrada [9] (“*Distribution-free predictive inference for regression*, JASA”) es de 2018; 2005 corresponde a Vovk et al. [16], citado sin número en §3.7.2. En §4.5.6 se cita “Zaffran et al. (2022)” donde la bibliografía tiene “Zaffran (2024), tesis doctoral” [21] — probablemente se quiso citar el artículo ICML 2022, que falta.
- **Citas huérfanas:** [8] (Huang et al., *Combining Prophet and Transformer models*) es el **antecedente más directo de esta tesis** y no se discute en ninguna parte del texto; [22] (Informer) nunca se usa.
- **Bibliografía:** títulos truncados en [5] (“... tras superar el 40”) y [7] (“... aumentan 219”); [17] con “*InternationalJournalofForecasting*” sin espacios; [2] atribuido a “*Stats Machine Learning*”; ausencia generalizada de volumen, páginas y DOI. 23 referencias es escaso para una tesis de magíster; falta la literatura canónica de EPF: Lago et al. (2021), *Forecasting day-ahead electricity prices: a review of state-of-the-art algorithms, best practices and an open-access benchmark*, que además define el protocolo de evaluación (LEAR, DNN, test DM) que resolvería O1 y O4 de una vez.
- **Redacción:** “modelo de *forecasting* se series temporales” (p. 13); paréntesis desbalanceado en el exponente de (2.7); “*missing values*” sin cursiva ni traducción; uso mezclado de coma y punto decimal entre tablas y texto.

6. Plan de corrección priorizado

#	Acción	Esfuerzo	Requiere GPU
P0 — bloqueantes para la defensa			
1	Líneas base ingenuas sobre el mismo test: persistencia, <i>naive</i> 24 h y 168 h, $AR(p)$. Reportar MASE y <i>skill score</i> en todas las tablas del Cap. 4	0,5 día	No
2	Rehacer toda selección (estrategia, optimizador, variante de CP, γ) en validación ; reportar test una sola vez	1 día	No
3	Limpiar <i>outliers</i> sólo en <i>train</i> ; reevaluar contra la serie cruda; añadir métricas condicionales al régimen	1 día	No
4	Escribir Capítulo 5 (Conclusiones y trabajo futuro), Resumen, <i>Abstract</i> ; eliminar <i>lorem ipsum</i> del Anexo	2–3 días	No
5	Reemplazar Wilcoxon por Diebold–Mariano con varianza HAC	0,5 día	No
6	Regenerar o eliminar la Tabla 4.5 (contradice a la 4.6)	0,2 día	No
P1 — fortalecen sustancialmente el trabajo			
7	≥ 5 semillas por arquitectura en 3 barras; reportar media $\pm$ sd para LN vs. DyT	2 días	Sí
8	Rehacer la comparación de CP con un único predictor puntual; añadir <i>interval score</i> de Winkler y cobertura condicional por hora y por mes	1 día	No
9	Repetir S+C a $h = 24$ (<i>day-ahead</i>) para 3 barras; es el horizonte que la motivación exige	2–3 días	Sí
10	Corregir §2.5 (MSE vs. MAE, 3 vs. 2 componentes, protocolo <i>expanding window</i>) y §3.1.3 (ADF/KPSS)	1 día	No
11	Bibliografía completa y corregida; discutir Huang et al. [8]; incorporar Lago et al. (2021) y Zaffran et al. (ICML 2022)	1 día	No
P2 — deseables			
12	Piso de varianza en $\hat{\sigma}_h$; truncar en 0 el límite inferior de <i>todos</i> los intervalos	0,2 día	No
13	Ablación limpia 2×2 para P+C vs. S+C	1–2 días	Sí
14	Modelo global único con serie_id como ablación frente a los 8 modelos independientes	1 día	Sí
15	Línea base institucional: costo marginal programado del CEN	1–2 días	No
16	<i>Clipping</i> a 0 de Prophet; reducir §3.5.2/§4.3.1 (nueve optimizadores) a un párrafo	0,5 día	No
17	Declarar semillas, versiones, <i>commit</i> y disponibilidad del código	0,2 día	No

Con P0 completo el trabajo es defendible. P0 + P1 lo convierten en material publicable en una revista aplicada del área.

7. Preguntas previsibles en la defensa

1. ¿Cuál es el MAE de una predicción de persistencia ($\hat{y}_{t+1} = y_t$) sobre el mismo conjunto de prueba, y cuál es el MASE del modelo?
2. En la §4.5.8, 16 de 17 desfases tienen desplazamiento óptimo *positivo* de ≈ 1 hora. ¿Cómo se descarta que el modelo esté aprendiendo esencialmente persistencia?
3. La §3.2.2 afirma que el test no se usa en la selección de modelos, pero las Tablas 4.5, 4.6, 4.10 y 4.30 seleccionan por MAE de prueba. ¿Cómo cambian los resultados si se selecciona en validación?
4. Los *outliers* se interpolan también en validación y prueba. ¿Cuál es la cobertura de LW-ACP sobre la serie *cruda*, con los *spikes* incluidos?
5. ¿Cuántas semillas se entrenaron por arquitectura? Si es una, ¿cómo se separa el efecto LayerNorm/DyT del efecto de inicialización?
6. El test de Wilcoxon supone diferencias pareadas independientes. Con errores horarios autocorrelacionados, ¿qué significa un $p = 10^{-42}$?
7. ACI usa un predictor Ridge con MAE peor que el crudo de S+C-LN. ¿Es válido comparar anchos de intervalo entre métodos con predictores distintos?
8. En el estudio de granularidad se mantiene $h = 1$ *paso*. ¿No se está comparando predecir a 24 h, 1 h y 15 min, en vez de comparar resoluciones?
9. Las variables climáticas provienen de reanálisis ERA5, no disponible en tiempo real. ¿Qué desempeño tendría el modelo con pronósticos meteorológicos operacionales?
10. ¿Por qué las Tablas 4.5 y 4.6 reportan MAE distintos para la misma estrategia y barra?
11. El objetivo declarado menciona programación del despacho y valorización de contratos. ¿Qué decisión concreta se apoya con una predicción a una hora?
12. ¿Cómo se compara el modelo con el costo marginal programado que publica el Coordinador?

8. Cierre

El trabajo demuestra competencia técnica sólida — implementación completa del TFT con dos mecanismos de normalización, cinco variantes de *Conformal Prediction*, un aporte propio (LW-ACP) razonablemente motivado por un diagnóstico empírico real de heterocedasticidad horaria, y un análisis de errores extremos de calidad —, y una disposición a reportar resultados que contradicen las propias hipótesis que es infrecuente y valiosa.

El problema no es de ejecución sino de **diseño experimental**: el trabajo mide con mucho cuidado diferencias entre variantes de sí mismo, sin haber fijado antes un punto de referencia externo que permita saber si el conjunto es bueno. Corregido eso — una línea base ingenua, selección en validación, evaluación sobre la serie real y tests apropiados a datos dependientes —, las conclusiones que sobrevivan estarán bien sostenidas, y la principal (que la señal física de posición solar hace innecesaria la descomposición estadística intermedia) es una conclusión interesante y con contenido.