Estimación del Costo Marginal en el SEN mediante Temporal Fusion Transformer: Comparación de Estrategias de Variables Exógenas, Arquitecturas y Cuantificación de Incertidumbre

Edward Benjamín Mitchell García

Departamento de Ingeniería Matemática
Facultad de Ciencias Físicas y Matemáticas
Universidad de Chile

Profesor guía: Alejandro Jofré Cáceres

2026

Contenidos

1. Motivación y objetivos
2. Datos
3. Metodología
4. Resultados
5. Conclusiones

El SEN en transición

- El Sistema Eléctrico Nacional (SEN) chileno ha experimentado una transición acelerada hacia generación solar: la participación ERNC pasó de $\sim$20 % a $\sim$40 % de la generación total desde 2020.
- Esto introduce **volatilidad estructural creciente** en el costo marginal horario: episodios de sobreoferta solar (*curtailment*) y transiciones de precio abruptas al entrar/salir el bloque fotovoltaico.
- En 2024 se perdieron **5 908,71 GWh** de energía renovable por *curtailment*, un aumento del **149 %** respecto al año anterior.
- Los métodos estadísticos clásicos (ARIMA, modelos de descomposición) capturan mal esta dinámica no lineal y cambiante.
- **Pregunta**: ¿puede un modelo híbrido de *deep learning*, con una señal exógena simple y determinista, mejorar el pronóstico horario y cuantificar honestamente su incertidumbre?

Objetivos

Objetivo general

- Desarrollar y evaluar un modelo híbrido basado en Temporal Fusion Transformer (TFT) para el pronóstico horario del costo marginal en el SEN, con cuantificación de incertidumbre calibrada.

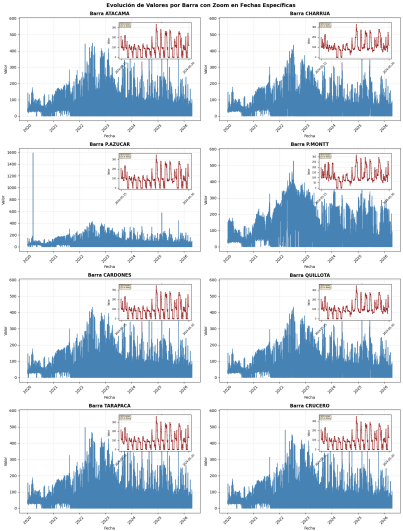
Objetivos específicos

- Comparar dos estrategias de *features* exógenas: Prophet+Clima (P+C) vs. Sol+Clima (S+C).
- Comparar dos mecanismos de normalización del Transformer: LayerNorm vs. Dynamic Tanh.
- Proponer y evaluar LW-ACP, un método de Conformal Prediction que combina ponderación horaria con adaptación *online*.
- Caracterizar mecanísticamente los errores más extremos del modelo.

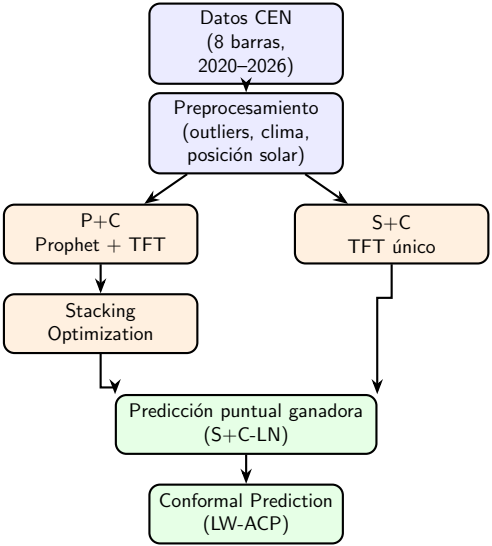
Datos

- Fuente: Coordinador Eléctrico Nacional (CEN) de Chile.
- Variable objetivo: costo marginal horario, enero 2020 – abril 2026 ($\sim$55 000 obs. por barra).
- Ocho barras de 220 kV, seleccionadas por representatividad geográfica:
  - Norte (solar/eólico): Atacama, Cardones, Crucero, Pan de Azúcar, Tarapacá
  - Centro: Quillota
  - Sur (hidroeléctrico): Charrúa, Puerto Montt
- División temporal estricta: 70 % entrenamiento / 15 % validación / 15 % prueba, respetando causalidad.

Serie de costo marginal por barra



Pipeline general



Todos los modelos se entrenan de forma independiente por barra.

Dos estrategias de *features* exógenas

P+C: Prophet + Clima

- Prophet descompone la serie en tendencia + estacionalidad.
- El TFT modela tanto el precio como el residuo de Prophet.
- Stacking Optimization combina ambas predicciones.

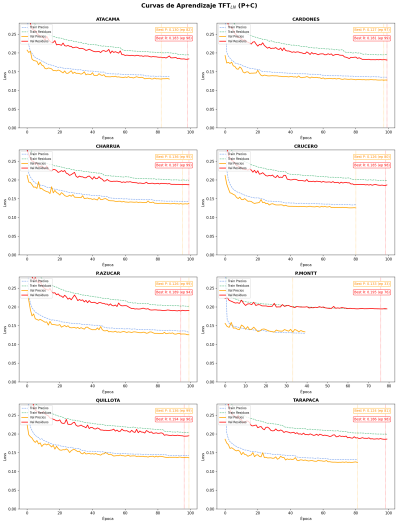
S+C: Sol + Clima

- Reemplaza la descomposición de Prophet por variables de posición solar (elevación, coseno de elevación) calculadas de forma **determinista** vía `pvlib`.
- Una única instancia del TFT, sin Stacking.
- Más simple: no requiere ajustar Prophet ni un segundo modelo de residuos.

Temporal Fusion Transformer

- Arquitectura de *deep learning* para forecasting de series de tiempo con atención interpretable (Lim et al., 2021).
- Ventana de contexto: 168 horas (1 semana). Horizonte principal: $h = 1$ hora.
- Se entrena minimizando MAE directamente (no la pérdida cuantílica original del TFT), dejando la cuantificación de incertidumbre a Conformal Prediction.
- Se comparan dos mecanismos de normalización interna:
  - **LayerNorm (LN)**: normalización local, por paso temporal.
  - **Dynamic Tanh (DyT)**: un único escalar α global aprendido, sin normalización explícita.

Curvas de aprendizaje



Conformal Prediction: de Split CP a LW-ACP

Split CP $\longrightarrow$ **ACI** $\longrightarrow$ **LW-ACP**

- **Split CP** (clásico): un cuantil fijo q, calculado una vez sobre calibración.
- **ACI** (Gibbs & Candès, 2021): adapta el nivel de cobertura α_t *online* según los aciertos/fallos recientes.
- **LW Split CP**: normaliza el *score* de no conformidad por la desviación estándar de cada hora del día $\hat{\sigma}_h$ (heterocedasticidad horaria).
- **LW-ACP (contribución de este trabajo)**: combina ambos mecanismos (ponderación horaria *y* adaptación *online*) en un solo método.

S+C supera a P+C

	S+C mejor	**Significativo (DM)**
De 16 combinaciones (8 barras $\times$ 2 arq.)	14	13

- S+C, la estrategia más simple, supera a P+C en 14 de 16 combinaciones (13 estadísticamente significativas, test de Diebold-Mariano con varianza Newey-West).
- El análisis de interpretabilidad del TFT confirma que la posición solar domina el decoder en 6 de las 8 barras: el modelo efectivamente aprende a usar esa señal.
- Conclusión: la señal física de posición solar es al menos tan informativa como la descomposición estadística de Prophet, con menor complejidad de pipeline.

Interpretabilidad: importancia de variables en el decoder

- El decoder de S+C-LN solo recibe las tres variables solares y el índice temporal relativo.

Barra	elevacion_solar	relative_time_idx	cos_elevacion	es_horario_verano
Atacama	26.33	31.59	23.82	18.27
Cardones	27.72	41.78	21.02	9.47
Charrúa	33.04	40.35	9.29	17.32
Crucero	63.46	7.94	13.80	14.80
Pan de Azúcar	44.28	20.43	15.30	19.99
Puerto Montt	16.86	44.77	30.04	8.33
Quillota	46.88	12.25	24.68	16.19
Tarapacá	39.25	29.94	9.84	20.97

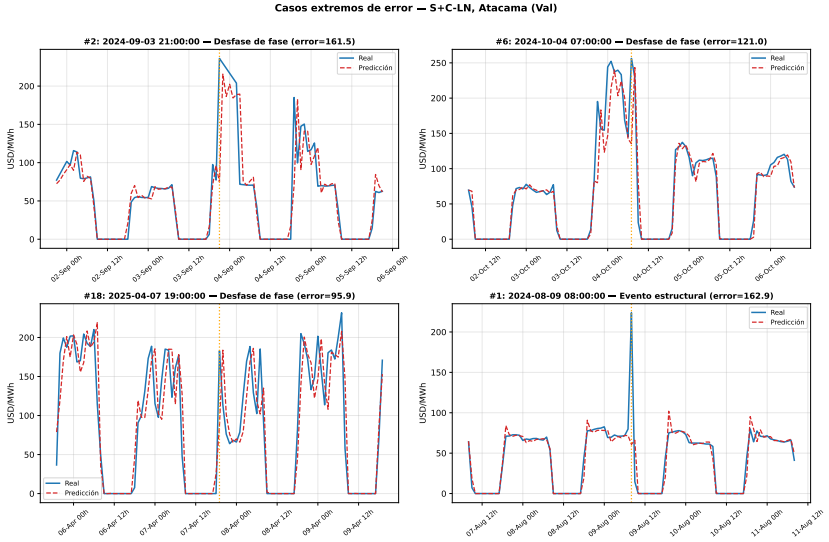
- Sumando `elevacion_solar` + `cos_elevacion`: la posición solar domina el decoder (42.3 %–77.3 %) en **6 de las 8 barras**.
- Puerto Montt es la excepción más clara: `relative_time_idx` lidera (44.8 %) por sobre la posición solar (16.9 %).

LayerNorm vs. Dynamic Tanh

	Significativas (DM)	**LN gana**	**Dif. típica**
De 16 combinaciones	12	11 de 12	$< 0{,}5\,\text{USD/MWh}$

- LN supera a DyT de forma **sistemática, aunque de magnitud pequeña**: gana en 11 de 12 combinaciones estadísticamente significativas (Diebold-Mariano pareado por hora).
- **Robustez a la semilla**: al repetir el entrenamiento con 5 semillas distintas, los intervalos de MAE de LN y DyT se solapan completamente en las 3 barras piloto.
  - La ventaja de LN es del mismo orden de magnitud que la variabilidad de inicialización.
  - No la contradice: el test DM compara errores pareados hora a hora dentro de una misma semilla, evidencia de un tipo distinto.

Análisis de errores extremos: desfase de fase



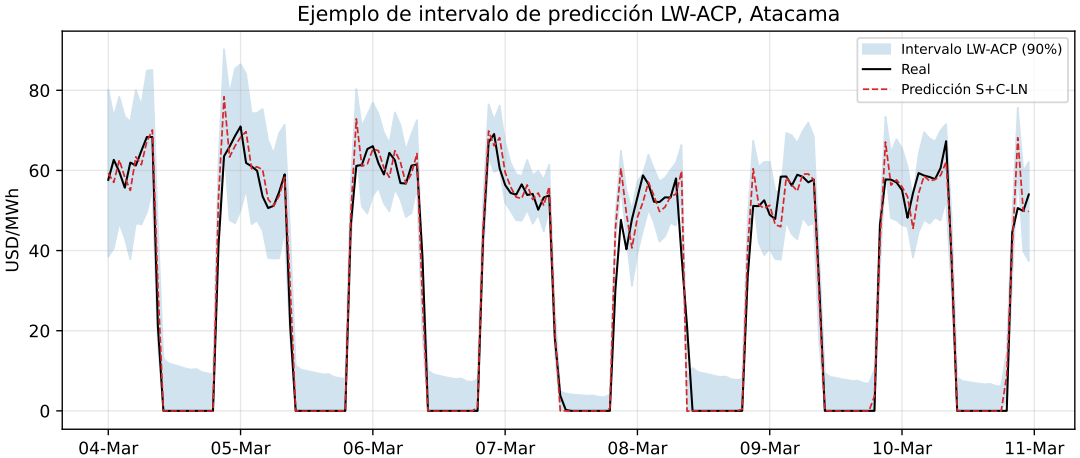
Análisis de errores extremos: desfase de fase

- Entre el 80 % y el 100 % de los veinte mayores errores de validación, en las ocho barras, corresponden a un **desfase de fase**: el modelo predice correctamente la magnitud de la transición diaria, pero con $\sim$1 hora de retraso.
- Patrón consistente en todo el SEN, no un artefacto de una barra particular.
- Errores de gran amplitud pero muy localizados en el tiempo $\Rightarrow$ motiva directamente el valor de Conformal Prediction adaptativo y ponderado por hora.

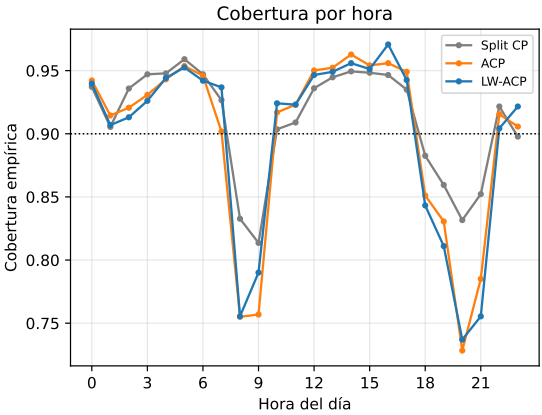
Puerto Montt: un caso no resuelto

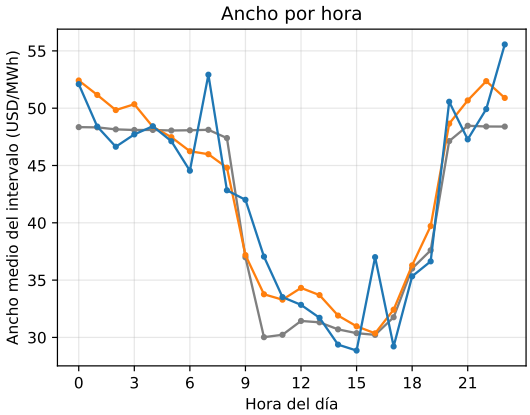
- Peor desempeño del sistema de forma consistente: MAE de prueba 13.68 USD/MWh vs. 6.4–8.0 USD/MWh del resto.
- Media y desviación estándar de precio sustancialmente mayores: dependencia hidrológica de baja frecuencia (meses), más lenta que la ventana de contexto del TFT (168h).
- Se probaron *features* hídricas propias (cota del embalse, agua caída) en variantes H+C y S+H+C: **no lograron mejorar** sobre S+C.
- Puerto Montt también exhibe desfase de fase, pero no ligado al ciclo solar como el resto del SEN.
- Queda documentado como un caso estructuralmente distinto, no resuelto por las extensiones exploradas.

LW-ACP: ejemplo de intervalo



LW-ACP: cobertura y ancho por hora





Resultados de Conformal Prediction (90 % nominal)

Método	**Ancho**	**|Cob−0.90|**	**Winkler**	**Pinball**
Split CP	40.90	0.0112	76.65	1.916
LW Split CP	**40.69**	0.0108	76.23	1.906
ACI ($\gamma = 0{,}05$)	42.21	**0.0023**	72.31	1.808
LW-ACP ($\gamma = 0{,}05$)	41.98	0.0024	**71.87**	**1.797**
CQR	43.04	0.0142	72.53	1.813

- 90 % es el nivel principal en la literatura de CP para mercados eléctricos (Kath & Ziel; Zaffran).
- Ningún método domina las cuatro métricas, pero LW-ACP gana en Winkler y pinball, las que combinan ancho y calibración.
- La adaptación *online* aumenta el ancho 2.6–3.2 %, pero reduce la desviación de cobertura en 79 %.
- Al 95 % LW-ACP sí domina todo: 58.25 USD/MWh, 8.7 % más angosto que Split CP.
- Sub-cobertura en horas de transición solar (0.799 vs. 0.90), el mismo mecanismo que el desfase de fase.

Comparación contra el CEN

Barra	MAE TFT	MAE CEN	Mejora
Puerto Montt	**13.68**	32.98	58.5 %
Crucero	**6.74**	17.10	60.6 %
Cardones	**6.63**	14.52	54.4 %
Pan de Azúcar	**6.93**	15.09	54.1 %
Charrúa	**7.98**	17.01	53.1 %
Quillota	**8.26**	17.26	52.1 %

- Se compara S+C-LN contra el *costo marginal programado* que el CEN publica operacionalmente (vía API pública), ambos evaluados contra el costo marginal real.
- Reducción de MAE entre **52.1 % y 60.6 %** (promedio 55.5 %) en las 6 barras donde se identificó el mnemotécnico, incluyendo Puerto Montt, el caso menos favorable.
- No es evidencia de que el CEN pronostique mal: su costo marginal programado resuelve un problema distinto (despacho óptimo del sistema, con restricciones físicas), no un pronóstico estadístico puntual.
- Sí evidencia que un pronóstico dedicado, sin esas restricciones operativas, puede superar sistemáticamente la cifra que circula en el mercado antes del despacho real.

Comparación con la literatura

- León et al. (2026) comparan modelos de *machine learning* clásico (RFR, SVR, etc.) para el SEN en Crucero, Alto Jahuel y Puerto Montt, con datos de 2024.
- Se entrenan dos TFT S+C adicionales, restringidos a 2024, para Crucero y Puerto Montt (barras compartidas).

Barra	MAE (este trabajo)	MAE (mejor de León et al.)
Crucero	5.11	7.71
Puerto Montt	13.64	17.11

- Reducción de MAE de **20 % a 34 %**, pese a entrenar con menos de un año de datos y sin ajuste específico por barra.

Extensiones exploradas

- **Horizonte day-ahead ($h = 24$)**: el modelo se degrada monótonamente con el horizonte; *skill score* negativo en 7/10 combinaciones. Aumentar la capacidad del modelo mejora el MAE (2.5–5.1 %) pero no revierte el signo.
- **Piloto sin recorte de outliers**: a $h = 1$, en las ocho barras, no perjudica el MAE general y reduce los errores más grandes (error máximo menor en las 8 barras, MAE en el percentil 99 menor en 7); significativo individualmente solo en 2 barras. Resultado mixto a $h = 24$ (4 barras).
- **Granularidad temporal**: mayor resolución (15 min) mejora la capacidad predictiva de forma consistente, controlando por período histórico.
- **Sensibilidad a pérdida asimétrica**: la ventaja de S+C-LN se sostiene en 7 de 8 barras independientemente de qué error sea más costoso.

Conclusiones principales

1. **La estrategia más simple es la más precisa**: S+C supera a P+C, con la posición solar dominando el decoder del TFT.
2. **LW-ACP** combina ponderación horaria y adaptación *online*, logrando el mejor Winkler y pinball al 90 % con cobertura calibrada, y los intervalos más angostos al 95 %.
3. Los errores más extremos siguen un patrón mecanístico común (desfase de fase de $\sim$1h), no ruido aleatorio disperso.
4. El modelo supera de forma sistemática tanto al costo marginal programado del CEN como a literatura reciente de ML clásico.
5. Puerto Montt permanece como un caso no resuelto, estructuralmente distinto al resto del SEN.

Limitaciones

- Un único split cronológico entrenamiento/validación/prueba (no *walk-forward validation*) por costo computacional.
- Sin semilla fija para los modelos principales del Capítulo 4 (sí para el estudio de robustez).
- Esfuerzo de ajuste de hiperparámetros asimétrico entre Prophet (optimizado por barra) y TFT (fijo).
- Reproducibilidad parcial del entorno de entrenamiento en GPU (versiones de librerías del cluster no registradas).
- Pipeline no directamente desplegable en operación real: ERA5 se publica con rezago.

Trabajo futuro

- Comparar LW-ACP contra AgACI (agregación de múltiples γ vía expertos *online*).
- Extender la comparación contra el CEN a Atacama y Tarapacá.
- *Walk-forward validation* sobre múltiples ventanas rodantes.
- Investigar directamente el mecanismo del desfase de fase (pérdida que penalice error de temporización).
- Extender el estudio de granularidad a las ocho barras y el piloto de outliers a las ocho barras a $h = 24$.
- LW-ACP con adaptación *online* indexada por hora del día.

Gracias

github.com/benjamitchell/Tesis-TFT-Electricidad