# Estimación del Costo Marginal en el SEN mediante Temporal Fusion Transformer: Comparación de Estrategias de Variables Exógenas, Arquitecturas y Cuantificación de Incertidumbre

Edward Benjamín Mitchell García

Departamento de Ingeniería Matemática
Facultad de Ciencias Físicas y Matemáticas
Universidad de Chile

Profesor guía: Alejandro Jofré Cáceres

2026

# Contenidos


1. Motivación y objetivos
2. Datos
3. Metodología
4. Resultados
5. Horizonte de pronóstico
6. Conclusiones

# El SEN en transición

- El Sistema Eléctrico Nacional (SEN) chileno ha experimentado una transición acelerada hacia generación solar: la participación ERNC pasó de $\sim$20 % a $\sim$40 % de la generación total desde 2020.
- Esto introduce **volatilidad estructural creciente** en el costo marginal horario: episodios de sobreoferta solar (*curtailment*) y transiciones de precio abruptas al entrar/salir el bloque fotovoltaico.
- En 2024 se perdieron **5 908,71 GWh** de energía renovable por *curtailment*, un aumento del **149 %** respecto al año anterior.
- Los métodos estadísticos clásicos (ARIMA, modelos de descomposición) capturan mal esta dinámica no lineal y cambiante.
- **Pregunta**: ¿puede un modelo híbrido de *deep learning*, con una señal exógena simple y determinista, mejorar el pronóstico horario y cuantificar honestamente su incertidumbre?

# Objetivos

**Objetivo general**

- Desarrollar y evaluar un modelo híbrido basado en Temporal Fusion Transformer (TFT) para el pronóstico horario del costo marginal en el SEN, con cuantificación de incertidumbre calibrada.

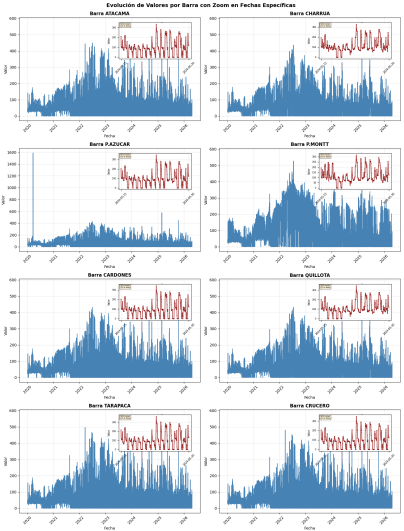
**Objetivos específicos**

- Comparar dos estrategias de *features* exógenas: Prophet+Clima (P+C) vs. Sol+Clima (S+C).
- Comparar dos mecanismos de normalización del Transformer: LayerNorm vs. Dynamic Tanh.
- Proponer y evaluar LW-ACP, un método de Conformal Prediction que combina ponderación horaria con adaptación *online*.
- Caracterizar mecanísticamente los errores más extremos del modelo.

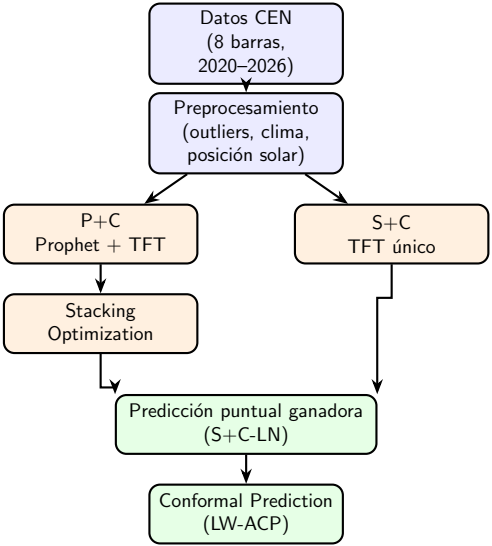
# Datos

- Fuente: Coordinador Eléctrico Nacional (CEN) de Chile.
- Variable objetivo: costo marginal horario, enero 2020 – abril 2026 ($\sim$55 000 obs. por barra).
- Ocho barras de 220 kV, seleccionadas por representatividad geográfica:
  - Norte (solar/eólico): Atacama, Cardones, Crucero, Pan de Azúcar, Tarapacá
  - Centro: Quillota
  - Sur (hidroeléctrico): Charrúa, Puerto Montt
- División temporal estricta: 70 % entrenamiento / 15 % validación / 15 % prueba, respetando causalidad.

# Serie de costo marginal por barra



# Pipeline general




*Todos los modelos se entrenan de forma independiente por barra.*

# Dos estrategias de *features* exógenas

**P+C: Prophet + Clima**

- Prophet descompone la serie en tendencia + estacionalidad.
- El TFT modela tanto el precio como el residuo de Prophet.
- Stacking Optimization combina ambas predicciones.

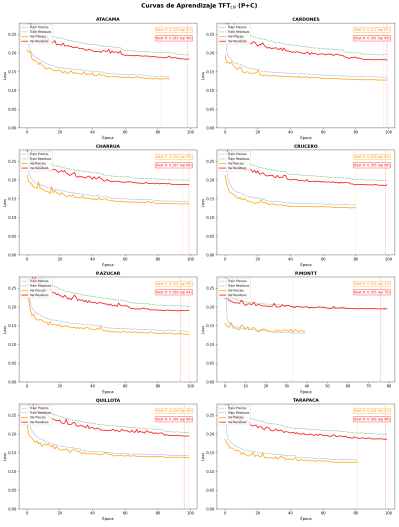
**S+C: Sol + Clima**

- Reemplaza la descomposición de Prophet por variables de posición solar (elevación, coseno de elevación) calculadas de forma **determinista** vía `pvlib`.
- Una única instancia del TFT, sin Stacking.
- Más simple: no requiere ajustar Prophet ni un segundo modelo de residuos.

# Temporal Fusion Transformer

- Arquitectura de *deep learning* para forecasting de series de tiempo con atención interpretable (Lim et al., 2021).
- Ventana de contexto: 168 horas (1 semana). Horizonte principal: $h = 1$ hora.
- Se entrena minimizando MAE directamente (no la pérdida cuantílica original del TFT), dejando la cuantificación de incertidumbre a Conformal Prediction.
- Se comparan dos mecanismos de normalización interna:
  - **LayerNorm (LN)**: normalización local, por paso temporal.
  - **Dynamic Tanh (DyT)**: un único escalar $\alpha$ global aprendido, sin normalización explícita.

# Curvas de aprendizaje



# Conformal Prediction: de Split CP a LW-ACP

**Split CP** $\longrightarrow$ **ACI** $\longrightarrow$ **LW-ACP**

- **Split CP** (clásico): un cuantil fijo $q$, calculado una vez sobre calibración.
- **ACI** (Gibbs & Candès, 2021): adapta el nivel de cobertura $\alpha_t$ *online* según los aciertos/fallos recientes.
- **LW Split CP**: normaliza el *score* de no conformidad por la desviación estándar de cada hora del día $\hat{\sigma}_h$ (heterocedasticidad horaria).
- **LW-ACP (contribución de este trabajo)**: combina ambos mecanismos (ponderación horaria *y* adaptación *online*) en un solo método.

# S+C supera a P+C

| | **S+C mejor** | **Significativo (DM)** |
|---|---|---|
| De 16 combinaciones (8 barras $\times$ 2 arq.) | 14 | 13 |

- S+C, la estrategia más simple, supera a P+C en 14 de 16 combinaciones (13 estadísticamente significativas, test de Diebold-Mariano con varianza Newey-West).
- El análisis de interpretabilidad del TFT confirma que la posición solar domina el decoder en 6 de las 8 barras: el modelo efectivamente aprende a usar esa señal.
- Conclusión: la señal física de posición solar es al menos tan informativa como la descomposición estadística de Prophet, con menor complejidad de pipeline.

# Interpretabilidad: importancia de variables en el decoder

- El decoder de S+C-LN solo recibe las tres variables solares y el índice temporal relativo.

| Barra | elevacion_solar | relative_time_idx | cos_elevacion | es_horario_verano |
|---|---|---|---|---|
| Atacama | 26.33 | 31.59 | 23.82 | 18.27 |
| Cardones | 27.72 | 41.78 | 21.02 | 9.47 |
| Charrúa | 33.04 | 40.35 | 9.29 | 17.32 |
| Crucero | 63.46 | 7.94 | 13.80 | 14.80 |
| Pan de Azúcar | 44.28 | 20.43 | 15.30 | 19.99 |
| Puerto Montt | 16.86 | 44.77 | 30.04 | 8.33 |
| Quillota | 46.88 | 12.25 | 24.68 | 16.19 |
| Tarapacá | 39.25 | 29.94 | 9.84 | 20.97 |

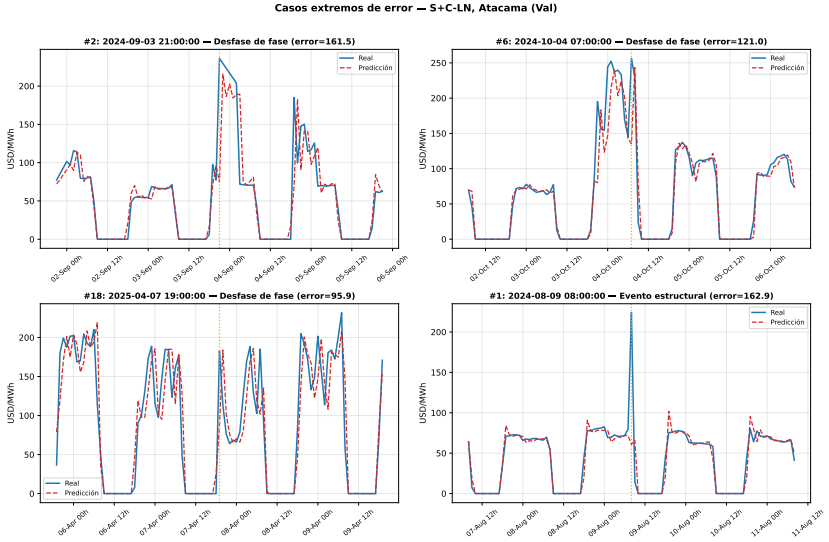
- Sumando `elevacion_solar` + `cos_elevacion`: la posición solar domina el decoder (42.3 %–77.3 %) en **6 de las 8 barras**.
- Puerto Montt es la excepción más clara: `relative_time_idx` lidera (44.8 %) por sobre la posición solar (16.9 %).

# LayerNorm vs. Dynamic Tanh

| | **Significativas (DM)** | **LN gana** | **Dif. típica** |
|---|---|---|---|
| De 16 combinaciones | 12 | 11 de 12 | $< 0{,}5$ USD/MWh |

- A una hora LN gana en 11 de 12 combinaciones significativas, pero la ventaja **no supera la variabilidad entre semillas ni se mantiene a 24 horas**: en la práctica, ambas son equivalentes.
- **Robustez a la semilla**: al repetir el entrenamiento con 5 semillas distintas, los intervalos de MAE de LN y DyT se solapan completamente en las 3 barras piloto.
  - La ventaja de LN es del mismo orden de magnitud que la variabilidad de inicialización.
  - No la contradice: el test DM compara errores pareados hora a hora dentro de una misma semilla, evidencia de un tipo distinto.

# Análisis de errores extremos: desfase de fase



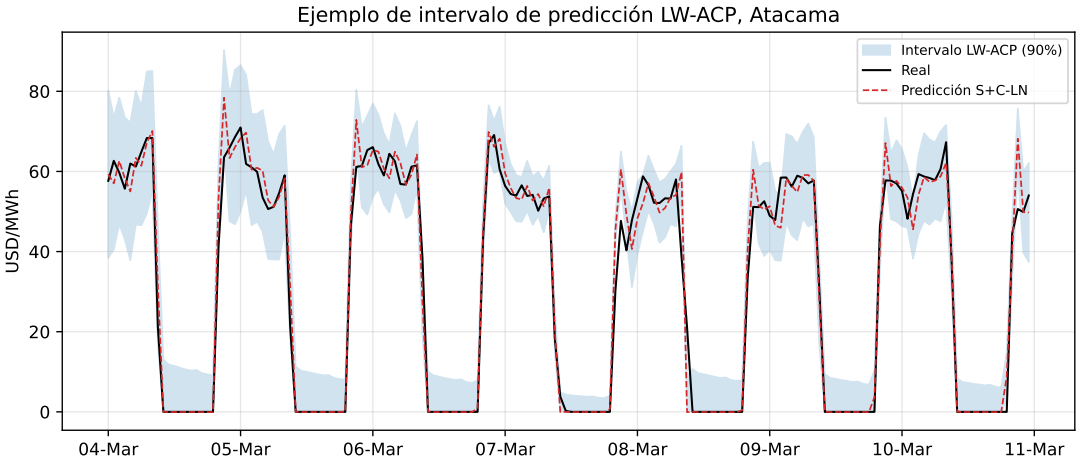
# Análisis de errores extremos: desfase de fase

- Entre el 80 % y el 100 % de los veinte mayores errores de validación, en las ocho barras, corresponden a un **desfase de fase**: el modelo predice correctamente la magnitud de la transición diaria, pero con $\sim$1 hora de retraso.
- Patrón consistente en todo el SEN, no un artefacto de una barra particular.
- Errores de gran amplitud pero muy localizados en el tiempo $\Rightarrow$ motiva directamente el valor de Conformal Prediction adaptativo y ponderado por hora.

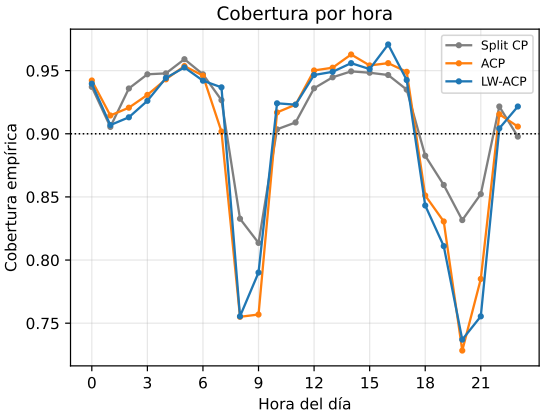
# Puerto Montt: un caso no resuelto

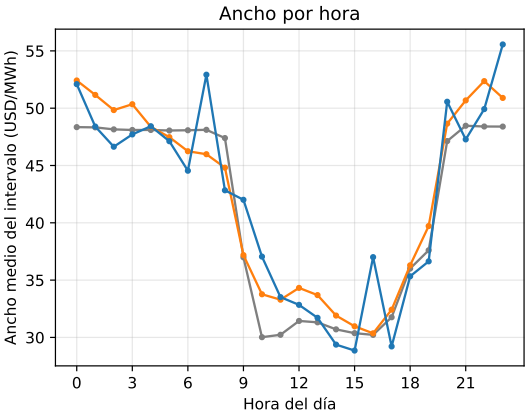
- Peor desempeño del sistema de forma consistente: MAE de prueba 13.68 USD/MWh vs. 6.4–8.0 USD/MWh del resto.
- Media y desviación estándar de precio sustancialmente mayores: dependencia hidrológica de baja frecuencia (meses), más lenta que la ventana de contexto del TFT (168h).
- Se probaron *features* hídricas propias (cota del embalse, agua caída) en variantes H+C y S+H+C: **no lograron mejorar** sobre S+C.
- Puerto Montt también exhibe desfase de fase, pero no ligado al ciclo solar como el resto del SEN.
- Queda documentado como un caso estructuralmente distinto, no resuelto por las extensiones exploradas.

# LW-ACP: ejemplo de intervalo



# LW-ACP: cobertura y ancho por hora



# Resultados de Conformal Prediction (90 % nominal)

| **Método** | **Ancho** | **\|Cob−0.90\|** | **Winkler** | **Pinball** |
|---|---|---|---|---|
| Split CP | 40.90 | 0.0112 | 76.65 | 1.916 |
| LW Split CP | **40.69** | 0.0108 | 76.23 | 1.906 |
| ACI ($\gamma = 0{,}05$) | 42.21 | **0.0023** | 72.31 | 1.808 |
| LW-ACP ($\gamma = 0{,}05$) | 41.98 | 0.0024 | **71.87** | **1.797** |
| CQR | 43.04 | 0.0142 | 72.53 | 1.813 |

- 90 % es el nivel principal en la literatura de CP para mercados eléctricos (Kath & Ziel; Zaffran).
- Ningún método domina las cuatro métricas, pero LW-ACP gana en Winkler y pinball, las que combinan ancho y calibración.
- La adaptación *online* aumenta el ancho 2.6–3.2 %, pero reduce la desviación de cobertura en 79 %.
- Al 95 % LW-ACP sí domina todo: 58.25 USD/MWh, 8.7 % más angosto que Split CP.
- Sub-cobertura en horas de transición solar (0.799 vs. 0.90), el mismo mecanismo que el desfase de fase.

# Comparación contra el CEN

| Barra | MAE CEN | MAE 1 h | vs. CEN | MAE 24 h | vs. CEN |
|---|---|---|---|---|---|
| Puerto Montt | 32.98 | 13.68 | −58,5 % | 38.89 | +17,9 % |
| Crucero | 17.10 | 6.74 | −60,6 % | – | – |
| Cardones | 14.52 | 6.63 | −54,4 % | – | – |
| Pan de Azúcar | 15.09 | 6.93 | −54,1 % | 13.64 | −9,6 % |
| Charrúa | 17.01 | 7.98 | −53,1 % | 18.41 | +8,2 % |
| Quillota | 17.26 | 8.26 | −52,1 % | – | – |

- Se compara S+C-LN contra el *costo marginal programado* que el CEN publica operacionalmente (vía API pública), ambos evaluados contra el costo marginal real.
- A una hora, el modelo reduce el MAE entre 52 % y 61 %, pero usa el precio de la hora anterior; el programado se fija antes de la operación.
- A 24 horas (igual anticipación) gana en Pan de Azúcar y pierde en Charrúa y Puerto Montt.
- La ventaja a una hora es el valor del precio recién observado, no un mejor modelo del sistema que la Programación de la Operación.

# Comparación con la literatura

- León et al. (2026) comparan modelos de *machine learning* clásico (RFR, SVR, etc.) para el SEN en Crucero, Alto Jahuel y Puerto Montt, con datos de 2024.
- Se entrenan dos TFT S+C adicionales, restringidos a 2024, para Crucero y Puerto Montt (barras compartidas).

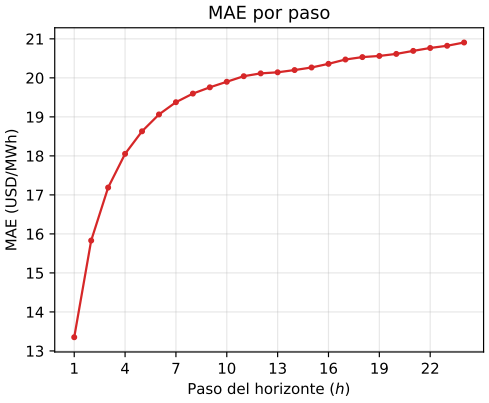
| Barra | MAE (este trabajo) | MAE (mejor de León et al.) |
|---|---|---|
| Crucero | 5.11 | 7.71 |
| Puerto Montt | 13.64 | 17.11 |

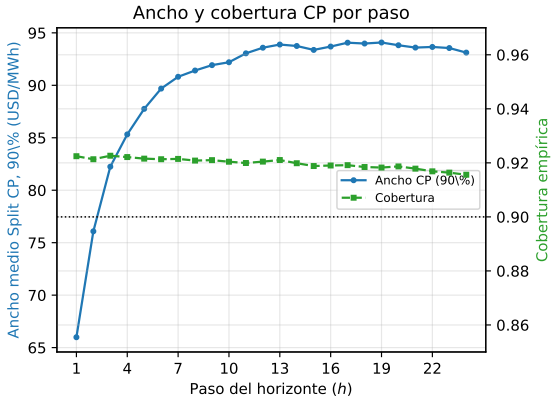
- Reducción de MAE de **20 % a 34 %**, pese a entrenar con menos de un año de datos y sin ajuste específico por barra.

# Alcance: una hora como escenario controlado

- Todos los resultados principales pronostican **la hora siguiente**, usando el precio observado hasta la hora anterior.
- Es el mismo horizonte del antecedente chileno más cercano (León et al., 2026), que deja el *day-ahead* como trabajo futuro.
- Sirve como **escenario controlado** para comparar estrategias de *features*, arquitecturas y métodos de Conformal Prediction.
- Pero el horizonte de decisión más relevante del mercado es el *day-ahead*: por eso se evaluó también el modelo a **24 horas**.
- La comparación con el CEN cambia con el horizonte: a una hora el modelo usa información que el programado no tiene; a igual anticipación, gana en una de tres barras.

# Pronóstico a 24 horas: error e incertidumbre por paso




- El MAE crece 57 % del primer al último paso; en promedio, el modelo no supera a la persistencia diaria (7 de 10 combinaciones).
- La cobertura de Conformal Prediction se mantiene en 0.916–0.923 (90 % nominal) en los 24 pasos, y el ancho se estabiliza desde el paso $\sim$12.

# ¿Se mantienen las conclusiones a 24 horas?

| **Conclusión a 1 hora** | **Resultado a 24 horas** | **¿Se mantiene?** |
|---|---|---|
| Heterocedasticidad horaria del error | Levene significativo en los 24 pasos en 4 de 5 barras (Charrúa se debilita) | Sí |
| LW-ACP es el mejor método de CP | Menor Winkler en los 24 pasos; intervalos 18.5 % más angostos que Split CP | Sí, más fuerte |
| LayerNorm supera a DyT | Diebold-Mariano: LN gana en 1 barra, DyT en 1, 3 empates | No: equivalentes |
| S+C supera a P+C | S+C gana en 1 barra, P+C en 1 (Puerto Montt), 3 empates | Empatan; S+C con un solo modelo |

- Lo que traspasa al *day-ahead* es la estructura del error y la cuantificación de incertidumbre; la ventaja en precisión puntual, no.

# Extensiones exploradas

- **Piloto sin recorte de outliers**: a $h = 1$, en las ocho barras, no perjudica el MAE general y reduce los errores más grandes (error máximo menor en las 8 barras, MAE en el percentil 99 menor en 7); significativo individualmente solo en 2 barras. Resultado mixto a $h = 24$ (4 barras).
- **Granularidad temporal**: mayor resolución (15 min) mejora la capacidad predictiva de forma consistente, controlando por período histórico.
- **Sensibilidad a pérdida asimétrica**: la ventaja de S+C-LN se sostiene en 7 de 8 barras independientemente de qué error sea más costoso.

# Conclusiones principales

1. **La estrategia más simple es la más precisa a una hora**: S+C supera a P+C, con la posición solar dominando el decoder del TFT; a 24 horas empatan, y S+C lo logra con un solo modelo.
2. **LW-ACP** combina ponderación horaria y adaptación *online*, logrando el mejor Winkler y pinball al 90 % con cobertura calibrada, y los intervalos más angostos al 95 %.
3. Los errores más extremos siguen un patrón mecanístico común (desfase de fase de $\sim$1h), no ruido aleatorio disperso.
4. A una hora supera a la literatura reciente de ML clásico al mismo horizonte; a 24 horas la calibración de los intervalos se mantiene, pero la predicción puntual no supera a la persistencia.
5. Puerto Montt permanece como un caso no resuelto, estructuralmente distinto al resto del SEN.

# Limitaciones

- **Horizonte**: los resultados principales son a una hora; a 24 horas la predicción puntual no supera a la persistencia diaria.
- Un único split cronológico entrenamiento/validación/prueba (no *walk-forward validation*) por costo computacional.
- Sin semilla fija para los modelos principales del Capítulo 4 (sí para el estudio de robustez).
- Esfuerzo de ajuste de hiperparámetros asimétrico entre Prophet (optimizado por barra) y TFT (fijo).
- Reproducibilidad parcial del entorno de entrenamiento en GPU (versiones de librerías del cluster no registradas).
- Pipeline no directamente desplegable en operación real: ERA5 se publica con rezago.

# Trabajo futuro

- Mejorar el *day-ahead* con información conocida de antemano, por ejemplo el costo marginal programado del CEN como variable de entrada.
- Comparar LW-ACP contra AgACI (agregación de múltiples $\gamma$ vía expertos *online*).
- Extender la comparación contra el CEN a Atacama y Tarapacá.
- *Walk-forward validation* sobre múltiples ventanas rodantes.
- Investigar directamente el mecanismo del desfase de fase (pérdida que penalice error de temporización).
- Extender el estudio de granularidad a las ocho barras y el piloto de outliers a las ocho barras a $h = 24$.
- LW-ACP con adaptación *online* indexada por hora del día.

# Gracias

github.com/benjamitchell/Tesis-TFT-Electricidad