



SEMINARIO DE MAGÍSTER - Departamento de Ingeniería Civil Matemática

Modelo Híbrido de Machine Learning Aplicado al Mercado Eléctrico.

Prophet · Temporal Fusion Transformer · Stacking Optimization · Conformal Prediction

Edward Benjamín Mitchell García

Profesor guía: Alejandro Jofré

Universidad de Chile · 2026

Agenda

1  Contexto y problema

2  Metodología

3  Componentes del modelo

4  Resultados

5  Hallazgos e interpretabilidad

6  Conclusiones y trabajo futuro

¿Por qué predecir el costo marginal?

El costo marginal es la señal económica central del Sistema Eléctrico Nacional: determina el precio de la energía en cada barra y guía decisiones de despacho, inversión y comercialización.



Alta penetración ERNC

Mayor volatilidad por dependencia solar/eólica, difícil de capturar con modelos clásicos.



No linealidad y saltos

Cambios bruscos de régimen entre horas de alta y baja generación renovable.



Impacto en decisiones reales

Afecta a generadores, comercializadores y reguladores en tiempo casi real.

8

barras del SEN modeladas

2020 – 2026

de datos horarios históricos

~50.000+

observaciones horarias por barra

Problema y objetivos



Problema

Los costos marginales del SEN exhiben:

- Alta volatilidad.
- No linealidad.
- Fuerte dependencia de externas.

Los modelos clásicos de series de tiempo capturan estacionalidad pero no relaciones complejas multivariadas; los modelos puramente deep learning no entregan cuantificación de incertidumbre confiable.




Objetivo general

Desarrollar un modelo híbrido que combine forecasting clásico, deep learning y cuantificación de incertidumbre, para predecir costos marginales en múltiples barras del SEN.

- ✓ Combinar Prophet + TFT mediante Stacking Optimization
- ✓ Cuantificar incertidumbre con Conformal Prediction
- ✓ Adaptar la incertidumbre localmente en el tiempo
- ✓ Interpretar qué variables explican cada predicción

8 barras del Sistema Eléctrico Nacional



Granularidad horaria

Periodo 2020–2026, series temporales hora a hora por barra.



Variables climáticas

Datos meteorológicos obtenidos de Open-Meteo por ubicación de cada barra.



Features de memoria

Como se comportó el costo hace determinadas horas, más ventanas móviles.

Pipeline del Modelo



Cada barra del SEN se modela de forma independiente; el stacking aprende los pesos óptimos entre Prophet y TFT, y la capa conformal entrega intervalos de predicción con cobertura garantizada.

Prophet

Modelo aditivo de descomposición que captura tendencia y estacionalidad (diaria, semanal, anual) de forma interpretable. Sirve como línea base robusta y como insumo para el stacking posterior.

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t$$




Grid search de 221 combinaciones

Optimización de hiperparámetros (changepoints, estacionalidad, regularización).



Parámetros CPS/SPS finales

Calibrados de forma independiente para cada una de las 8 barras.



Temporal Fusion Transformer (TFT)

Arquitectura de atención temporal con redes de selección de variables, capaz de ponderar dinámicamente qué inputs importan en cada instante y de entregar interpretabilidad nativa.



TFT_LN

LayerNorm

Normalización clásica por capa (Layer Normalization), estándar en arquitecturas Transformer.

BARRA	MAE	RMSE	R^2
Atacama	6.67	13.48	0.87
Charrua	8.61	15.58	0.87
P. Montt	14.32	26.44	0.81



TFT_DyT

Dynamic Tanh



Alternativa propuesta por Zhu et al. (2025): reemplaza LayerNorm por una transformación Dynamic Tanh, mejorando las predicciones.

BARRA	MAE	RMSE	R^2
Atacama	6.84	13.90	0.88
Crucero	8.30	15.20	0.88
P. Montt	14.02	25.32	0.83

Stacking Optimization

La idea central es usar Prophet para modelar la globalidad de la serie, y usar los resultados de tendencia y estacionalidad para alimentar el TFT.

- **Prophet:** Captura la tendencia, pero no patrones complejos ni dependencias largas.
- **Transformer:** Aprende patrones complejos y dependencias largas, pero necesita señales más limpias.



Conformal Prediction: cuantificar incertidumbre



Garantía libre de distribución

No asume una forma paramétrica para los errores del modelo.



Cobertura nominal

Construye intervalos que contienen el valor real con probabilidad $1-\alpha$ garantizada.



Marco de Zaffran et al. (2024)

Base teórica utilizada como punto de partida, en su variante Split Conformal Prediction.

Split Conformal Prediction — idea base

1. Dividir datos en entrenamiento y calibración
2. Calcular residuos en el set de calibración
3. Obtener el cuantil $(1-\alpha)$ de los residuos
4. Construir intervalo: $\hat{y} \pm \hat{q}$

Limitación: el ancho del intervalo es fijo en el tiempo y no se adapta a cambios locales de volatilidad — motiva la siguiente contribución.

COMPONENTE 4

LW - ACP

Locally Weighted Adaptive Conformal Prediction.


A diferencia del Split CP estándar, LW-ACP actualiza los intervalos de predicción de forma local y adaptativa en el tiempo, ponderando observaciones recientes y similares para responder mejor a cambios de régimen (p. ej. alta volatilidad por entrada de renovables)

- ✓ Ponderación local de residuos
- ✓ Actualización online (sin reentrenar)
- ✓ Mejor cobertura en regímenes cambiantes

REDUCCIÓN DE ANCHO DE INTERVALO

–17,7%

frente a Split Conformal Prediction estándar, manteniendo cobertura nominal.




TFT_LN vs. TFT_DyT a nivel de stacking

4 / 8


barras donde TFT_LN supera a TFT_DyT en el stacking final

La estrategia de Stacking reporta una mejora de ~68% respecto a Prophet y ~4% respecto al Transformer.

DyT mantiene desempeño competitivo con menor costo computacional, consistente con lo reportado por Zhu et al. (2025).



LW-ACP vs. Adaptive Conformal Prediction



-17,7%

ancho promedio de intervalo

Manteniendo la cobertura nominal ($1-\alpha$) objetivo,
gracias a la ponderación local de residuos y
actualización online.




Errores extremos



Al analizar los errores extremos del modelo, se observó que la distribución tiene colas muy pesadas.

- ✓ Estas colas son las que producen intervalos de conformidad anchos en relación a las métricas.
- ✓ Puede tener relación con el cambio de hora y el desfase del ciclo solar
- ✓ Los lags (1h, 24h, 168h) cruzan el punto de transición de forma distinta

Implicancia: Estudiar si darle conocimiento al modelo sobre el cambio de horario invierno/verano corrige los desfases y disminuye los errores extremos.



TFT Variable Selection Networks

El TFT incluye redes de selección de variables que asignan pesos de importancia a cada input en cada paso temporal, permitiendo entender qué variables explican cada predicción y no solo qué tan bien predice el modelo.



Transparencia

Permite auditar el modelo más allá de una caja negra. · Heatmaps de importancia para variables climáticas, lags y calendario. · Las variables relevantes difieren según la composición de generación local.



Importancia por variable



Comparación entre barras

*Aquí iría un Heatmap de VSN por barra
Si tuviera uno.*

Conclusiones



Framework híbrido funcional

Prophet + TFT + Stacking + Conformal Prediction, validado en 8 barras del SEN.



TFT_LN vs TFT_DyT

LN lidera en 5/8 barras; DyT es competitivo con menor costo computacional.



LW-ACP

Reduce el ancho de intervalo en ~17,7% manteniendo cobertura nominal.



Hallazgo DST

Los errores extremos se concentran en torno a transiciones de horario de verano.



Interpretabilidad

Las variable selection networks permiten explicar las predicciones por barra.

Trabajo futuro



Cerrar resultados

Consolidar resultados definitivos de los modelo TFT y la sección de interpretabilidad.



Tratamiento de errores extremos

Incorporar features o re-muestreo específico para las semanas de cambio de horario. Buscar alternativas de tratamiento.



Extender LW-ACP

Explorar esquemas de ponderación adicionales y validación en más barras del sistema.



¡Gracias!

¿Preguntas y comentarios?

