



UNIVERSIDAD DE CHILE
FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS
DEPARTAMENTO DE INGENIERÍA MATEMÁTICA

ALGORITMO HÍBRIDO DE MACHINE LEARNING APLICADO AL MERCADO
ELÉCTRICO

TESIS PARA OPTAR AL GRADO DE
MAGÍSTER EN MATEMÁTICAS APLICADAS

MEMORIA PARA OPTAR AL TÍTULO DE
INGENIERO CIVIL EN MATEMÁTICAS

EDWARD BENJAMÍN MITCHELL GARCÍA

PROFESOR GUÍA:
ALEJANDRO JOFRÉ CÁCERES

MIEMBROS DE LA COMISIÓN:
NOMBRE COMPLETO UNO
NOMBRE COMPLETO DOS
NOMBRE COMPLETO TRES

SANTIAGO DE CHILE

2026

Resumen

FALTA HACER UN RESUMEN

Una dedicatoria corta.

Agradecimientos

Mis padres, Mady y Edward, mis hermanos, Agu y Rena, mi cachorra Adharita, mi gran amor, Fran, mi kit y mis u panas

Tabla de Contenido

1. Introducción	1
1.1. Mercado eléctrico	1
1.2. Modelos actuales	2
1.3. Propuesta	3
1.4. Objetivos	4
1.4.1. Objetivo General	4
1.4.2. Objetivos Específicos	4
1.5. Esta sección de organización la hago al final, pero es más o menos así:	5
2. Marco Teórico	6
2.1. Series Temporales	6
2.1.1. Estacionariedad	6
2.1.2. Estacionalidad múltiple	7
2.1.3. Procesos no estacionarios y transformaciones	9
2.1.4. Horizonte de predicción y estrategia de forecasting multihorizonte . .	9
2.1.5. Forecasting multivariado y estructura de barras	10
2.2. Prophet	11
2.2.1. Componente de tendencia	11
2.2.2. Componente de estacionalidad	12
2.2.3. Componente de festividades y eventos especiales	12
2.2.4. Estimación e inferencia	13

2.2.5.	Rol de Prophet en la arquitectura híbrida	13
2.3.	Transformer y Temporal Fusion Transformer	13
2.3.1.	Mecanismo de atención	14
2.3.2.	Atención multi-cabeza	15
2.3.3.	Arquitectura Transformer	15
2.3.4.	Temporal Fusion Transformer	16
2.3.5.	Rol del TFT en la arquitectura híbrida	19
2.4.	Layer Normalization y Dynamic Tanh	20
2.4.1.	Layer Normalization	20
2.4.2.	Comportamiento empírico de LayerNorm: curvas tipo tanh	21
2.4.3.	Dynamic Tanh (DyT)	22
2.4.4.	LayerNorm vs DyT	23
2.4.5.	Uso de DyT en el TFT para predicción de costos marginales	25
2.5.	Stacking Optimization	26
2.5.1.	Formulación general y diversidad del ensamble	27
2.5.2.	Protocolo de entrenamiento y prevención de data leakage	28
2.5.3.	Stacking Optimization en el modelo híbrido propuesto	29
2.6.	Conformal Prediction	29
2.6.1.	Split Conformal Prediction (SCP)	30
2.6.2.	Conformal Prediction con Ensemble (EnbPI)	31
2.6.3.	Adaptive Conformal Inference (ACI)	32
2.6.4.	ACI con Agregación de Expertos Online (AgACI)	33
2.6.5.	Métricas de evaluación de los intervalos de predicción	34
3.	Metodología	35
3.1.	Datos	35
3.1.1.	Fuente y descripción	35
3.1.2.	Estadísticas descriptivas y análisis exploratorio	36

3.1.3.	Análisis de estacionariedad	38
3.2.	Preprocesamiento	38
3.2.1.	Limpieza y tratamiento de valores atípicos	39
3.2.2.	División temporal de los datos	39
3.2.3.	Normalización	40
3.3.	Modelo Prophet	40
3.3.1.	Configuración y optimización de hiperparámetros	40
3.3.2.	Componente de tendencia	41
3.3.3.	Componente de estacionalidad anual	43
3.3.4.	Predicciones a 48 horas	44
3.4.	Temporal Fusion Transformer	44
3.4.1.	Construcción de features y dataloaders	44
3.4.2.	Arquitectura y entrenamiento	46
3.4.3.	Curvas de aprendizaje	47
3.5.	Stacking Optimization	47
3.5.1.	Estrategias de ensamblaje	47
3.5.2.	Métodos de optimización de pesos	49
3.6.	TFT con Dynamic Tanh	49
3.6.1.	Curvas de aprendizaje	50
3.6.2.	Análisis del parámetro α aprendido	50
3.7.	Conformal Prediction	50
3.7.1.	Configuración general	53
3.7.2.	Split CP clásico	54
3.7.3.	EnbPI V2	54
3.7.4.	ACI <i>offline</i>	54
3.7.5.	ACI <i>online</i>	54
4.	Resultados y Análisis	56

4.1. Modelo Prophet	56
4.1.1. Desempeño por barra	56
4.2. Temporal Fusion Transformer con LayerNorm	59
4.2.1. Desempeño por barra	59
4.3. Stacking Optimization	62
4.3.1. Selección del mejor método de optimización	62
4.3.2. Selección de la mejor estrategia	63
4.4. Temporal Fusion Transformer con Dynamic Tanh	64
4.4.1. Desempeño por barra	64
4.4.2. Stacking Optimization con TFT _{DyT}	66
4.4.3. Comparativa TFT _{LN} vs TFT _{DyT}	67
4.4.4. Comparativa TFT _{LN} vs. TFT _{DyT}	68
4.5. Conformal Prediction	70
4.5.1. Split CP clásico	70
4.5.2. EnbPI V2	71
4.5.3. ACI <i>offline</i>	71
4.5.4. ACI <i>online</i>	71
4.5.5. Comparativa de métodos	73
4.5.6. Comparación con regresión cuantílica	73
4.5.7. Síntesis	74
4.6. Análisis de interpretabilidad del TFT	74
4.6.1. Importancia en el encoder	75
4.6.2. Importancia en el decoder	76
4.6.3. Atención temporal	77
4.6.4. Síntesis	77
4.6.5. Análisis de errores extremos	78
Bibliografía	84

Capítulo 1

Introducción

1.1. Mercado eléctrico

El Sistema Eléctrico Nacional (SEN) de Chile ha experimentado una transformación estructural sin precedentes durante la última década. La unificación del Sistema Interconectado del Norte Grande (SING) y el Sistema Interconectado Central (SIC) en 2017 consolidó una red única que, al cierre de 2024, alcanzó una capacidad instalada de 36.778 MW [11]. Dentro de este crecimiento, las Energías Renovables No Convencionales (ERNC) alcanzaron por primera vez el 50,3 % (18.522MW) de la capacidad instalada, lideradas por la energía solar con un 23 % y la eólica con un 14 %. En términos de generación, las ERNC aportaron el 40,4 % de los 85.519 GWh producidos durante 2024, lo que representa un aumento del 10,9 % respecto al año anterior [11]. Esta expansión sitúa a Chile como uno de los sistemas eléctricos con mayor penetración renovable de América Latina, con una trayectoria de crecimiento que en cinco años (2019 - 2024) llevó la participación ERNC del 20 % al 40 % de la generación total [5].

Sin embargo, esta transición energética ha introducido una volatilidad estructural en la operación del sistema que no tiene precedentes en la historia del sector energético chileno. La intermitencia inherente a las fuentes solares y eólicas, combinada con una capacidad instalada solar que ya supera los 11.000 MW, suficiente para cubrir prácticamente la totalidad de la demanda del SEN, que oscila entre 10.700 y 12.200 MW, genera episodios recurrentes de sobreoferta [6]. La consecuencia directa es la caída del costo marginal a valores cercanos a cero durante el bloque solar en zonas de alta concentración renovable, seguida de alzas abruptas en horarios de menor generación o en períodos de déficit hídrico [7]. Este fenómeno se manifiesta concretamente en los vertimientos o curtailments. En 2024 se perdieron 5.908,71 GWh de energía eólica y solar, un aumento del 149 % respecto a los 2.375,86 GWh de 2023, equivalentes al 17 % de toda la generación renovable disponible [6]. En el mes más crítico del año, noviembre, las plantas solares operaron menos de la mitad de su tiempo potencial por exceso de oferta.

La volatilidad resultante del costo marginal, principal señal de precio en el mercado spot del SEN, tiene implicancias directas sobre la viabilidad financiera de los agentes del mercado,

la programación del despacho eléctrico y el diseño de contratos de suministro de mediano y largo plazo. A diferencia de mercados con matrices estables, el SEN combina tres fuentes de incertidumbre simultáneas: la variabilidad climática que afecta tanto a la generación solar y eólica como a los embalses hidroeléctricos, los cambios estructurales derivados de la incorporación continua de nueva capacidad renovable, con tasas de crecimiento superiores al 22 % anual frente a un crecimiento de la demanda de apenas el 2 %, y las congestiones en la red de transmisión que desacoplan los precios entre zonas del sistema [1]. Esta combinación hace del forecasting del precio spot en el SEN un problema de predicción de series temporales especialmente complejo, que demanda enfoques metodológicos capaces de capturar tanto la estacionalidad múltiple como las no-linealidades y los quiebres estructurales propios de un mercado en plena transición, esto motiva una revisión detallada de los modelos disponibles en la literatura.

1.2. Modelos actuales

La predicción del precio en mercados eléctricos ha sido abordada históricamente mediante modelos estadísticos clásicos como ARIMA y sus variantes estacionales, los cuales asumen estacionariedad y linealidad en las series temporales [15]. Si bien estos modelos ofrecen interpretabilidad y eficiencia computacional, su capacidad predictiva se ve limitada en mercados con alta penetración renovable como el SEN, donde la serie de costos marginales exhibe heterocedasticidad, quiebres estructurales asociados a la incorporación continua de nueva capacidad instalada, y patrones de estacionalidad múltiple determinados simultáneamente por ciclos horarios, diarios y estacionales [15]. Adicionalmente, estos modelos no capturan el comportamiento no lineal de la serie durante episodios de sobreoferta renovable, donde el costo marginal puede colapsar a cero o exhibir alzas abruptas en cuestión de horas, comportamiento que los modelos lineales son estructuralmente incapaces de representar.

En respuesta a estas limitaciones, la literatura ha explorado modelos de aprendizaje profundo con mayor expresividad. En particular, el *Temporal Fusion Transformer* (TFT), propuesto por Lim et al. (2021) [10], representa un avance significativo al combinar capas recurrentes para el procesamiento local de dependencias de corto plazo con mecanismos de auto-atención interpretables para dependencias de largo alcance [10]. A diferencia de los Transformers comunes [13], el TFT incorpora encoders de covariables estáticas, selección de variables mediante redes de selección con compuertas, y salidas probabilísticas mediante regresión cuantílica, lo que lo hace especialmente adecuado para contextos de forecasting multihorizonte con múltiples variables exógenas, como las que caracterizan al mercado eléctrico chileno. Sin embargo, el TFT opera típicamente sobre la serie cruda sin descomponer explícitamente tendencia y estacionalidad, lo que puede dificultar su adaptación en presencia de cambios estructurales graduales como los que experimenta el SEN durante su acelerada transición energética.

Un aspecto técnico relevante en el diseño de arquitecturas Transformer para series temporales es el rol de las capas de normalización. La normalización de capas, *Layer Normalization* (LayerNorm), ha sido considerada un componente esencial en prácticamente todas las arquitecturas Transformer desde su introducción [13]. Sin embargo, Zhu et al. (2025) [21] de-

muestran que es posible prescindir de estas capas mediante la introducción de *Dynamic Tanh* (DyT), cuya operación central se define como $\text{DyT}(x) = \tanh(\alpha x)$, donde α es un parámetro escalar aprendible que regula el escalado de la entrada antes de aplicar la función de activación. En la implementación completa, esta operación se complementa con una transformación afín posterior $\gamma \cdot \text{DyT}(x) + \beta$, donde β y γ son parámetros vectoriales aprendibles equivalentes a los que LayerNorm ya incorpora en su etapa de reescalado, no son parte de la operación DyT en sí, sino el mecanismo estándar que permite a la capa restaurar la escala original de las activaciones. La propuesta se inspira en la observación empírica de que las capas LayerNorm en Transformers entrenados producen mapeos entrada-salida con forma de S , cuyo comportamiento puede ser replicado eficientemente por la función $\tanh$ escalada. Los autores validan que los Transformers con DyT igualan o superan el rendimiento de sus contrapartes normalizadas en tareas diversas, sin requerir ajuste de hiperparámetros. La comparación entre TFT con LayerNorm y TFT con DyT constituye, por tanto, una interrogante abierta y metodológicamente relevante en el contexto de forecasting de series temporales energéticas, dado que las propiedades de estabilización del gradiente y la velocidad de convergencia pueden diferir significativamente en series con alta variabilidad y episodios de spike como las del SEN.

Los modelos híbridos representan una alternativa prometedora al combinar las fortalezas complementarias de enfoques distintos. Prophet, desarrollado por Taylor y Letham (2018) [12] ofrece una descomposición explícita de tendencia, estacionalidad múltiple y efectos de calendario mediante un modelo aditivo, resultando especialmente adecuado para series con patrones estacionales fuertes, valores faltantes y cambios de tendencia abruptos [12]. La combinación de Prophet con el TFT permitiría, en principio, aprovechar la estructura interpretable de la descomposición temporal para capturar la componente sistemática de la serie, mientras el TFT modela las dependencias no lineales. No obstante, la literatura sobre modelos híbridos para mercados eléctricos latinoamericanos es escasa, y los estudios existentes raramente incorporan mecanismos formales de ensamblaje, como *Stacking Optimization*, ni abordan la cuantificación de incertidumbre con garantías estadísticas. Las predicciones puntuales, predominantes en la literatura de forecasting eléctrico, son insuficientes para la toma de decisiones bajo riesgo en mercados con la volatilidad estructural observada en el SEN, lo que motiva la incorporación de *Conformal Prediction* (CP) como mecanismo de cuantificación de incertidumbre con cobertura garantizada sin supuestos distribucionales [19].

1.3. Propuesta

En este contexto, la presente tesis propone un modelo híbrido de aprendizaje automático para la predicción del costo marginal en el mercado eléctrico chileno, diseñado para abordar de manera conjunta las limitaciones identificadas en los enfoques existentes. El modelo integra Prophet para la descomposición explícita de tendencia y estacionalidad múltiple, con dos variantes del TFT, una con LayerNorm y otra con DyT, para la captura de dependencias temporales no lineales de largo alcance. Los modelos base se ensamblan mediante *Stacking Optimization*, un esquema de combinación que aprende los pesos óptimos de cada componente a partir de sus errores de predicción en un conjunto de validación, superando las limitaciones del promediado simple. Finalmente, la incertidumbre de las predicciones se

cuantifica mediante *Conformal Prediction*, un marco de inferencia estadística que garantiza intervalos de cobertura válidos con probabilidad preestablecida y sin imponer supuestos sobre la distribución de los errores [19]. El modelo es evaluado sobre datos históricos del SEN, con el objetivo de evaluar si la integración estructurada de estos componentes permite superar el desempeño de los modelos individuales y proveer predicciones con incertidumbre cuantificada y estadísticamente válida. Las principales contribuciones esperadas para este trabajo son:

- (i) La primera aplicación de un modelo híbrido Prophet-TFT con ensamblaje formal al mercado eléctrico chileno,
- (ii) la comparación empírica de LayerNorm y Dynamic Tanh en un contexto de forecasting energético, y
- (iii) la incorporación de Conformal Prediction como mecanismo de incertidumbre con garantías de cobertura en el SEN.

1.4. Objetivos

1.4.1. Objetivo General

El objetivo general del proyecto es desarrollar y evaluar un modelo híbrido de aprendizaje automático que combine Prophet, Temporal Fusion Transformer y Conformal Prediction para la predicción del costo marginal en el mercado eléctrico chileno, incorporando cuantificación de incertidumbre con garantías estadísticas de cobertura.

1.4.2. Objetivos Específicos

1. Caracterizar el comportamiento histórico del costo marginal en el Sistema Eléctrico Nacional, identificando sus patrones de estacionalidad, tendencia y volatilidad estructural asociados a la penetración de energías renovables no convencionales.
2. Diseñar e implementar la arquitectura del modelo híbrido, integrando Prophet como componente de descomposición temporal con dos variantes del TFT, con LayerNorm y con Dynamic Tanh, como modelos de captura de dependencias no lineales.
3. Desarrollar un esquema de ensamblaje mediante Stacking Optimization que combine los modelos base de forma óptima, aprendiendo los pesos de combinación a partir del desempeño en un conjunto de validación.
4. Implementar Conformal Prediction como mecanismo de cuantificación de incertidumbre y validar empíricamente la cobertura de los intervalos de predicción resultantes.
5. Evaluar el desempeño del modelo propuesto frente a baselines establecidos, utilizando métricas de error puntual y probabilístico.

1.5. Esta sección de organización la hago al final, pero es más o menos así:

El presente documento se organiza de la siguiente manera. El Capítulo 2 introduce el marco teórico, presentando los fundamentos de Prophet, el Temporal Fusion Transformer, Stacking Optimization y Conformal Prediction. El Capítulo 3 revisa la literatura relevante en forecasting de precios eléctricos, modelos híbridos y cuantificación de incertidumbre, identificando las brechas que motivan este trabajo. El Capítulo 4 describe el mercado eléctrico chileno, las fuentes de datos utilizadas y el proceso de preprocesamiento. El Capítulo 5 detalla la metodología propuesta, incluyendo el diseño de la arquitectura híbrida, el esquema de ensamblaje y la implementación de Conformal Prediction. El Capítulo 6 presenta los experimentos realizados, las métricas de evaluación y los resultados obtenidos. El Capítulo 7 discute los hallazgos en el contexto del mercado eléctrico chileno y las limitaciones del modelo. Finalmente, el Capítulo 8 sintetiza las contribuciones del trabajo y propone líneas de investigación futura.

Capítulo 2

Marco Teórico

2.1. Series Temporales

Una serie temporal es una secuencia de observaciones $\{y_t\}_{t=1}^T$ indexadas en el tiempo, donde el orden de las observaciones es la parte esencial. A diferencia de los datos de corte transversal, en una serie temporal la dependencia entre observaciones consecutivas constituye la principal fuente de información para las predicciones.

Formalmente, se asume que cada observación y_t es una realización de una variable aleatoria Y_t , y el conjunto $\{Y_t\}_{t \in \mathbb{Z}}$ define un proceso estocástico. El objetivo del forecasting es estimar la distribución condicional:

$$p(Y_{t+h} \mid \mathcal{F}_t),$$

donde $h \geq 1$ es el horizonte de predicción y $\mathcal{F}_t = \sigma(Y_t, Y_{t-1}, \dots)$ es la filtración generada por la historia del proceso hasta el tiempo t . En la práctica, la mayoría de los modelos de forecasting estiman únicamente la media condicional $\mathbb{E}[Y_{t+h} \mid \mathcal{F}_t]$, produciendo predicciones puntuales. Sin embargo, para la toma de decisiones bajo incertidumbre, como la programación del despacho eléctrico o valorización de contratos en el SEN, es necesario tener garantías estadísticas con respecto a las predicciones.

2.1.1. Estacionariedad

Un proceso estocástico $\{Y_t\}$ se denomina estrictamente estacionario si su distribución conjunta es invariante ante traslaciones temporales, es decir, si para todo $k \in \mathbb{Z}$ y todo conjunto finito de índices $\{t_1, \dots, t_n\}$ se cumple que:

$$(Y_{t_1}, \dots, Y_{t_n}) \stackrel{d}{=} (Y_{t_1+k}, \dots, Y_{t_n+k}) \quad (2.1)$$

La estacionariedad es una propiedad estructural de un proceso estocástico que describe la invarianza de sus características estadísticas en el tiempo. En la práctica se trabaja

con la noción más débil de *estacionariedad en covarianza* o *estacionariedad débil*, que exige únicamente que:

$$\begin{aligned}\mathbb{E}[Y_t] &= \mu \quad \forall t \geq 0 \\ \text{Cov}(Y_t, Y_{t+k}) &= \gamma(k) \quad \forall t, k \geq 0\end{aligned}$$

La estacionariedad es un supuesto central en los modelos estadísticos clásicos como ARI-MA, cuya validez depende de que la serie no muestre tendencias ni cambios estructurales en su nivel de varianza. En mercados eléctricos con alta penetración renovable, es frecuente observar no estacionariedad de múltiples orígenes: tendencias de largo plazo asociadas a cambios estructurales en la matriz energética, heterocedasticidad vinculada a episodios de sobreoferta, y quiebres abruptos por eventos hidrológicos o de congestión.

Un proceso no estacionario que puede volverse estacionario mediante diferenciación de orden d se denomina integrado de orden d , denotado $I(d)$. La verificación formal de este supuesto se realiza mediante pruebas de raíz unitaria. La prueba *Augmented Dickey-Fuller* (ADF) contrasta la hipótesis nula de raíz unitaria contra la alternativa de estacionariedad, mientras que la prueba *KPSS* invierte el rol de las hipótesis, contrastando estacionariedad como hipótesis nula. El uso conjunto de ambas pruebas permite una caracterización más robusta de la estructura de la serie.




Figura 2.1: Ejemplificación de una serie estacionaria y una no estacionarias.

2.1.2. Estacionalidad múltiple

Una serie temporal exhibe estacionalidad cuando presenta patrones que se repiten con una periodicidad fija m . En el contexto de series temporales de precios eléctricos, es habitual observar estacionalidad en múltiples escalas simultáneamente: un patrón diario de periodo $m_1 = 24$ horas, asociado al ciclo de demanda residencial e industrial, un patrón semanal de periodo $m_2 = 168$ horas, determinado por la diferencia entre días hábiles y fines de semana,

y un patrón anual de periodo $m_3 = 8760$ horas, vinculado a la variación estacional de la radiación solar y la hidrología.

La manera natural de modelar esta estructura es mediante una descomposición aditiva:

$$y_t = T_t + \sum_{j=1}^J S_t^{(j)} + \varepsilon_t \quad , \quad (2.2)$$

donde T_t es la componente de tendencia, $S_t^{(j)}$ es la j -ésima componente estacional de periodo m_j y $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$ es el término de error. La idea de este modelo radica en el supuesto de que las fuentes de variación son conceptualmente separables y aditivas: la tendencia captura la dinámica de largo plazo del mercado, cada componente estacional captura un ciclo recurrente de distinta escala, y el residuo recoge la variabilidad no estructurada.

En el contexto de series temporales, una componente estacional $S_t^{(j)}$ de periodo m es por definición una función periódica, por lo que puede representarse mediante una serie de Fourier truncada de orden K_j :

$$S_t^{(j)} = \sum_{k=1}^{K_j} \left[a_k^{(j)} \cos\left(\frac{2\pi kt}{m_j}\right) + b_k^{(j)} \sin\left(\frac{2\pi kt}{m_j}\right) \right] \quad (2.3)$$

donde los coeficientes $\{a_k^{(j)}, b_k^{(j)}\}$ son parámetros estimables. Esta representación viene de la teoría clásica de señales, donde cualquier función periódica de periodo m que sea integrable puede aproximarse mediante sumas de senos y cosenos de frecuencias múltiplos de $\frac{1}{m}$.

Esta representación tiene tres ventajas que la hacen adecuada para su estimación mediante optimización: es diferenciable, lo que permite la optimización por descenso de gradiente, es flexible, pues puede aproximar estacionalidades de cualquier forma y no solo senoidales, y parsimoniosa, lo que permite capturar patrones complejos con pocos coeficientes. El orden K_j controla la suavidad de la estacionalidad estimada: valores pequeños de K_j producen componentes suaves, mientras que valores grandes permiten capturar formas más irregulares.




Figura 2.2: Visualización de una serie con estacionalidad múltiple descompuesta

2.1.3. Procesos no estacionarios y transformaciones

Cuando una serie presenta tendencia, varianza no constante o cambios estructurales, es necesario aplicar transformaciones previas al entrenamiento para estabilizar sus propiedades estadísticas y mejorar la convergencia de los modelos. La transformación más utilizada en el contexto de modelos de aprendizaje profundo es la *estandarización* o *normalización z-score*, que transforma cada observación según:

$$\tilde{y}_t = \frac{y_t - \hat{\mu}}{\hat{\sigma}} \quad (2.4)$$

donde $\hat{\mu}$ y $\hat{\sigma}$ son la media y desviación estándar estimadas exclusivamente sobre el conjunto de entrenamiento. Esta transformación garantiza que la serie transformada tenga media cero y varianza unitaria, lo que estabiliza el gradiente durante el entrenamiento y hace que los parámetros del modelo sean comparables entre distintas barras y horizontes. Es fundamental que los parámetros $\hat{\mu}$ y $\hat{\sigma}$ se estimen solo sobre el conjunto de entrenamiento y se apliquen sin reestimación al conjunto de validación y prueba, evitando así la filtración de información futura o *data leakage*.

Otras transformaciones comunes incluyen la diferenciación de orden d :

$$\Delta^d y_t = (1 - B)^d y_t \quad (2.5)$$

donde B es el operador de rezago $By_t = y_{t-1}$, que elimina tendencias polinomiales de grado d , y la transformación logarítmica $\tilde{y}_t = \log(y_t)$, que estabiliza la varianza en series con heterocedasticidad multiplicativa. En este trabajo se adopta la estandarización z-score como transformación principal, aplicada de manera independiente a cada barra del SEN mediante `StandardScaler`.

2.1.4. Horizonte de predicción y estrategia de forecasting multi-horizonte

El horizonte de predicción h determina cuántos pasos adelante se desea predecir. En mercados eléctricos, el horizonte más relevante operacionalmente es el *day-ahead*, es decir, $h = 24$ horas, que corresponde al ciclo de programación del despacho en el SEN. En este trabajo se adopta un horizonte de $h = 1$ hora, lo que corresponde a la predicción del costo marginal de la hora inmediata siguiente dado una ventana de predicción de longitud L . Formalmente, el problema de predicción se define como estimar:

$$\hat{y}_{t+1} = f(y_{t-L+1:t}, \mathbf{x}_{t-L+1:t+1}) \quad (2.6)$$

donde L es la longitud de la ventana de contexto y $\mathbf{x}_t$ denota el vector de covariables exógenas conocidas en el tiempo t , como temperatura, demanda o generación, y f es el modelo de forecasting.

Aunque en este trabajo se considera $h = 1$, vale la pena situar este caso dentro del marco general de estrategias de forecasting multihorizonte, dado que el TFT fue diseñado para el caso general $h \geq 1$. Las tres estrategias principales son: la estrategia *recursiva*, que aplica iterativamente el modelo de un paso para generar predicciones de múltiples horizontes usando predicciones previas como entrada; la estrategia *directa*, que entrena un modelo independiente para cada horizonte h , y la estrategia MIMO (*Multiple Input Multiple Output*), que predice simultáneamente todos los horizontes con un único modelo, capturando las dependencias entre ellos. El TFT adopta la estrategia MIMO, lo que lo hace naturalmente extensible a horizontes mayores si el alcance del trabajo lo permite.

2.1.5. Forecasting multivariado y estructura de barras

En este trabajo el problema de forecasting no se limita a una única serie, sino que se extiende a $B = 8$ barras del SEN, cada una con su propia serie de costos marginales horarios $\{y_t^{(b)}\}_{t=1}^T$ con $b = 1, \dots, 8$. Este escenario define un problema de forecasting multivariado, donde las series pueden presentar dependencias cruzadas, por ejemplo, barras eléctricamente contiguas tienden a exhibir costos marginales correlacionados, salvo en episodios de congestión de transmisión, donde los precios se desacoplan, generando heterogeneidad estructural entre barras.

Formalmente, la correlación entre dos barras b y b' puede cuantificarse mediante la función de correlación cruzada:

$$\rho^{(b,b')}(k) = \frac{\text{Cov}(Y_t^{(b)}, Y_{t+k}^{(b')})}{\sqrt{\text{Var}(Y_t^{(b)}) \text{Var}(Y_t^{(b')})}} \quad (2.7)$$

Un enfoque que explota esta estructura es el *forecasting con dependencias espaciales*, donde la predicción para la barra b incorpora información de las barras vecinas. Sin embargo, este enfoque requiere modelar explícitamente la topología de la red eléctrica y puede introducir complejidad adicional cuando las congestiones generan desacoplamientos no estacionarios entre barras.

La estrategia adoptada en este trabajo consiste en entrenar un modelo independiente por barra, lo cual simplifica el problema a costa de ignorar las dependencias cruzadas. Esta decisión se justifica por dos razones: las congestiones de transmisión en el SEN introducen heterogeneidad estructural entre barras que dificultaría el entrenamiento conjunto, y los modelos independientes son más interpretables y permiten identificar con claridad el comportamiento específico de cada barra. La incorporación de dependencias espaciales mediante correlación cruzada queda propuesta como una extensión natural de este trabajo para investigación futura.

2.2. Prophet

Prophet es un modelo de forecasting se series temporales desarrollado por Taylor y Letham (2018) en Meta [12], diseñado para producir predicciones interpretables en series con patrones estacionales fuertes, missing values y cambios de tendencia abruptos. A diferencia de los modelos estadísticos clásicos como ARIMA y sus variantes, Prophet no requiere que la serie sea estacionaria ni impone supuestos sobre la estructura de autocorrelación de los residuos. Su diseño está orientado a la estimación automática de componentes interpretables, lo que lo hace especialmente adecuado como componente de descomposición en arquitecturas híbridas.

Prophet formula el problema de forecasting como la estimación de un modelo aditivo de la forma:

$$\hat{y}_t^{Prophet} = T(t) + S(t) + H(t) + \varepsilon_t \quad (2.8)$$

donde $T(t)$ es la componente de tendencia, $S(t)$ es la componente de estacionalidad, $H(t)$ captura el efecto de días festivos y eventos especiales, y $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$ es el término de error. Cada componente se estima de manera independiente, lo que otorga al modelo su interpretabilidad característica. La estimación de los parámetros se realiza mediante inferencia bayesiana con el software Stan, lo que permite incorporar incertidumbre en las predicciones de manera natural.

2.2.1. Componente de tendencia

Prophet ofrece dos especificaciones para la componente de tendencia $T(t)$. La primera es un *modelo de crecimiento logístico*, adecuado para trabajar con series que tienen una capacidad máxima o saturación:

$$T(t) = \frac{C}{1 + e^{(-k(t-m))}} \quad (2.9)$$

donde C es la capacidad de saturación, k es la tasa de crecimiento y m es el punto de inflexión. La segunda, y más utilizada en series de precios, es un *modelo lineal por tramos* (*piecewise linear*):

$$T(t) = (k + \mathbf{a}(t)^\top \boldsymbol{\delta})t + (m + \mathbf{a}(t)^\top \boldsymbol{\gamma}) \quad (2.10)$$

donde k es la tasa de crecimiento global, $\boldsymbol{\delta} \in \mathbb{R}^S$ es el vector de cambios de pendiente en cada uno de los S puntos de quiebre, $\mathbf{a}(t) \in \{0, 1\}^S$ es un vector indicador que activa los cambios acumulados hasta el tiempo t , y $\boldsymbol{\gamma}$ ajusta el intercepto para garantizar continuidad en los puntos de quiebre. Los puntos de quiebre pueden especificarse manualmente o detectarse automáticamente por el modelo, lo que le permite adaptarse a cambios estructurales graduales como los que experimenta el costo marginal del SEN ante la incorporación continua de capacidad renovable.

La detección automática de los puntos de quiebre se realiza colocando una distribución a priori dispersa sobre los ajustes de pendiente $\delta \sim \text{Laplace}(0, \tau)$, donde $\tau > 0$ controla la flexibilidad del modelo. Un prior disperso permite que Prophet proponga un gran número de puntos de quiebre candidatos, típicamente uno por mes en una historia de varios años, pero penaliza aquellos ajustes que no son necesarios para explicar los datos. Cuando $\tau \rightarrow 0$, el modelo reduce a una tendencia lineal o logística simple sin quiebres. Este mecanismo de regularización es especialmente relevante para las series de costos marginales del SEN, donde los cambios estructurales son graduales y difíciles de datar con precisión [12].

2.2.2. Componente de estacionalidad

La componente estacional $S(t)$ se modela mediante series de Fourier, siguiendo la representación introducida en la Sección 2.1. Para cada escala estacional de periodo m_j , Prophet define:

$$S(t) = \sum_{j=1}^J \sum_{k=1}^{K_j} \left[a_k^{(j)} \cos\left(\frac{2\pi kt}{m_j}\right) + b_k^{(j)} \sin\left(\frac{2\pi kt}{m_j}\right) \right] \quad (2.11)$$

donde los coeficientes $a_k^{(j)}, b_k^{(j)}$ son parámetros del modelo estimados durante el ajuste. El orden K_j controla la flexibilidad de cada componente estacional: Prophet usa por defecto $K = 10$ para la estacionalidad anual y $K = 3$ para la semanal, valores que pueden ajustarse según la complejidad de los patrones observados. En este trabajo se consideran las estacionalidades diaria ($m_1 = 24$), semanal ($m_2 = 168$) y anual ($m_3 = 8760$), capturando los tres ciclos recurrentes identificados en la Sección 2.1.

2.2.3. Componente de festividades y eventos especiales

La componente $H(t)$ modela el efecto de días festivos y eventos especiales que producen desviaciones sistemáticas en la serie, no capturables por la estacionalidad regular. Prophet representa este efecto como:

$$H(t) = \mathbf{Z}(t)\boldsymbol{\kappa} \quad (2.12)$$

donde $\mathbf{Z}(t) \in \{0, 1\}^L$ es un vector indicador que activa el evento correspondiente al tiempo t , y $\boldsymbol{\kappa} \in \mathbb{R}^L$ es el vector de efectos estimados para cada uno de los L eventos definidos. En este trabajo se incorporan los feriados nacionales del calendario chileno, dado que el consumo eléctrico y el despacho del SEN exhiben patrones sistemáticamente distintos en días festivos respecto a días hábiles.

2.2.4. Estimación e inferencia

Los parámetros del modelo $\{\delta, \beta, \kappa, \sigma\}$ se estiman bajo un marco bayesiano. Prophet coloca distribuciones a priori sobre los parámetros de cambio de tendencia $\delta \sim \text{Laplace}(0, \tau)$, donde τ controla la regularización de los quiebres, y sobre los coeficientes estacionales $\beta \sim \mathcal{N}(0, \sigma_s^2)$. La inferencia se realiza mediante *Maximum A Posteriori* (MAP) por defecto, o mediante muestreo MCMC completo cuando se requieren intervalos de credibilidad. Esta formulación permite que Prophet propague incertidumbre en la tendencia y la estacionalidad hacia las predicciones finales.

2.2.5. Rol de Prophet en la arquitectura híbrida

En el modelo propuesto en este trabajo, Prophet cumple el rol de componente de descomposición temporal. Dado que Prophet modela explícitamente la tendencia, la estacionalidad múltiple y los efectos de calendario, sus predicciones capturan la estructura sistemática de largo plazo de la serie. Los residuos de Prophet:

$$r_t = y_t - \hat{y}_t^{\text{Prophet}} \quad (2.13)$$

representan la variabilidad no explicada por la estructura sistemática, episodios de sobreoferta renovable, congestiones de transmisión y fluctuaciones de corto plazo, que son precisamente las componentes que el TFT está mejor equipado para modelar. Esta separación de roles motiva el diseño de dos modelos TFT paralelos: uno entrenado sobre los residuos $\{r_t\}$ y otro entrenado directamente sobre la serie original $\{y_t\}$, las predicciones se combinan con las hechas por Prophet posteriormente mediante Stacking Optimization, como se detalla en la Sección 2.5.

2.3. Transformer y Temporal Fusion Transformer

El mecanismo de atención y la arquitectura Transformer, introducidas por Vaswani et al. (2017) [13] revolucionaron el procesamiento secuencial de datos y el *Deep Learning*. Hasta entonces, los dos paradigmas dominantes para el modelado de secuencias eran las arquitecturas recurrentes, en particular las *Redes Neuronales Recurrentes* (RNN) y los modelos de *Memoria Larga a Corto Plazo* (LSTM), y las arquitecturas convolucionales aplicadas a secuencias. Ambas familias presentaban limitaciones complementarias: las recurrentes procesaban la secuencia de forma inherentemente secuencial, lo que impedía su paralelización durante el entrenamiento, mientras que las convolucionales, aunque paralelizables, requerían apilar múltiples capas para capturar dependencias de largo alcance. El Transformer elimina simultáneamente la recurrencia y la convolución, reemplazándolas por un mecanismo de auto-atención que conecta cualquier par de posiciones de la secuencia en un número constante de operaciones, permitiendo tanto la paralelización completa del entrenamiento como el modelado directo de dependencias de largo alcance [13]. En esta sección se presenta primero

el mecanismo de atención y la arquitectura Transformer clásica, para luego describir el *Temporal Fusion Transformer* (TFT), la variante especializada para forecasting multihorizonte utilizada en este trabajo.

2.3.1. Mecanismo de atención

El mecanismo de atención permite que un modelo pondere diferencialmente la relevancia de distintas posiciones de una secuencia al producir una representación para cada posición. La idea central es que, al predecir el valor en el tiempo t , no todas las observaciones pasadas son igual de relevantes, algunas tienen mayor influencia que otras dependiendo del contexto.

Formalmente, el mecanismo de atención opera sobre tres matrices: las *queries* $\mathbf{Q} \in \mathbb{R}^{n \times d_k}$, las *keys* $\mathbf{K} \in \mathbb{R}^{m \times d_k}$ y los *values* $\mathbf{V} \in \mathbb{R}^{m \times d_v}$, donde n es el número de posiciones de consulta, m el número de posiciones de referencia, d_k la dimensión de las queries y keys, y d_v la dimensión de los values. La salida del mecanismo de atención es:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}} \right) \mathbf{V} \quad (2.14)$$

El término $\mathbf{Q}\mathbf{K}^\top \in \mathbb{R}^{n \times m}$ calcula los productos punto entre cada query y cada key, produciendo una matriz de *scores* que mide la afinidad entre pares de posiciones. La división por $\sqrt{d_k}$ estabiliza los gradientes durante el entrenamiento. Sin este factor, cuando d_k es grande los productos punto crecen en magnitud, empujando a la función softmax hacia regiones de gradiente muy pequeño. La función softmax normaliza los *scores* por filas, produciendo una distribución de probabilidad sobre las posiciones de referencia:

$$\alpha_{ij} = \frac{\exp(\mathbf{q}_i^\top \mathbf{k}_j / \sqrt{d_k})}{\sum_{l=1}^m \exp(\mathbf{q}_i^\top \mathbf{k}_l / \sqrt{d_k})} \quad (2.15)$$

donde α_{ij} es el peso de atención que la posición i asigna a la posición j . La salida para la posición i es entonces la combinación convexa de los values ponderada por estos pesos:

$$\mathbf{o}_i = \sum_{j=1}^m \alpha_{ij} \mathbf{v}_j \quad (2.16)$$

Este mecanismo se denomina *scaled dot-product attention* y tiene complejidad computacional $\mathcal{O}(n \cdot m \cdot d_k)$ en tiempo y $\mathcal{O}(n \cdot m)$ en memoria, lo que puede ser restrictivo para secuencias largas.

2.3.2. Atención multi-cabeza

En la práctica, es beneficioso que el modelo pueda atender a distintos tipos de relaciones simultáneamente, por ejemplo, dependencias de corto plazo y de largo plazo al mismo tiempo. La *atención multi-cabeza* (*multi-head attention*) logra esto proyectando las queries, keys y values en H subespacios distintos y calculando la atención en cada uno, de forma paralela:

$$\text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \dots, \text{head}_H) \mathbf{W}^O \quad (2.17)$$

donde cada cabeza se define como:

$$\text{head}_h = \text{Attention}(\mathbf{QW}_h^Q, \mathbf{KW}_h^K, \mathbf{VW}_h^V) \quad (2.18)$$

con matrices de proyección $\mathbf{W}_h^Q \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $\mathbf{W}_h^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $\mathbf{W}_h^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ y $\mathbf{W}^O \in \mathbb{R}^{Hd_v \times d_{\text{model}}}$. Típicamente se fija $d_k = d_v = d_{\text{model}}/H$ para mantener el costo computacional equivalente al de una sola cabeza de dimensión completa.

2.3.3. Arquitectura Transformer

El Transformer completo apila N bloques idénticos, cada uno compuesto por una capa de atención multi-cabeza seguida de una red neuronal de alimentación directa, también conocida como *Feed-Forward Network* (FFN), con conexiones residuales y normalización de capa alrededor de cada subcapa:

$$\mathbf{Z}^{(l)} = \text{LayerNorm}(\mathbf{Z}^{(l-1)} + \text{MultiHead}(\mathbf{Z}^{(l-1)}, \mathbf{Z}^{(l-1)}, \mathbf{Z}^{(l-1)})) \quad (2.19)$$

$$\mathbf{Z}^{(l+1)} = \text{LayerNorm}(\mathbf{Z}^{(l)} + \text{FFN}(\mathbf{Z}^{(l)})) \quad (2.20)$$

donde la FFN aplica dos transformaciones lineales con una activación no lineal intermedia:

$$\text{FFN}(\mathbf{z}) = \mathbf{W}_2 \text{ReLU}(\mathbf{W}_1 \mathbf{z} + \mathbf{b}_1) + \mathbf{b}_2 \quad (2.21)$$

Dado que el mecanismo de atención es invariante al orden de las posiciones, el Transformer incorpora *codificación posicional* (*positional encoding*) para inyectar información sobre la posición temporal de cada observación. La codificación posicional estándar usa funciones senosoidales:

$$\text{PE}(t, 2i) = \sin\left(\frac{t}{10000^{2i/d_{\text{model}}}}\right), \quad \text{PE}(t, 2i+1) = \cos\left(\frac{t}{10000^{2i/d_{\text{model}}}}\right) \quad (2.22)$$

donde t es la posición temporal y $2i, 2i + 1$ son las dimensiones del vector de codificación. Esta representación tiene la propiedad de que para cualquier desplazamiento fijo ϕ , el vector $\text{PE}(t + \phi)$ puede expresarse como una transformación lineal de $\text{PE}(t)$, permitiendo al modelo aprender relaciones relativas entre posiciones.

2.3.4. Temporal Fusion Transformer

El Temporal Fusion Transformer (TFT), propuesto por Lim et al. (2021) [10], extiende la arquitectura Transformer para el problema específico de forecasting multihorizonte con covariables heterogéneas. A diferencia del Transformer clásico, el TFT incorpora mecanismos explícitos para el manejo de covariables estáticas, selección de variables relevantes, procesamiento secuencial local e interpretabilidad de las dependencias temporales aprendidas. La arquitectura se organiza en cinco componentes principales que se describen a continuación.

Codificación de entradas y embeddings

El TFT recibe tres tipos de entradas: covariables estáticas $\mathbf{s} \in \mathbb{R}^{d_s}$, que no varían en el tiempo, por ejemplo, el identificador de barra, covariables temporales pasadas conocidas $\mathbf{x}_{t-L:t} \in \mathbb{R}^{L \times d_x}$ y covariables temporales futuras conocidas $\mathbf{x}_{t:t+H} \in \mathbb{R}^{H \times d_x}$, por ejemplo, el día de la semana o el indicador de feriado. Cada variable es proyectada a un espacio de representación de dimensión d_{model} mediante transformaciones lineales o embeddings aprendibles.

Gated Residual Network

El bloque fundamental del TFT es la *Gated Residual Network* (GRN), que permite al modelo suprimir información irrelevante mediante una compuerta aprendible:

$$\text{GRN}(\mathbf{a}, \mathbf{c}) = \text{LayerNorm}(\mathbf{a} + \text{GLU}(\mathbf{W}_1 \text{ELU}(\mathbf{W}_2 \mathbf{a} + \mathbf{W}_3 \mathbf{c} + \mathbf{b}_2) + \mathbf{b}_1)) \quad (2.23)$$

donde $\mathbf{a}$ es la entrada principal, $\mathbf{c}$ es un contexto opcional, ELU es la función de activación exponencial lineal, y GLU (*Gated Linear Unit*) es el mecanismo de compuerta definido como:

$$\text{GLU}(\mathbf{h}) = \sigma(\mathbf{W}_4 \mathbf{h} + \mathbf{b}_3) \odot (\mathbf{W}_5 \mathbf{h} + \mathbf{b}_4) \quad (2.24)$$

donde σ es la función sigmoide y $\odot$ denota el producto de Hadamard. La compuerta $\sigma(\cdot)$ puede aprender a anular completamente la contribución del bloque cuando la entrada no es informativa, lo que dota al TFT de una capacidad de regularización adaptativa que el Transformer clásico no posee.

Variable Selection Network

La *Variable Selection Network* (VSN) extiende la idea de la GRN para seleccionar, de manera suave y diferenciable, cuáles de las m_χ covariables disponibles son más relevantes para la predicción en cada paso temporal. Dada la concatenación Ξ_t de las representaciones de todas las covariables en el tiempo t , la VSN genera pesos de selección mediante una GRN seguida de una función softmax:

$$\mathbf{v}_t^\chi = \text{Softmax} \left(\text{GRN}_{v_\chi} (\Xi_t, \mathbf{c}_s) \right) \quad (2.25)$$

donde $\mathbf{c}_s$ es el vector de contexto derivado de las covariables estáticas mediante un encoder separado. Cada covariable j es además procesada por su propia GRN antes de la ponderación:

$$\tilde{\xi}_t = \sum_{j=1}^{m_\chi} v_{\chi_t}^{(j)} \cdot \tilde{\xi}_t^{(j)} \quad (2.26)$$

donde $v_{\chi_t}^{(j)}$ es el j -ésimo elemento del vector $\mathbf{v}_t^\chi$ y $\tilde{\xi}_t^{(j)}$ es la representación procesada de la covariable j en el tiempo t . Los pesos $v_{\chi_t}^{(j)}$ son interpretables y permiten identificar qué variables exógenas contribuyen más a la predicción en cada instante.

Procesamiento secuencial local

Antes de aplicar la atención global, el TFT procesa la secuencia temporal mediante una capa sequence-to-sequence basada en LSTM para capturar dependencias locales de corto plazo. El diseño usa un LSTM encoder para las entradas pasadas y un LSTM decoder para las entradas futuras conocidas, ambos unidireccionales para preservar la causalidad:

$$[\mathbf{h}_{t-L}, \dots, \mathbf{h}_t] = \text{LSTM}_{\text{enc}} \left(\left[\tilde{\xi}_{t-L}, \dots, \tilde{\xi}_t \right] \right) \quad (2.27)$$

$$[\mathbf{h}_{t+1}, \dots, \mathbf{h}_{t+H}] = \text{LSTM}_{\text{dec}} \left(\left[\tilde{\xi}_{t+1}, \dots, \tilde{\xi}_{t+H} \right] \right) \quad (2.28)$$

donde los estados iniciales del LSTM decoder se inicializan con vectores de contexto $\mathbf{c}_c$ y $\mathbf{c}_h$ derivados de las covariables estáticas, lo que permite que la información estática condicione el procesamiento local. Las salidas del LSTM se conectan al resto de la arquitectura mediante una conexión residual con compuerta (*Gated Skip Connection*):

$$\tilde{\phi}(t, n) = \text{LayerNorm} \left(\tilde{\xi}_{t+n} + \text{GLU}_{\tilde{\phi}}(\phi(t, n)) \right) \quad (2.29)$$

donde $\phi(t, n)$ es la salida del LSTM en la posición n relativa al tiempo de forecast t . Esta conexión residual cumple un rol de regularización: si el procesamiento local no aporta

información, la compuerta GLU puede suprimirlo completamente, permitiendo que el flujo de información saltee la capa y degradando el modelo graciosamente hacia una arquitectura más simple [10].

Dado que en este trabajo $H = 1$, la distinción encoder/decoder colapsa a una única pasada hacia adelante sobre la ventana de contexto, simplificando la notación a:

$$[\mathbf{h}_{t-L}, \dots, \mathbf{h}_t] = \text{LSTM} \left(\left[\tilde{\xi}_{t-L}, \dots, \tilde{\xi}_t \right] \right) \quad (2.30)$$

Esta combinación de LSTM y Transformer permite al TFT capturar tanto dependencias locales, a través del LSTM, como dependencias de largo alcance, a través de la atención.

Enriquecimiento estático

Las covariables estáticas, como el identificador de barra en este trabajo, no solo actúan como contexto para la selección de variables: el TFT les dedica una capa explícita de *enriquecimiento estático* que inyecta información estática directamente en las representaciones temporales antes de que estas entren al bloque de auto-atención. Formalmente, para cada posición n de la secuencia, la capa aplica una GRN condicionada por el vector de contexto estático $\mathbf{c}_e$:

$$\theta(t, n) = \text{GRN}_\theta \left(\tilde{\phi}(t, n), \mathbf{c}_e \right) \quad (2.31)$$

donde $\tilde{\phi}(t, n)$ es la representación local producida por la capa LSTM con su conexión residual y los pesos de la GRN son compartidos a lo largo de toda la secuencia. El efecto es que cada representación temporal queda condicionada por la identidad de la entidad, en este caso la barra eléctrica, permitiendo al modelo aprender dinámicas temporales distintas para cada nodo del sistema sin necesidad de entrenar instancias separadas [10].

Atención temporal interpretable

El TFT reemplaza la atención multi-cabeza estándar por una variante interpretable en la que todas las cabezas comparten la misma matriz de valores:

$$\text{InterpretableAttention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \tilde{\mathbf{A}} \mathbf{V} \mathbf{W}_V \quad (2.32)$$

$$\tilde{\mathbf{A}} = \frac{1}{H} \sum_{h=1}^H \text{softmax} \left(\frac{\mathbf{Q} \mathbf{W}_h^Q (\mathbf{K} \mathbf{W}_h^K)^\top}{\sqrt{d_k}} \right) \quad (2.33)$$

Al compartir los valores entre cabezas y promediar las matrices de atención, el TFT produce una única matriz $\tilde{\mathbf{A}}$ que puede visualizarse directamente para identificar qué instantes

temporales del pasado son más relevantes para la predicción. Esta propiedad es especialmente valiosa en el contexto del SEN, donde identificar qué horas o días del pasado influyen más en el costo marginal tiene valor interpretativo directo para los operadores del sistema.

Un requisito fundamental en forecasting es que el modelo no pueda acceder a observaciones futuras al generar una predicción, es decir, que la atención respete la causalidad temporal. El TFT garantiza esto mediante *enmascaramiento causal* (*decoder masking*): en la matriz de scores $\mathbf{QW}_h^Q(\mathbf{KW}_h^K)^\top$, todas las entradas que corresponden a posiciones futuras respecto al horizonte de predicción se fijan en $-\infty$ antes de aplicar la función softmax, lo que hace que sus pesos de atención sean exactamente cero tras la normalización [13, 10]. Formalmente, el elemento (i, j) de la matriz de atención satisface $\tilde{\mathbf{A}}_{ij} = 0$ para todo $j > i$. En el contexto de este trabajo, donde se predicen costos marginales horarios con datos del mercado eléctrico chileno, esta restricción no es solo una convención arquitectónica sino una condición de validez del modelo: permitir que la atención alcance instantes futuros equivaldría a filtración de información (*data leakage*) y produciría métricas de evaluación artificialmente optimistas.

Salidas cuantílicas

A diferencia del Transformer clásico que produce predicciones puntuales, el TFT genera predicciones para múltiples cuantiles $q \in \mathcal{Q}$ simultáneamente mediante capas lineales independientes aplicadas a la representación final:

$$\hat{y}_t^{(q)} = \mathbf{W}_q \mathbf{h}_t + \mathbf{b}_q \quad \forall q \in \mathcal{Q} \quad (2.34)$$

El modelo se entrena minimizando la pérdida de regresión cuantílica sumada sobre todos los cuantiles y horizontes:

$$\mathcal{L} = \sum_{q \in \mathcal{Q}} \sum_t \mathcal{L}_q(y_t, \hat{y}_t^{(q)}) \quad (2.35)$$

donde la pérdida cuantílica para el cuantil q es:

$$\mathcal{L}_q(y, \hat{y}) = \max(q(y - \hat{y}), (q - 1)(y - \hat{y})) \quad (2.36)$$

Esta formulación garantiza que $\hat{y}_t^{(q)}$ converja al cuantil q de la distribución condicional de Y_t , proporcionando intervalos de predicción sin supuestos distribucionales. En este trabajo se utilizan los cuantiles $\mathcal{Q} = \{0.02, 0.1, 0.25, 0.5, 0.75, 0.9, 0.98\}$, donde $\hat{y}_t^{(0.5)}$ es la predicción mediana y los cuantiles 0.02 y 0.98 definen un intervalo de predicción del 96 %.

2.3.5. Rol del TFT en la arquitectura híbrida

En el modelo propuesto, se entrenan dos instancias del TFT en paralelo: una sobre los residuos de Prophet $\{r_t\}$ y otra directamente sobre la serie original $\{y_t\}$. La primera ins-

tancia captura la variabilidad de corto plazo no explicada por la descomposición sistemática de Prophet, mientras que la segunda modela la serie completa sin restricciones de descomposición. Ambas instancias se comparan mediante las mismas métricas de evaluación, y sus predicciones, junto con las de Prophet, se combinan posteriormente mediante Stacking Optimization, como se detalla en la Sección 2.5.

Adicionalmente, las componentes descompuestas por Prophet, la tendencia $T(t)$, la estacionalidad $S(t)$ y el efecto de festividades $H(t)$, se incorporan como covariables exógenas en ambas instancias del TFT, permitiendo que el modelo de atención explote explícitamente la estructura temporal identificada por Prophet al construir sus representaciones.

2.4. Layer Normalization y Dynamic Tanh

Las capas de normalización son uno de los componentes fundamentales de las redes neuronales profundas modernas. Su adopción masiva está impulsada por sus beneficios empíricos en la optimización: aceleran la convergencia, estabilizan el entrenamiento y reducen la sensibilidad a la inicialización de parámetros [17]. En la arquitectura Transformer, y por extensión en el TFT, la normalización de capa o *Layer Normalization* (LayerNorm) aparece en cada bloque de la red: dentro de las GRN, alrededor de las capas de atención y en las conexiones residuales. Su presencia es tan sistemática que ha llegado a considerarse indispensable. En este trabajo se reemplaza LayerNorm por *Dynamic Tanh* (DyT) [21] en toda la arquitectura TFT, lo que constituye una de las contribuciones de diseño del modelo propuesto. En esta sección se presenta primero la formulación y propiedades de LayerNorm, luego se analiza el comportamiento empírico que motivó el desarrollo de DyT, y finalmente se describe DyT y se fundamenta su uso en el contexto de este trabajo.

2.4.1. Layer Normalization

La normalización de capa, propuesta por Ba et al. (2016) [2], opera de manera independiente para cada token en cada muestra del *batch*. Dado un vector de activaciones $\mathbf{x} \in \mathbb{R}^C$, donde C es la dimensión del embedding, LayerNorm calcula la media μ y la varianza σ^2 sobre las C dimensiones del propio vector y normaliza:

$$\text{LayerNorm}(\mathbf{x}) = \gamma \cdot \frac{\mathbf{x} - \mu}{\sqrt{\sigma^2 + \varepsilon}} + \beta \quad (2.37)$$

donde:

$$\mu = \frac{1}{C} \sum_{k=1}^C x_k, \quad \sigma^2 = \frac{1}{C} \sum_{k=1}^C (x_k - \mu)^2$$


y $\gamma, \beta \in \mathbb{R}^C$ son parámetros afines aprendibles, denominados, respectivamente, parámetros de escala y de desplazamiento, que permiten que la salida adopte cualquier rango. El término $\varepsilon > 0$ es una constante pequeña para estabilidad numérica.

A diferencia de la normalización por *batch* (*Batch Normalization*), que calcula estadísticas a través de muestras del *batch* y posiciones temporales, LayerNorm calcula las estadísticas de manera completamente local para cada token en cada muestra, lo que la hace independiente del tamaño del *batch* y adecuada para secuencias de longitud variable. Esta propiedad es especialmente importante en el contexto del TFT, donde el tamaño del *batch* puede variar y las secuencias temporales tienen estructura heterogénea.


El rol funcional de LayerNorm en el Transformer es doble. En primer lugar, centra y escala las activaciones para mantenerlas en un rango controlado, lo que estabiliza el flujo de gradientes a través de las capas profundas. En segundo lugar, al operar por token, introduce una no-linealidad implícita: aunque la operación de centrado y escalado es lineal para cada token individualmente, la diversidad de medias y varianzas entre tokens hace que la transformación completa sobre todas las activaciones del tensor sea no-lineal.

2.4.2. Comportamiento empírico de LayerNorm: curvas tipo tanh

Un resultado empírico central del trabajo de Zhu et al. (2025) [21] es que las capas LayerNorm en Transformers entrenados producen, de manera consistente y no trivial, mapeos entrada-salida con forma de curva en S , estadísticamente similares a la función $\tanh$. Este comportamiento fue documentado en tres arquitecturas Transformer de dominios distintos: Vision Transformer (ViT), modelos de habla (wav2vec 2.0) y modelos de difusión (DiT), observándose el mismo patrón en todos los casos para las capas más profundas de la red.



(a) Entrada-salida producidas por LayerNorm.



(b) $\tanh(\alpha x)$ con tres valores diferentes de α

Figura 2.3: Similitud entre los mapeos entrada-salida de LayerNorm y la función $\tanh$ escalada.

Para entender por qué emergen estas curvas, es útil notar que LayerNorm realiza una transformación lineal independiente para cada token. Dado el token i , todos sus elementos x_{ik} se escalan por el mismo factor $1/\sigma_i$. Sin embargo, como cada token tiene una varianza distinta, las pendientes de estas transformaciones lineales son distintas entre sí. Cuando se visualizan en conjunto todas las activaciones del tensor, los segmentos de recta de distintas pendientes se ensamblan formando una curva en S no-lineal. Las pocas activaciones con valores extremos, aquellas con $|x_{ik}|$ grande, son las más afectadas por la normalización, pues

sus varianzas son altas y el factor $1/\sigma_i$ las comprime fuertemente. Este efecto de *squashing* no-lineal sobre valores extremos es, según Zhu et al. (2025), la propiedad esencial de LayerNorm que explica su importancia en el entrenamiento de redes profundas.

Esta observación tiene una implicación directa: si el comportamiento funcional de LayerNorm es empíricamente similar al de una función $\tanh$ escalada, entonces una operación definida explícitamente como $\tanh(\alpha \mathbf{x})$ podría reproducir dicho comportamiento de manera más directa, sin necesidad de calcular estadísticas de activación.

2.4.3. Dynamic Tanh (DyT)

Inspirados por la similitud entre los mapeos de LayerNorm y la función $\tanh$, Zhu et al. (2025) [21] proponen *Dynamic Tanh* (DyT) como un reemplazo directo (*drop-in replacement*) de las capas de normalización en Transformers. Para un tensor de entrada $\mathbf{x}$, una capa DyT se define como:

$$\text{DyT}(\mathbf{x}) = \gamma \cdot \tanh(\alpha \mathbf{x}) + \beta \quad (2.38)$$

donde $\alpha \in \mathbb{R}$ es un escalar aprendible que controla la escala de la entrada antes de la función $\tanh$, y $\gamma, \beta \in \mathbb{R}^C$ son parámetros afines aprendibles, análogos a los de LayerNorm. La operación es completamente *elemento a elemento*: no requiere calcular ninguna estadística del tensor de entrada (media, varianza), lo que la distingue del resto de variantes de normalización.




Figura 2.4: Bloque Transformer original (Izquierda) y propuesta Transformer con DyT (Derecha). DyT reemplaza directamente a LayerNorm sin modificar el resto de la arquitectura [21].

El parámetro α cumple un rol central. Al escalar la entrada antes de $\tanh$, controla la pendiente efectiva de la curva en S : valores grandes de α producen una saturación más rápida, es decir, una curva más abrupta, mientras que valores pequeños producen un comportamiento más lineal en el rango central. Durante el entrenamiento, α aprende a rastrear aproximadamente $1/\sigma$ de las activaciones de entrada, de manera análoga a cómo LayerNorm normaliza por la desviación estándar. Zhu et al. (2025) [21] verifican empíricamente esta correlación: los valores finales de α en redes entrenadas presentan una fuerte correlación positiva con $1/\sigma$ de las activaciones correspondientes.

Para entender por qué α converge a $1/\sigma$, es útil considerar el comportamiento de $\tanh$ en la región lineal. Para valores pequeños de $|\alpha x|$, la función $\tanh$ admite la aproximación de primer orden:

$$\tanh(\alpha x) \approx \alpha x, \quad |\alpha x| \ll 1 \quad (2.39)$$

En esta región, DyT se comporta como una transformación lineal $\gamma \cdot \alpha \mathbf{x} + \beta$, estructuralmente análoga a la parte lineal de LayerNorm con factor de escala efectivo α . Si la red aprende a minimizar la discrepancia entre el comportamiento de DyT y el de LayerNorm, el valor óptimo de α en la región central debe satisfacer $\alpha \approx 1/\sigma$, pues ese es el factor de escala que LayerNorm aplica. Fuera de la región lineal, la saturación de $\tanh$ comprime los valores extremos, replicando el efecto de *squashing* de LayerNorm sobre activaciones con varianza alta. Este razonamiento conecta la observación empírica de Zhu et al. con la dinámica de optimización: α converge a $1/\sigma$ porque es el punto de equilibrio que minimiza la diferencia funcional entre DyT y LayerNorm para las activaciones de la red. A diferencia de LayerNorm, donde el factor de escala $1/\sigma$ se recalcula explícitamente en cada pasada hacia adelante a partir de las estadísticas del batch, en DyT este factor emerge de manera implícita como consecuencia del entrenamiento: la red aprende a normalizarse a sí misma sin requerir cómputo de estadísticas, lo que constituye una forma de normalización paramétrica en contraste con la normalización estadística de LayerNorm.




Figura 2.5: Seguimiento de $1/\sigma$ y α a final de cada época.

La inicialización de α es relevante para la estabilidad del entrenamiento. Para modelos no-LLM, Zhu et al. (2025) [21] recomiendan $\alpha_0 = 0.5$ como valor por defecto, con γ inicializado en $\mathbf{1}$ y β en $\mathbf{0}$, en analogía directa con la inicialización estándar de LayerNorm. Con esta configuración, DyT produce curvas de convergencia prácticamente idénticas a las de LN sin necesidad de ajustar ningún otro hiperparámetro del modelo original.

2.4.4. LayerNorm vs DyT

La diferencia estructural más importante entre LayerNorm y DyT es la ausencia de cálculo de estadísticas en DyT. En LayerNorm, cada pasada hacia adelante requiere calcular μ y

σ^2 sobre las C dimensiones de cada token, lo que implica una operación de reducción (*reduction*) que introduce dependencias entre elementos del tensor y limita ciertas optimizaciones de hardware. DyT, al ser completamente elemento a elemento, elimina esta dependencia, sin embargo, Zhu et al. (2025) reportan que, una vez que los modelos se compilan con optimizaciones estándar (`torch.compile`), las latencias de ambas operaciones se igualan, de modo que la ventaja computacional de DyT es marginal en práctica sobre hardware convencional.

Las diferencias funcionales más sustanciales son las siguientes. LayerNorm normaliza *por token*: cada token es escalado por su propia desviación estándar, lo que hace que la transformación sea adaptativa a las estadísticas locales de cada posición temporal. DyT, en cambio, aplica un único escalar global α a todas las posiciones, lo que equivale a una normalización colectiva del tensor completo. Esta distinción es relevante para series temporales con alta variabilidad entre pasos: LayerNorm se adapta localmente a cada paso, mientras que DyT aprende un comportamiento promedio. La segunda diferencia relevante es que LayerNorm centra las activaciones (resta la media), mientras que DyT no lo hace explícitamente. La función $\tanh$ es impar y centrada en cero, lo que introduce un sesgo implícito hacia el centrado, pero sin la garantía de media exactamente cero que provee LayerNorm.

Un aspecto adicional relevante es la elección de la función de *squashing*. Zhu et al. (2025) evalúan alternativas a $\tanh$ en DyT: la función identidad (sin squashing), *hardtanh* y sigmoide.




Figura 2.6: Curvas de tres funciones squashing: $\tanh$, hardtanh y sigmoide.

Los resultados muestran que la ausencia de squashing produce divergencia del entrenamiento, lo que confirma que el efecto de compresión de valores extremos es indispensable. Entre las funciones de squashing, $\tanh$ supera a las demás en rendimiento, lo que los autores atribuyen a dos propiedades: su *suavidad* (es infinitamente diferenciable, a diferencia de *hardtanh* que tiene discontinuidades en la derivada) y su *simetría* respecto al cero (es una función impar, lo que favorece gradientes equilibrados durante el entrenamiento). Estas propiedades hacen que $\tanh$ sea la función de squashing más apta para reemplazar LayerNorm en Transformers.

model	identity	$\tanh$	hardtanh	sigmoid
ViT-S	58.5% $\rightarrow$ failed	80.3%	79.9%	79.6%
ViT-B	61.0% $\rightarrow$ failed	82.5%	82.2%	81.6%

Figura 2.7: Accuracy de clasificación en ImageNet-1K con diferentes funciones de squashing

En términos de rendimiento empírico, Zhu et al. (2025) reportan que DyT iguala o supera a LayerNorm en una amplia variedad de tareas y arquitecturas, incluyendo clasificación de

imágenes con ViT y ConvNeXt, aprendizaje auto-supervisado con MAE y DINO, modelos de difusión DiT, modelos de lenguaje LLaMA (7B a 70B), modelos de habla wav2vec 2.0 y modelos de secuencias genómicas. En todos los casos, los modelos con DyT entrenados con los mismos hiperparámetros del modelo original con LayerNorm producen resultados comparables o mejores, sin ajuste adicional.

model	LN	DyT	change
ViT-B	82.3%	82.5%	↑0.2%
ViT-L	83.1%	83.6%	↑0.5%
ConvNeXt-B	83.7%	83.7%	-
ConvNeXt-L	84.3%	84.4%	↑0.1%

(a) Clasificación ImageNet-1K.

score / loss	RMSNorm	DyT	change
LLaMA 7B	0.513 / 1.59	0.513 / 1.60	- / ↑0.01
LLaMA 13B	0.529 / 1.53	0.529 / 1.54	- / ↑0.01
LLaMA 34B	0.536 / 1.50	0.536 / 1.50	- / -
LLaMA 70B	0.549 / 1.45	0.549 / 1.45	- / -

(b) Lenguaje (zero-shot).

model	LN	DyT	change
DiT-B	64.9	63.9	↓1.0
DiT-L	45.9	45.7	↓0.2
DiT-XL	19.9	20.8	↑0.9

(c) Generación de imágenes (FID).

model	LN	DyT	change
wav2vec 2.0 Base	1.95	1.95	-
wav2vec 2.0 Large	1.92	1.91	↓0.01

(d) Preentrenamiento de voz.

Figura 2.8: Resultados experimentales: (a) ViT en ImageNet-1K, (b) LLaMA en lm-eval, (c) DiT en generación de imágenes, (d) wav2vec en LibriSpeech.

2.4.5. Uso de DyT en el TFT para predicción de costos marginales

En el modelo propuesto en este trabajo, DyT reemplaza a LayerNorm en todos los puntos donde esta aparece en la arquitectura TFT: dentro de cada bloque GRN (en la conexión residual final), en las conexiones residuales con compuerta (*gated skip connections*) de la capa LSTM, en la capa de enriquecimiento estático y en la capa de auto-atención interpretable. La sustitución es uniforme y directa: cada ocurrencia de $\text{LayerNorm}(\mathbf{a} + \text{GLU}(\cdot))$ en las ecuaciones de la Sección 2.3.4 se reemplaza por $\text{DyT}(\mathbf{a} + \text{GLU}(\cdot))$, manteniendo inalterada la estructura del bloque.

El parámetro α es independiente para cada capa DyT de la red, lo que significa que el TFT aprende factores de escala distintos para cada GRN, cada conexión residual del LSTM y cada capa de atención. Esta flexibilidad permite que la red calibre el grado de squashing de manera diferenciada según la variabilidad de las activaciones en cada módulo.

La motivación principal para adoptar DyT en este contexto es la naturaleza de las series de costo marginal en el Sistema Eléctrico Nacional (SEN). Los costos marginales horarios presentan una distribución fuertemente asimétrica con colas pesadas: en condiciones normales los valores se ubican en el rango de \$20 a \$80 USD/MWh, pero durante eventos de escasez

hídrica, fallas de generación o congestiones de transmisión pueden producirse *spikes* que superan los \$300 USD/MWh, valores que exceden en más de un orden de magnitud el rango habitual. En el contexto de la arquitectura TFT, estos valores extremos se propagan como activaciones de gran magnitud a través de los bloques GRN y las capas de atención. LayerNorm los comprime normalizando por la desviación estándar del token correspondiente, pero esta compresión depende de la estadística local de cada paso temporal, lo que puede generar gradientes inestables cuando un token aislado contiene un valor extremo rodeado de valores normales. DyT, al aplicar la saturación de tanh directamente sobre las activaciones mediante el escalar global α , comprime los valores extremos de manera más uniforme e independiente de la estadística local, actuando como una forma de regularización implícita sobre los spikes del costo marginal.

Una segunda consideración es la interacción entre DyT y el mecanismo de atención interpretable del TFT. Dado que los pesos de atención $\tilde{\mathbf{A}}_{ij}$ se calculan sobre representaciones que ya han pasado por la capa de enriquecimiento estático con DyT, la compresión de activaciones extremas garantiza que los scores de atención no sean dominados por spikes temporales, lo que favorece la interpretabilidad: los instantes pasados más relevantes para la predicción reflejan patrones estructurales del mercado eléctrico y no artefactos de valores atípicos.

La inicialización de α sigue la recomendación de Zhu et al. (2025) para modelos no-LLM, fijando $\alpha_0 = 0.5$ con $\gamma = \mathbf{1}$ y $\beta = \mathbf{0}$. Con esta configuración, el TFT con DyT puede entrenarse directamente con los mismos hiperparámetros utilizados en la versión con LayerNorm, sin requerir ajuste adicional, lo que simplifica el proceso de búsqueda de hiperparámetros y hace la comparación entre ambas versiones directamente interpretable.

En el contexto del modelo híbrido propuesto, la elección de DyT tiene una implicancia adicional que va más allá del rendimiento individual del TFT. Dado que el esquema de Stacking Optimization descrito en la Sección 2.5 combina las predicciones del TFT con LayerNorm, el TFT con DyT y Prophet mediante una combinación lineal con pesos aprendidos, la diversidad entre los modelos base es un factor determinante de la calidad del ensamblaje: modelos que cometen errores distintos y poco correlacionados se complementan mejor que modelos similares. Al reemplazar LayerNorm por DyT se introduce una diferencia estructural en el mecanismo de normalización que, en presencia de spikes del costo marginal, puede producir distribuciones de error cualitativamente distintas entre ambas variantes del TFT. Esta diversidad estructural es precisamente lo que el Stacking Optimization puede explotar para mejorar la predicción conjunta, haciendo de la comparación LayerNorm versus DyT no solo un experimento de ablación sino un componente funcional del modelo híbrido.

2.5. Stacking Optimization

El *Stacking*, también denominado *stacked generalization*, es una técnica de ensamblaje de modelos introducida por Wolpert (1992) [16] que combina las predicciones de múltiples modelos base mediante un metamodelo entrenado para minimizar el error de predicción conjunta. A diferencia de métodos de ensamblaje más simples como el promedio o el voto mayoritario, el Stacking aprende los pesos de combinación de forma supervisada, lo que le permite asignar mayor importancia a los modelos base que presentan menor error en las

regiones del espacio de entrada donde los demás fallan.

La intuición central del Stacking es la siguiente: distintos modelos base capturan aspectos complementarios de la distribución de los datos, y el metamodelo puede explotar esta complementariedad combinando sus predicciones de manera que se cancelen los errores individuales. Para que esta cancelación sea efectiva, es necesario que los errores de los modelos base estén escasamente correlacionados, condición que se denomina *diversidad del ensamble* [3].

2.5.1. Formulación general y diversidad del ensamble

Sea $\{M_k\}_{k=1}^K$ un conjunto de K modelos base, donde cada modelo M_k produce una predicción $\hat{y}_t^{(k)}$ para el instante t . El Stacking construye un vector de meta-características:

$$\tilde{\mathbf{z}}_t = \left(\hat{y}_t^{(1)}, \hat{y}_t^{(2)}, \dots, \hat{y}_t^{(K)} \right)^\top \in \mathbb{R}^K \quad (2.40)$$

y entrena un metamodelo $g : \mathbb{R}^K \rightarrow \mathbb{R}$ tal que:

$$\hat{y}_t^{\text{stack}} = g(\tilde{\mathbf{z}}_t) \quad (2.41)$$

En su formulación más simple, g es una combinación lineal con pesos $\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_K)^\top$:

$$\hat{y}_t^{\text{stack}} = \sum_{k=1}^K \alpha_k \hat{y}_t^{(k)} = \boldsymbol{\alpha}^\top \tilde{\mathbf{z}}_t \quad (2.42)$$

Los pesos $\boldsymbol{\alpha}$ se estiman minimizando el error cuadrático medio sobre un conjunto de validación:

$$\hat{\boldsymbol{\alpha}} = \arg \min_{\boldsymbol{\alpha}} \sum_{t \in \mathcal{V}} (y_t - \boldsymbol{\alpha}^\top \tilde{\mathbf{z}}_t)^2 \quad (2.43)$$

donde $\mathcal{V}$ denota el conjunto de índices de validación. En la práctica, la minimización de (2.43) puede realizarse mediante métodos analíticos como mínimos cuadrados o mediante optimización metaheurística.

La ganancia teórica del Stacking sobre cualquiera de los modelos base individuales depende de la diversidad de los errores de predicción. Si $\varepsilon_t^{(k)} = y_t - \hat{y}_t^{(k)}$ denota el error del modelo k en el instante t , el error del ensamble lineal con pesos $\boldsymbol{\alpha}$ es $\varepsilon_t^{\text{stack}} = \sum_{k=1}^K \alpha_k \varepsilon_t^{(k)}$, y su varianza, asumiendo $\sum_k \alpha_k = 1$, es:

$$\text{Var}(\varepsilon_t^{\text{stack}}) = \boldsymbol{\alpha}^\top \boldsymbol{\Sigma} \boldsymbol{\alpha} \quad (2.44)$$

donde $\Sigma \in \mathbb{R}^{K \times K}$ es la matriz de covarianzas de los errores con $\Sigma_{ij} = \text{Cov}(\varepsilon_t^{(i)}, \varepsilon_t^{(j)})$. Cuando los errores están perfectamente correlacionados ($\Sigma = \sigma^2 \mathbf{1}\mathbf{1}^\top$), el ensamble no reduce la varianza del error respecto al modelo base promedio. En cambio, cuando los errores son incorrelacionados ($\Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_K^2)$), la varianza del ensamble es estrictamente menor que la de cualquier modelo base individual con pesos uniformes [3]. Esta observación justifica la importancia de seleccionar modelos base estructuralmente distintos. Cuando los modelos base presentan predicciones muy correlacionadas, la matriz de diseño $\tilde{\mathbf{Z}} = (\tilde{\mathbf{z}}_t)_{t \in \mathcal{V}}$ puede ser casi singular, lo que hace preferible la estimación regularizada mediante regresión de Ridge:

$$\hat{\alpha} = \left(\tilde{\mathbf{Z}}^\top \tilde{\mathbf{Z}} + \lambda \mathbf{I} \right)^{-1} \tilde{\mathbf{Z}}^\top \mathbf{y}_{\mathcal{V}} \quad (2.45)$$

donde $\lambda > 0$ es el parámetro de regularización y $\mathbf{y}_{\mathcal{V}}$ es el vector de valores observados en el conjunto de validación.

2.5.2. Protocolo de entrenamiento y prevención de data leakage

Un aspecto crítico del Stacking en el contexto de series temporales es la prevención del *data leakage* al construir el conjunto de meta-características. En problemas de clasificación o regresión con datos i.i.d., el procedimiento estándar consiste en generar las predicciones de los modelos base mediante validación cruzada k -fold: cada modelo base se entrena en los $k - 1$ folds restantes y produce predicciones fuera de muestra para el fold reservado, de modo que las meta-características $\tilde{\mathbf{z}}_t$ son siempre predicciones fuera de muestra [16]. Este protocolo garantiza que el metamodelo se entrena sobre predicciones que no han visto los datos de entrenamiento de los modelos base, evitando sobreajuste.

En series temporales, la validación cruzada estándar no es aplicable porque viola el orden temporal de las observaciones: entrenar con datos futuros para predecir el pasado inflaría artificialmente el rendimiento de los modelos base y produciría meta-características con filtración de información. El protocolo correcto para series temporales es la *validación cruzada con expansión temporal* (*time series split*), ilustrada en la Figura 2.9:

1. Se divide la serie en $K + 1$ bloques cronológicos de igual tamaño.
2. En la iteración $k \in \{1, \dots, K\}$, los modelos base se entrenan sobre los primeros k bloques y producen predicciones fuera de muestra sobre el bloque $k + 1$.
3. Las predicciones fuera de muestra de todos los modelos base para cada observación se concatenan para formar $\tilde{\mathbf{z}}_t$.
4. El metamodelo se entrena sobre $\{\tilde{\mathbf{z}}_t, y_t\}_{t \in \mathcal{V}}$, donde $\mathcal{V}$ es el conjunto de validación final, cronológicamente posterior al período de entrenamiento de los modelos base.

Este protocolo garantiza que en ningún punto se utilizan observaciones futuras para generar las meta-características, preservando la causalidad temporal del proceso de estimación.




Figura 2.9: Visualización de Time Series Split.

2.5.3. Stacking Optimization en el modelo híbrido propuesto

En el modelo propuesto en este trabajo, el Stacking combina las predicciones de tres modelos base: Prophet, el TFT con LayerNorm entrenado sobre los residuos de Prophet (denominado TFT_{LN}) y el TFT con DyT entrenado sobre la serie original (denominado TFT_{DyT}). La predicción del ensamble en el instante t para la barra b es:

$$\hat{y}_t^{(b), \text{Stack}} = \alpha_1^{(b)} \hat{y}_t^{(b), \text{Prophet}} + \alpha_2^{(b)} \left(\hat{y}_t^{(b), \text{Prophet}} + \hat{r}_t^{(b), \text{TFT}_{\text{LN}}} \right) + \alpha_3^{(b)} \hat{y}_t^{(b), \text{TFT}_{\text{DyT}}} \quad (2.46)$$

donde $\hat{r}_t^{(b), \text{TFT}_{\text{LN}}}$ es la predicción del TFT_{LN} sobre el residuo de Prophet, de modo que $\hat{y}_t^{(b), \text{Prophet}} + \hat{r}_t^{(b), \text{TFT}_{\text{LN}}}$ constituye una predicción en la escala original de la serie. Los pesos $\alpha^{(b)} = (\alpha_1^{(b)}, \alpha_2^{(b)}, \alpha_3^{(b)})^\top$ son específicos por barra y se estiman resolviendo (2.43) sobre el conjunto de validación, con regularización Ridge según (2.45) como una de las alternativas consideradas para controlar la colinealidad entre las predicciones de los dos modelos TFT.

La motivación para incluir los tres modelos base responde directamente al principio de diversidad discutido en la Sección 2.5.1. Prophet captura la estructura de largo plazo de la serie mediante descomposición aditiva interpretable, pero sus errores son sistemáticos en presencia de fluctuaciones no lineales de corto plazo. El TFT_{LN} modela la variabilidad residual de corto plazo y hereda la estabilidad de LayerNorm frente a secuencias de amplitud moderada. El TFT_{DyT} , al operar sobre la serie completa con la compresión de tanh, es más robusto frente a los *spikes* del costo marginal descritos en la Sección 2.4.4, pero puede sobreajustar la tendencia en períodos de baja volatilidad. Esta heterogeneidad estructural en los patrones de error favorece covarianzas $\text{Cov}(\varepsilon^{(i)}, \varepsilon^{(j)})$ pequeñas en magnitud, lo que, por la descomposición de la varianza del ensamble de (2.43), garantiza que el Stacking produce ganancias de predicción medibles respecto a cualquiera de los modelos base por separado.

Finalmente, la predicción puntual $\hat{y}_t^{(b), \text{Stack}}$ sirve como centro de los intervalos de predicción contruidos mediante Conformal Prediction en la Sección 2.6.

2.6. Conformal Prediction

La *Predicción Conforme* o *Conformal Prediction* (CP) es un marco estadístico para construir intervalos de predicción con garantías de cobertura finita sin supuestos distribucionales

sobre los datos, más allá de la intercambiabilidad [14]. A diferencia de los métodos probabilísticos clásicos, cuyas garantías son asintóticas o requieren supuestos paramétricos sobre el modelo, CP produce intervalos válidos para cualquier algoritmo de predicción subyacente, incluyendo redes neuronales, modelos de ensamble y modelos híbridos como el propuesto en este trabajo.

Formalmente, dado un nivel de no-cobertura $\alpha \in (0, 1)$ fijado por el usuario, el objetivo es construir un intervalo de predicción $C_{n,\alpha}(x_{n+1})$ tal que:

$$\mathbb{P}\{Y_{n+1} \in C_{n,\alpha}(X_{n+1})\} \geq 1 - \alpha \quad (2.47)$$

Un intervalo que satisface (2.47) se denomina *marginamente válido*. Al mismo tiempo, se exige que el intervalo sea *eficiente*, es decir, lo más estrecho posible: intervalos excesivamente anchos son válidos pero no informativos. El equilibrio entre validez y eficiencia es el criterio central para comparar las distintas variantes de CP [19].

La propiedad de intercambiabilidad es el supuesto base de CP: una secuencia aleatoria $(Z_1, \dots, Z_n)$ es intercambiable si su distribución conjunta es invariante bajo cualquier permutación de los índices. Este supuesto es más débil que la independencia e idéntica distribución (i.i.d.), pero excluye las series temporales, donde la dependencia temporal viola la intercambiabilidad. Esta limitación motiva las variantes adaptativas de CP descritas en las siguientes Secciones.

2.6.1. Split Conformal Prediction (SCP)

La *Split Conformal Prediction* (SCP) es la variante más simple y computacionalmente eficiente de CP, introducida por Papadopoulos et al. (2002) y reformulada por Lei et al. (2018) [9]. Su idea central es dividir el conjunto de entrenamiento en dos partes: un subconjunto de entrenamiento propio $\mathcal{T}r$ y un conjunto de calibración $\mathcal{Cal}$, de modo que el modelo se ajusta solo sobre $\mathcal{T}r$ y los residuos sobre $\mathcal{Cal}$ se usan para construir el intervalo.

Dado un modelo de predicción $\hat{\mu}$ ajustado sobre $\mathcal{T}r$, se define la *puntuación de conformidad* (*conformity score*) de cada punto de calibración como el residuo absoluto:

$$S_i = |y_i - \hat{\mu}(x_i)|, \quad i \in \mathcal{Cal} \quad (2.48)$$

El conjunto de puntuaciones de calibración es $\mathcal{S} = \{S_i\}_{i \in \mathcal{Cal}} \cup \{+\infty\}$, donde el valor $+\infty$ se añade para garantizar la validez de cobertura en muestra finita. Se calcula el cuantil corregido de nivel $1 - \alpha$ sobre $\mathcal{S}$:

$$\hat{q}_{1-\alpha}(\mathcal{S}) = \text{Cuantil}(1 - \alpha; \mathcal{S}) \quad (2.49)$$

El intervalo de predicción para un nuevo punto x_{n+1} es entonces:

$$C_{n,\alpha}(x_{n+1}) = [\hat{\mu}(x_{n+1}) - \hat{q}_{1-\alpha}(\mathcal{S}), \hat{\mu}(x_{n+1}) + \hat{q}_{1-\alpha}(\mathcal{S})] \quad (2.50)$$

Teorema 2.6.1 (Validez marginal de SCP [9]) Si $(X_1, Y_1), \dots, (X_n, Y_n), (X_{n+1}, Y_{n+1})$ son intercambiables y $\hat{\mu}$ es independiente del conjunto de calibración $\mathcal{Cal}$, entonces el intervalo (2.50) satisface:

$$1 - \alpha \leq \mathbb{P}\{Y_{n+1} \in C_{n,\alpha}(X_{n+1})\} \leq 1 - \alpha + \frac{1}{|\mathcal{Cal}| + 1} \quad (2.51)$$

La cota superior en (2.51) muestra que la cobertura excede el nivel nominal en a lo más $\frac{1}{|\mathcal{Cal}|+1}$, un término que tiende a cero conforme crece el conjunto de calibración. En la práctica, mantener entre el 10 % y el 30 % del conjunto de entrenamiento para calibración es un compromiso adecuado entre el tamaño del conjunto de calibración y la precisión del modelo ajustado [19].

La principal limitación de SCP es que produce intervalos de ancho constante, independiente de las covariables x_{n+1} : el cuantil $\hat{q}_{1-\alpha}(\mathcal{S})$ es un escalar global, lo que implica que el intervalo tendrá el mismo ancho para instantes con alta volatilidad que para instantes con precios estables. En el contexto del SEN, donde los spikes del costo marginal concentran la incertidumbre en regímenes específicos, esta rigidez reduce la eficiencia del intervalo. La segunda limitación, más fundamental para series temporales, es que la garantía (2.51) requiere intercambiabilidad, supuesto que no se cumple en datos con dependencia temporal.

2.6.2. Conformal Prediction con Ensemble (EnbPI)

Ensemble Prediction Interval o *EnbPI*, fue propuesto por Xu y Xie (2021) [18] como una adaptación de CP a series temporales mediante la incorporación de un componente de *bootstrap* que permite actualizar los scores de conformidad de manera secuencial sin reajustar el modelo subyacente, reduciendo así el costo computacional.

El procedimiento de EnbPI opera en dos fases. En la fase de entrenamiento, se generan B muestras bootstrap del conjunto de entrenamiento $\{(x_t, y_t)\}_{t=1}^{T_0}$ y se ajusta el modelo de predicción $\hat{\mu}_b$ sobre cada muestra $b \in \{1, \dots, B\}$. Para cada punto de entrenamiento $t \leq T_0$, EnbPI construye una predicción fuera de muestra agregando únicamente los predictores entrenados en muestras bootstrap que no incluyen el punto (x_t, y_t) :

$$\hat{\mu}^{(-t)}(x_t) = \frac{1}{|\mathcal{B}_{-t}|} \sum_{b \in \mathcal{B}_{-t}} \hat{\mu}_b(x_t) \quad (2.52)$$

donde $\mathcal{B}_{-t} = \{b : (x_t, y_t) \notin \text{muestra}_b\}$ es el subconjunto de predictores no entrenados sobre el punto t . Los scores de calibración se definen entonces como $S_t = |y_t - \hat{\mu}^{(-t)}(x_t)|$ para $t \leq T_0$.

En la fase de predicción para instantes $t > T_0$, EnbPI agrega todos los B predictores para

producir la predicción puntual $\hat{\mu}(x_t) = \frac{1}{B} \sum_{b=1}^B \hat{\mu}_b(x_t)$ y actualiza secuencialmente el conjunto de scores incorporando el residuo más reciente y descartando el más antiguo, manteniendo así una ventana deslizante de scores de calibración. El intervalo en el instante t es:

$$C_t(x_t) = [\hat{\mu}(x_t) - \hat{q}_{1-\alpha}(\mathcal{S}_t), \hat{\mu}(x_t) + \hat{q}_{1-\alpha}(\mathcal{S}_t)] \quad (2.53)$$

donde $\mathcal{S}_t$ es el conjunto de scores actualizado hasta el instante $t - 1$. La ventaja clave de EnbPI respecto a SCP es que los intervalos se adaptan a la volatilidad reciente de la serie sin necesidad de reajustar el modelo, lo que permite capturar cambios en la distribución del error a lo largo del tiempo.

En este trabajo se implementa la variante *EnbPI V2*, que utiliza la agregación por media en todas las fases del procedimiento en lugar de mezclar media y cuantil, corrección que mejora la cobertura empírica [19].

2.6.3. Adaptive Conformal Inference (ACI)

La *Adaptive Conformal Inference* (ACI) fue propuesta por Gibbs y Candès (2021) [4] para adaptarse a series temporales bajo cambios de distribución arbitrarios. La idea central de ACI es reemplazar el nivel de no-cobertura fijo α por un nivel efectivo α_t que se actualiza recursivamente en función del historial de cobertura:

$$\alpha_{t+1} = \alpha_t + \gamma (\alpha - \mathbf{1}\{y_t \notin C_t(x_t)\}) \quad (2.54)$$

donde $\gamma > 0$ es un hiperparámetro de tasa de aprendizaje y $\mathbf{1}\{\cdot\}$ es la función indicadora. La lógica de la actualización (3.5) es la siguiente: si en el instante t el intervalo no cubre el valor real ($y_t \notin C_t$), entonces $\alpha_{t+1} < \alpha_t$, lo que amplía el intervalo en la siguiente predicción; si cubre, $\alpha_{t+1} > \alpha_t$, reduciendo el intervalo. Inicialmente se fija $\alpha_1 = \alpha$.

El intervalo de predicción en el instante t se construye con el nivel actualizado:

$$C_t(x_t) = [\hat{\mu}_t(x_t) - \hat{q}_{1-\alpha_t}(\mathcal{S}_{\text{cal}_t}), \hat{\mu}_t(x_t) + \hat{q}_{1-\alpha_t}(\mathcal{S}_{\text{cal}_t})] \quad (2.55)$$

donde $\hat{\mu}_t$ es el modelo reajustado en el instante t sobre los T_0 puntos más recientes y $\mathcal{S}_{\text{cal}_t}$ es el conjunto de scores del conjunto de calibración en el instante t .

La garantía de cobertura de ACI es asintótica: bajo cualquier distribución de los datos, la frecuencia de no-cobertura converge al nivel nominal [4]:

$$\frac{1}{T_1} \sum_{t=T_0+1}^{T_0+T_1} \mathbf{1}\{y_t \notin C_t(x_t)\} \xrightarrow{a.s.} \alpha, \quad T_1 \rightarrow \infty \quad (2.56)$$

El parámetro γ tiene un impacto crítico sobre la eficiencia de ACI. Zaffran (2024) demuestra que en el caso intercambiable, la longitud esperada del intervalo crece linealmente con γ , mientras que en series con dependencia temporal de tipo AR(1), existe un $\gamma^* > 0$ que minimiza la longitud esperada. Este resultado ilustra el compromiso fundamental de ACI: un γ pequeño produce intervalos eficientes cuando los datos son casi intercambiables, pero pierde cobertura cuando la dependencia temporal es fuerte; un γ grande garantiza cobertura incluso bajo alta dependencia, pero a costa de generar intervalos ocasionalmente infinitos.

2.6.4. ACI con Agregación de Expertos Online (AgACI)

La sensibilidad de ACI a la elección de γ motivó el desarrollo de *AgACI* (*Aggregated ACI*), un método libre de parámetros introducido por Zaffran et al. en [19] que evita la selección de γ mediante agregación de expertos *online*.

AgACI ejecuta en paralelo K instancias de ACI con una grilla de valores $\{\gamma_k\}_{k=1}^K$ y agrega sus predicciones de cotas superior e inferior de manera independiente mediante una regla de agregación online Φ . En cada instante t , los pesos $\omega_{t,k}^{(\cdot)}$ asignados al experto k para la cota superior o inferior se actualizan en función del historial de pérdidas acumuladas:

$$\omega_{t,k}^{(\cdot)} = \Phi\left(\left\{\rho_{\beta^{(\cdot)}}\left(y_s, \hat{b}_{s,k}^{(\cdot)}(x_s)\right), s \in \{T_0 + 1, \dots, t\}, k' \in \{1, \dots, K\}\right\}\right) \quad (2.57)$$

donde $\rho_{\beta}(y, \hat{b}) = (\beta - \mathbf{1}\{y < \hat{b}\})(y - \hat{b})$ es la pérdida *pinball* con parámetro $\beta^{(\ell)} = \alpha/2$ para la cota inferior y $\beta^{(u)} = 1 - \alpha/2$ para la cota superior. La cota agregada en el instante $t + 1$ es la media ponderada de los K expertos:

$$\tilde{b}_{t+1}^{(\cdot)}(x) = \frac{\sum_{k=1}^K \omega_{t,k}^{(\cdot)} \hat{b}_{t+1,k}^{(\cdot)}(x)}{\sum_{k=1}^K \omega_{t,k}^{(\cdot)}} \quad (2.58)$$

La regla de agregación Φ adoptada es BOA (*Bernstein Online Aggregation*, Wintenberger (2017)), que ha mostrado buen desempeño en datos financieros y series de precios de energía [19]. La pérdida pinball penaliza fuertemente los intervalos infinitos o muy anchos, lo que garantiza que AgACI no degrade la eficiencia al agregar expertos con γ grandes.

La diferencia entre la variante **online** y la variante **offline** de ACP (ACI y AgACI) utilizada en este trabajo radica en el reajuste del modelo subyacente $\hat{\mu}_t$. En la variante online, el modelo de predicción se reajusta en cada instante t sobre la ventana más reciente de T_0 observaciones, lo que permite adaptarse a cambios de distribución pero implica un costo computacional proporcional al número de pasos de predicción. En la variante offline, el modelo se ajusta una única vez sobre el conjunto de entrenamiento original y los scores de calibración se actualizan secuencialmente sin reentrenar, reduciendo el costo computacional a expensas de una menor adaptabilidad ante cambios estructurales. En el contexto del SEN, donde los costos marginales pueden experimentar cambios de régimen graduales asociados a la incorporación de renovables, la comparación entre ambas variantes es de interés directo.

2.6.5. Métricas de evaluación de los intervalos de predicción

Para comparar las cuatro variantes de CP se utilizan dos métricas complementarias. La primera es la *cobertura empírica*, que mide la proporción de instantes del conjunto de prueba en que el valor real cae dentro del intervalo predicho:

$$\widehat{\text{Cov}} = \frac{1}{T_1} \sum_{t=T_0+1}^{T_0+T_1} \mathbf{1}\{y_t \in C_t(x_t)\} \quad (2.59)$$

Un método válido satisface $\widehat{\text{Cov}} \geq 1 - \alpha$ empíricamente. La segunda métrica es la *longitud media del intervalo*:

$$\bar{L} = \frac{1}{T_1} \sum_{t=T_0+1}^{T_0+T_1} |C_t(x_t)| \quad (2.60)$$

donde $|C_t(x_t)|$ denota la longitud del intervalo en el instante t . Un método eficiente minimiza $\bar{L}$ sujeto a que $\widehat{\text{Cov}} \geq 1 - \alpha$. La evaluación conjunta de cobertura y longitud media es el criterio estándar adoptado en Zaffran (2024) y permite identificar qué variante de CP ofrece el mejor equilibrio entre validez y eficiencia para la distribución específica de los costos marginales del SEN.

Capítulo 3

Metodología

3.1. Datos

3.1.1. Fuente y descripción

Los datos utilizados en este trabajo provienen del portal del Coordinador Eléctrico Nacional (CEN) de Chile. La variable objetivo es el costo marginal horario en ocho barras de 220 kV del sistema, cubriendo el período comprendido entre enero de 2020 y abril de 2026, lo que representa aproximadamente 55.000 observaciones por barra. Las ocho barras consideradas son Atacama, Cardones, Charrúa, Crucero, Pan de Azúcar, Puerto Montt, Quillota y Tarapacá, seleccionadas por su representatividad geográfica a lo largo del sistema: las barras del norte, Atacama, Cardones, Crucero, Pan de Azúcar y Tarapacá, concentran la generación solar del desierto de Atacama y la región de Antofagasta, y la generación eólica de la región de Coquimbo; la barra de Quillota, cercana a Valparaíso, refleja la demanda industrial y residencial de la zona central, y las barras del sur, Charrúa y Puerto Montt, captura la dinámica de la generación hidroeléctrica de la zona centro-sur y sur del sistema. Esta distribución geográfica introduce heterogeneidad estructural entre barras, especialmente en episodios de congestión de transmisión donde los precios se desacoplan, lo que justifica la decisión de entrenar modelos independientes por barra descrita en la Sección 2.1.

El período 2020–2026 es especialmente relevante para el problema de forecasting porque concentra dos fenómenos estructurales de alto impacto en el SEN: la aceleración de la penetración de energías renovables no convencionales, que llevó la participación ERNC del 20 % al 40 % de la generación total, y los episodios de sobreoferta solar que generaron curtailments récord a partir de 2023. Ambos fenómenos introducen cambios estructurales graduales en la distribución del costo marginal que constituyen el principal desafío metodológico del problema.

3.1.2. Estadísticas descriptivas y análisis exploratorio

La Figura 3.1 presenta las series de costo marginal horario para las ocho barras durante el período de estudio.

Las series exhiben tres características estructurales relevantes. En primer lugar, presentan estacionalidad múltiple visible sobretudo a escala diaria y semanal, con un ciclo diario marcado por la caída del costo marginal durante el bloque solar y el alza en horas de menor radiación. En segundo lugar, se observan spikes de alta magnitud asociados a eventos de escasez hídrica, fallas de generación o congestiones de transmisión. En tercer lugar, se aprecia una tendencia decreciente en el nivel base del costo marginal a partir de 2022 en las barras del norte, consistente con la incorporación masiva de capacidad solar en esa zona del sistema.

La Tabla 3.1 resume las estadísticas descriptivas de cada barra. La heterogeneidad entre barras es marcada. Puerto Montt presenta la media más alta con 100.11 USD/MWh y la mayor desviación estándar con 94.05 USD/MWh, muy superior al resto de las barras, lo que refleja la influencia de la generación hidroeléctrica y su mayor variabilidad estacional asociada a los ciclos de precipitaciones. Las barras del norte, en cambio, presentan medias más bajas y medianas en el rango de \$54 a \$57 USD/MWh, coherente con la abundante generación solar que presiona el costo marginal hacia abajo durante el bloque diurno. El mínimo de 0.0 USD/MWh es común a todas las barras y corresponde a episodios de sobreoferta renovable donde el costo marginal colapsa. El caso más notable es la barra Pan de Azúcar, que registra un máximo de 1588.95 USD/MWh, considerablemente superior al máximo de 576.82 USD/MWh compartido por las demás barras, lo que refleja un evento extremo de congestión o escasez ocurrido cerca del año 2020, visible en la Figura 3.1. Este spike de magnitud excepcional constituye precisamente el tipo de evento que motiva el uso de DyT en la arquitectura TFT, por su capacidad de comprimir activaciones extremas de manera más robusta que LayerNorm, como se argumentó en la Sección 2.4.5.

Barra	Media	Desv. Est.	Mínimo	Mediana	Máximo
Atacama	62.30	60.20	0.0	55.14	576.82
Cardones	62.37	59.75	0.0	55.01	576.82
Charrúa	66.21	58.87	0.0	57.35	576.82
Crucero	63.23	61.79	0.0	54.36	576.82
Pan de Azúcar	63.26	60.32	0.0	56.40	1588.95
Puerto Montt	100.11	94.05	0.0	67.14	576.82
Quillota	66.74	58.79	0.0	59.09	576.82
Tarapacá	65.28	64.08	0.0	56.03	576.82

Tabla 3.1: Estadísticas descriptivas del costo marginal horario para las ocho barras del SEN, período 2020–2026.




Figura 3.1: Evolución del costo marginal horario para las ocho barras del SEN, período 2020–2026. Zoom en el período del 15/05/2024 - 30/05/2024

3.1.3. Análisis de estacionariedad

Para caracterizar formalmente las propiedades estadísticas de cada serie se aplican conjuntamente las pruebas ADF y KPSS descritas en la Sección 2.1.3. Los resultados se presentan en la Tabla 3.2.

Barra	Est. ADF	p -valor ADF	Est. KPSS	p -valor KPSS
Atacama	-13.2000	$< 0,001$	8.1252	$< 0,01$
Cardones	-12.4464	$< 0,001$	8.1567	$< 0,01$
Charrúa	-12.7728	$< 0,001$	8.4554	$< 0,01$
Crucero	-12.6482	$< 0,001$	4.5352	$< 0,01$
Pan de Azúcar	-12.6063	$< 0,001$	7.2476	$< 0,01$
Puerto Montt	-11.6217	$< 0,001$	4.8858	$< 0,01$
Quillota	-12.7277	$< 0,001$	4.5890	$< 0,01$
Tarapacá	-12.8396	$< 0,001$	8.2951	$< 0,01$

Tabla 3.2: Resultados de las pruebas de estacionariedad ADF y KPSS para las ocho barras.

El patrón es consistente en todas las barras: la prueba ADF rechaza la hipótesis nula de raíz unitaria con $p < 0,001$, mientras que la prueba KPSS rechaza la hipótesis nula de estacionariedad con $p < 0,01$, reportado en su valor límite inferior dado que los estadísticos superan ampliamente los umbrales críticos de la librería. Este resultado aparentemente contradictorio es característico de las series de costos marginales eléctricos y tiene una interpretación directa: las series no son paseos aleatorios puros, lo que implica reversión a la media en el largo plazo, pero tampoco son estacionarias en sentido débil debido a la presencia simultánea de heterocedasticidad asociada a los spikes de alta magnitud y de cambios estructurales graduales en el nivel base del costo marginal producto de la incorporación continua de capacidad renovable. En conjunto, ambas pruebas caracterizan las series como procesos estacionarios en media pero no en varianza, con cambios estructurales de largo plazo. Esta caracterización justifica directamente dos decisiones metodológicas adoptadas en este trabajo: el uso de estandarización z-score como transformación de preprocesamiento, que estabiliza la escala de la serie, y el uso de Prophet con detección automática de puntos de quiebre, que modela explícitamente los cambios estructurales graduales en la tendencia.

3.2. Preprocesamiento

El preprocesamiento de los datos se realiza en dos etapas diferenciadas según el modelo destino, dado que Prophet y el TFT tienen requisitos distintos respecto a la escala de los datos.

3.2.1. Limpieza y tratamiento de valores atípicos

En primer lugar se verifica la integridad de la serie temporal. Los datos del CEN no presentan valores faltantes en el período estudiado; no obstante, el pipeline contempla interpolación lineal como mecanismo de contingencia ante eventuales ausencias puntuales, preservando así la continuidad temporal de la serie sin introducir sesgos hacia valores futuros.

En segundo lugar se tratan los outliers. Dado que las series de costo marginal presentan spikes de alta magnitud asociados a eventos excepcionales, se aplica un umbral de 4 desviaciones estándar calculadas sobre el conjunto de entrenamiento: las observaciones que superan $\hat{\mu} + 4\hat{\sigma}$ se reemplazan mediante interpolación lineal entre los valores adyacentes. Este umbral es suficientemente amplio para preservar los spikes estructurales del mercado, como los episodios de escasez hídrica o congestión de transmisión, que son parte de la dinámica real del sistema y deben ser aprendidos por el modelo, mientras elimina únicamente los valores de magnitud excepcional que podrían distorsionar el entrenamiento, como el spike de 1.588,95 USD/MWh registrado en la barra Pan de Azúcar. El umbral se estima exclusivamente sobre el conjunto de entrenamiento y se aplica sin reestimación al resto de los conjuntos, evitando data leakage.

3.2.2. División temporal de los datos

Los datos se dividen en tres conjuntos cronológicamente ordenados, respetando estrictamente la causalidad temporal: ningún conjunto contiene observaciones posteriores a las del conjunto siguiente. La división adoptada es 70 % entrenamiento, 15 % validación y 15 % test, que corresponde a los siguientes períodos:

Conjunto	Inicio	Término	Proporción
Entrenamiento	2020-01-01 01:00	2024-06-01 12:00	70 %
Validación	2024-06-01 13:00	2025-05-13 06:00	15 %
Test	2025-05-13 07:00	2026-04-24 00:00	15 %

Tabla 3.3: División temporal de los datos por conjunto.

El conjunto de entrenamiento cubre el período 2020–2024, que incluye la transición energética acelerada y los episodios de sobreoferta solar de los primeros años. El conjunto de validación, comprendido entre junio de 2024 y mayo de 2025, se utiliza para la optimización de hiperparámetros de Prophet, la selección del mejor ensamble en el Stacking Optimization y el ajuste de los pesos de combinación. El conjunto de prueba, de mayo de 2025 a abril de 2026, se reserva exclusivamente para la evaluación final del modelo y la construcción de los intervalos de Conformal Prediction, y no es accedido en ninguna etapa del entrenamiento ni de la selección de modelos.

3.2.3. Normalización

La normalización se aplica de manera diferenciada según el modelo. Prophet opera directamente sobre los valores originales del costo marginal en USD/MWh, dado que su formulación aditiva es interpretable en la escala original y sus componentes de tendencia y estacionalidad tienen significado físico directo en esa escala.

Para el TFT, en cambio, se aplica estandarización z-score independientemente para cada barra:

$$\tilde{y}_t^{(b)} = \frac{y_t^{(b)} - \hat{\mu}^{(b)}}{\hat{\sigma}^{(b)}} \quad (3.1)$$

donde $\hat{\mu}^{(b)}$ y $\hat{\sigma}^{(b)}$ son la media y desviación estándar estimadas exclusivamente sobre el conjunto de entrenamiento de la barra b . La normalización independiente por barra es necesaria porque las series presentan niveles y variabilidades distintas, como se evidencia en la Tabla 3.1, donde Puerto Montt tiene una media de 100.11 USD/MWh frente a las barras del norte con medias en torno a 62–66 USD/MWh. Aplicar una normalización conjunta introduciría un sesgo sistemático en las barras con niveles más extremos. Los parámetros $\hat{\mu}^{(b)}$ y $\hat{\sigma}^{(b)}$ se aplican sin reestimación a los conjuntos de validación y prueba, preservando la integridad de la evaluación fuera de muestra.

3.3. Modelo Prophet

3.3.1. Configuración y optimización de hiperparámetros

Prophet se entrena sobre los valores originales del costo marginal en USD/MWh, sin transformación previa, dado que su formulación aditiva es interpretable en la escala original y sus componentes de tendencia y estacionalidad tienen significado físico directo en esa escala. Se incorporan los feriados nacionales del calendario chileno como variable exógena mediante el argumento `holidays`, capturando el efecto sistemático de los días festivos sobre el despacho del SEN descrito en la Sección 2.2.3. Las estacionalidades diaria, semanal y anual se activan explícitamente. El tipo de tendencia se fija como lineal por tramos (`growth='linear'`), adecuado para series de precios que no tienen una capacidad de saturación definida. Además, esta decisión de diseño está motivada por las dificultades prácticas en la implementación del modo multiplicativo: Prophet requiere la especificación explícita de valores de techo y piso para ese modo, parámetros que no tienen una interpretación directa en series de costos marginales sin capacidad de saturación definida, y el entrenamiento con modo multiplicativo presentó tiempos de cómputo significativamente mayores sin mejoras observables en validación preliminar. La búsqueda se realiza mediante grid search minimizando el MAE sobre el conjunto de validación, preservando la causalidad temporal.

Los hiperparámetros optimizados son `changepoint_prior_scale` (CPS), que controla la flexibilidad de la tendencia lineal por tramos, y `seasonality_prior_scale` (SPS), que

controla la flexibilidad de las componentes estacionales, ambos descritos en la Sección 2.2. La búsqueda se realiza mediante grid search minimizando el MAE sobre el conjunto de validación, preservando la causalidad temporal. La Tabla 3.4 presenta los hiperparámetros óptimos encontrados para cada barra.

Barra	CPS	SPS	MAE val.
Atacama	0.02	0.2	21.54
Cardones	0.05	5.0	21.89
Charrúa	0.02	0.01	24.30
Crucero	0.05	0.007	22.25
Pan de Azúcar	0.05	0.007	22.66
Puerto Montt	0.05	0.01	46.01
Quillota	0.02	1.0	23.77
Tarapacá	0.05	0.01	23.09

Tabla 3.4: Hiperparámetros óptimos de Prophet por barra. MAE en conjunto de validación (USD/MWh).

Dos patrones emergen de los resultados. Primero, los valores de CPS son bajos en todas las barras (0.02–0.05), indicando que Prophet prefiere tendencias suaves con pocos cambios abruptos, consistente con los cambios estructurales graduales del mercado descritos en la Sección 3.1. Segundo, los valores de SPS son notablemente bajos en la mayoría de las barras (0.007–0.01), lo que indica que con datos horarios Prophet prefiere estacionalidades rígidas, posiblemente porque la alta densidad temporal de las observaciones ya provee suficiente información para estimar los patrones estacionales sin necesidad de flexibilidad adicional. Las excepciones son Cardones (SPS=5.0) y Quillota (SPS=1.0), cuyas estacionalidades requieren mayor adaptabilidad, y Atacama (SPS=0.2), que ocupa una posición intermedia.

3.3.2. Componente de tendencia

La Figura 3.2 presenta la componente de tendencia estimada por Prophet para las ocho barras durante el período 2020–2026.

La tendencia estimada revela un patrón estructural común a todas las barras: una fase de alza sostenida entre 2020 y 2022–2023, seguida de una caída pronunciada que se estabiliza en niveles significativamente inferiores a partir de 2024. Este comportamiento es consistente con la dinámica del mercado eléctrico chileno descrita en la Sección 3.1: el alza corresponde al período de recuperación post-pandemia y alta demanda, mientras que la caída refleja la incorporación masiva de capacidad solar y eólica que presiona el costo marginal a la baja. Puerto Montt presenta una tendencia cualitativamente distinta al resto, con niveles significativamente más altos, en torno a 200 USD/MWh en el peak de 2022–2023, y una caída más abrupta, lo que refleja la influencia de los ciclos hidrológicos en la generación hidroeléctrica del sur.




Figura 3.2: Componente de tendencia estimada por Prophet para las ocho barras del SEN, período 2020–2026.

3.3.3. Componente de estacionalidad anual

La Figura 3.3 presenta la componente de estacionalidad anual estimada por Prophet para las ocho barras.




Figura 3.3: Componente de estacionalidad anual estimada por Prophet para las ocho barras del SEN.

La componente anual revela patrones diferenciados entre zonas del sistema. Las barras del norte presentan una amplitud moderada de ± 20 – 30 USD/MWh, con un ciclo que refleja la variación estacional de la radiación solar. Puerto Montt, en cambio, exhibe la mayor amplitud de todas las barras, alcanzando ± 60 USD/MWh, asociada a los ciclos de deshielo y precipitaciones que determinan la disponibilidad del recurso hídrico para la generación

hidroeléctrica del sur.

3.3.4. Predicciones a 48 horas

La Figura 3.4 ilustra las predicciones de Prophet para un horizonte de 48 horas a partir del último instante del conjunto de prueba, mostrando el histórico reciente y la proyección para cada barra.

Las predicciones a 48 horas confirman que Prophet captura correctamente la estructura del ciclo diario, reproduciendo la caída característica durante el bloque solar y el alza en horas de menor generación renovable. Sin embargo, se observa que en algunas barras la predicción alcanza valores negativos, lo que constituye una limitación física del modelo: el costo marginal no puede ser negativo en el SEN, pero Prophet, al ser un modelo de descomposición aditiva sin restricciones de dominio, puede extrapolar fuera del rango físicamente válido cuando la componente estacional supera a la tendencia. Esta limitación es inherente a la formulación de Prophet y refuerza la necesidad del TFT como componente complementario, cuya arquitectura de red neuronal le permite aprender implícitamente los límites del rango observado.

3.4. Temporal Fusion Transformer

3.4.1. Construcción de features y dataloaders

El TFT recibe los datos estandarizados, según la transformación descrita en la Sección 3.2, y un conjunto de features construidas a partir de las componentes de Prophet y de la historia reciente de la serie. Las features se organizan en tres grupos según la taxonomía del TFT descrita en la Sección 2.3.4.

Las *covariantes estáticas* incluyen el identificador de barra (`serie_id`), que permite al modelo aprender dinámicas temporales distintas para cada nodo del sistema sin necesidad de entrenar instancias separadas, tal como se describió en la Sección 2.3.4.

Las *covariantes temporales conocidas* (`known_reals`) incluyen las cuatro componentes descompuestas por Prophet: tendencia (`trend`), estacionalidad anual (`yearly`), estacionalidad semanal (`weekly`) y estacionalidad diaria (`daily`), más un indicador binario de feriado nacional (`is_holiday`). Estas covariantes son conocidas para cualquier horizonte futuro dado que Prophet puede generarlas para cualquier instante temporal y el calendario de feriados es fijo, lo que las hace aptas para ser usadas tanto en el encoder como en el decoder del TFT.

Las *covariantes temporales desconocidas* (`unknown_reals`) difieren según el modelo. Para el TFT de precios se incluyen la serie estandarizada (`y_real`), los lags de 1, 24 y 168 horas (`y_lag1`, `y_lag24`, `y_lag168`), la media móvil de 24 y 168 horas (`rolling_mean_24`, `rolling_mean_168`) y la desviación estándar móvil de 24 y 168 horas (`rolling_std_24`, `rolling_std_168`), y cinco variables climáticas horarias. Para el TFT de residuos se uti-




Figura 3.4: Predicciones de Prophet a 48 horas para las ocho barras del SEN, mostrando el histórico reciente (azul) y la proyección (rojo). Se aprecia el ciclo diario capturado por el modelo, con la caída característica durante el bloque solar y el alza en horas nocturnas.

lizan las mismas features pero calculadas sobre el residuo de Prophet en lugar de la serie original. La elección de lags de 1, 24 y 168 horas captura tanto la dependencia inmediata como el patrón diario y semanal del costo marginal, mientras que las estadísticas móviles de 24 y 168 horas proveen información sobre el nivel y la volatilidad reciente de la serie.

Las variables climáticas corresponden a temperatura a 2 metros (`temperatura`), humedad relativa (`humedad`), velocidad del viento a 10 metros (`velocidad_viento`), precipitación (`precipitacion`) y nubosidad (`nubosidad`), obtenidas con resolución horaria desde la API de archivo de Open-Meteo (`archive-api.open-meteo.com`), que provee datos de reanálisis ERA5 del Centro Europeo de Predicción Meteorológica a Medio Plazo (ECMWF). Los datos se obtienen para las coordenadas geográficas de la ciudad más representativa de cada barra: Iquique para Tarapacá, Antofagasta para Crucero, Copiapó para Cardones, Vallenar para Atacama, La Serena para Pan de Azúcar, Valparaíso para Quillota, Concepción para Charrúa y Puerto Montt para la barra homónima.

La ventana de contexto se fija en $L = 168$ horas, equivalente a una semana completa, lo que permite al TFT acceder a un ciclo semanal completo de historia al realizar cada predicción. El horizonte de predicción es $h = 1$ hora, consistente con el objetivo de forecasting definido en la Sección 2.1.4. Para cada instante de predicción, el encoder mínimo se fija en $L/2 = 84$ horas para garantizar que todas las ventanas de entrenamiento tengan contexto suficiente. PyTorch Forecasting agrega automáticamente el índice de tiempo relativo (`add_relative_time_idx`) y las escalas del target (`add_target_scales`) como features adicionales. Una ventana de contexto de dos semanas ($L = 336$ horas) y de 10 días ($L = 240$ horas) fue evaluada preliminarmente, pero descartada por exceder los recursos de memoria disponibles en el clúster de cómputo utilizado, por lo que $L = 168$ horas constituye el máximo viable bajo las restricciones computacionales del trabajo.

Los dataloaders se construyen de manera que el conjunto de validación incluye el período de entrenamiento más el de validación, y el conjunto de prueba incluye los tres períodos concatenados, preservando la continuidad del índice temporal (`time_idx`) en todo momento. Se verifica explícitamente que el índice sea monótonamente creciente en cada conjunto para garantizar la causalidad temporal.

3.4.2. Arquitectura y entrenamiento

Los hiperparámetros del TFT se presentan en la Tabla 3.5. Se entrenan dos instancias del TFT con la misma configuración: una sobre la serie estandarizada de precios ($\text{TFT}_{\text{LN}} \text{ precios}$) y otra sobre los residuos de Prophet ($\text{TFT}_{\text{LN}} \text{ residuos}$).

El modelo se optimiza mediante Adam con tasa de aprendizaje inicial de 0.001, reducida automáticamente por un factor cuando la pérdida de validación no mejora durante 5 épocas consecutivas (`ReduceLROnPlateau`). El entrenamiento se detiene anticipadamente si la pérdida de validación no mejora en más de 10^{-4} durante 15 épocas consecutivas. El gradiente se recorta a 0.1 para estabilizar el entrenamiento en presencia de los spikes del costo marginal. El tiempo de entrenamiento de cada modelo por barra es de aproximadamente 12 horas en un PC de trabajo y aproximadamente 3:30 horas en el cluster del NLHPC.

Hiperparámetro	Valor
Learning rate inicial	0.001
Hidden size	32
Attention heads	4
Dropout	0.2
Hidden continuous size	8
Función de pérdida	Quantil Loss
Cuantiles	[0,02, 0,1, 0,25, 0,5, 0,75, 0,9, 0,98]
Épocas máximas	100
Early stopping patience	15 épocas
Reduce LR on plateau patience	5 épocas
Gradient clipping	0.1
Ventana de contexto L	168 horas
Horizonte h	1 hora

Tabla 3.5: Hiperparámetros del TFT con LayerNorm.

3.4.3. Curvas de aprendizaje

La Figura 3.5 presenta las curvas de aprendizaje para las barras Atacama, Cardones y Charrúa, mostrando la pérdida cuantílica en los conjuntos de entrenamiento y validación para ambos modelos.

Las curvas muestran convergencia estable en todas las barras sin señales de sobreajuste severo. La pérdida de validación del modelo de precios converge en torno a 0.068–0.073, mientras que la del modelo de residuos se estabiliza alrededor de 0.101–0.104, lo que es esperable dado que los residuos de Prophet son intrínsecamente más difíciles de predecir que la serie original al haber eliminado la estructura sistemática de largo plazo. Ambos modelos alcanzan su mejor desempeño en épocas avanzadas del entrenamiento, cercanas a las épocas 95–99, lo que indica que el límite de 100 épocas es adecuado y que el early stopping no se activa prematuramente.

3.5. Stacking Optimization

3.5.1. Estrategias de ensamblaje

El Stacking Optimization combina las predicciones de Prophet y las dos instancias del TFT mediante una combinación lineal convexa con pesos aprendidos sobre el conjunto de validación, siguiendo el marco descrito en la Sección 2.5. Se evalúan seis estrategias de ensamblaje que cubren desde los modelos base individuales hasta combinaciones progresivamente más complejas:

1. **Prophet solo:** predicción directa de Prophet sin combinación.




Figura 3.5: Curvas de aprendizaje del TFT con LayerNorm. Se muestran la pérdida cuantílica de entrenamiento y validación para los modelos de precios y residuos. Las líneas verticales indican la época de mejor desempeño en validación.

2. **TFT_{LN} precios solo:** predicción directa del TFT entrenado sobre la serie de precios.
3. **Prophet + TFT_{LN} precios:** combinación convexa $\hat{y} = w_1 \hat{y}^{\text{Prophet}} + w_2 \hat{y}^{\text{TFT}_P}$.
4. **Prophet + TFT_{LN} residuos (D):** suma directa $\hat{y} = \hat{y}^{\text{Prophet}} + \hat{r}^{\text{TFT}_R}$ con pesos fijos $w_1 = w_2 = 1$.
5. **Prophet + TFT_{LN} residuos (Opt):** combinación convexa $\hat{y} = w_1 \hat{y}^{\text{Prophet}} + w_2 \hat{r}^{\text{TFT}_R}$ con pesos optimizados.
6. **(Prophet + residuos) + TFT_{LN} precios (opt):** combinación convexa entre la predicción híbrida Prophet-residuos con suma directa y el TFT_{LN} de precios, $\hat{y} = w_1(\hat{y}^{\text{Prophet}} + \hat{r}^{\text{TFT}_R}) + w_2 \hat{y}^{\text{TFT}_P}$, con pesos optimizados.

En todas las estrategias con optimización de pesos se impone la restricción de combinación convexa $w_1 + w_2 = 1$ con $w_1, w_2 \geq 0$, de modo que los pesos son interpretables como cuotas de participación de cada componente. Los pesos se estiman minimizando el MAE sobre el conjunto de validación y se aplican sin reestimación al conjunto de prueba.

3.5.2. Métodos de optimización de pesos

Para las estrategias que requieren optimización de pesos se comparan nueve métodos: búsqueda en grilla con resoluciones de 21, 41 y 101 puntos (*Grid_21*, *Grid_41*, *Grid_101*), Nelder-Mead, SLSQP, L-BFGS-B, Evolución Diferencial, Regresión Ridge con $\alpha = 0,01$ y búsqueda aleatoria con 1.000 iteraciones (*Random_1000*). Todos los métodos optimizan sobre el conjunto de validación y los pesos resultantes se evalúan en prueba sin reajuste.

La búsqueda en grilla explora el espacio $w_1 \in [0, 1]$ de manera uniforme con la resolución indicada, siendo el método más simple y transparente. Los métodos basados en `scipy.optimize.minimize` (Nelder-Mead, SLSQP, L-BFGS-B) y Evolución Diferencial aplican optimización numérica directa sobre la función objetivo MAE. La Regresión Ridge estima los pesos mediante regresión lineal regularizada con restricción de positividad, normalizando los coeficientes para satisfacer la restricción de suma unitaria. La búsqueda aleatoria muestrea uniformemente el espacio de pesos y selecciona el de menor MAE.

3.6. TFT con Dynamic Tanh

El TFT_{DyT} es una variante del TFT con LayerNorm descrito en la Sección 3.4 en la que todas las capas LayerNorm de la arquitectura son reemplazadas por capas Dynamic Tanh (DyT), siguiendo la sustitución uniforme descrita en la Sección 2.4.5. La configuración de features, dataloaders, hiperparámetros y protocolo de entrenamiento es idéntica a la del TFT_{LN}, con la única diferencia en el mecanismo de normalización. El parámetro α de cada capa DyT se inicializa en $\alpha_0 = 0,5$ con $\gamma = \mathbf{1}$ y $\beta = \mathbf{0}$, siguiendo la recomendación de Zhu et al. (2025) para modelos no-LLM descrita en la Sección 2.4.3.

3.6.1. Curvas de aprendizaje

La Figura 3.6 presenta las curvas de aprendizaje del TFT_{DyT} para las barras Atacama, Cardones y Charrúa.

Las curvas muestran un comportamiento cualitativamente distinto al del TFT_{LN} en las primeras épocas: la pérdida inicial es mayor, en torno a 0.35, frente a 0.275 del modelo con LayerNorm, lo que refleja que DyT requiere más iteraciones para calibrar el parámetro α hacia su valor de equilibrio $1/\sigma$, tal como se discutió en la Sección 2.4.3. Sin embargo, ambos modelos convergen a valores de pérdida de validación comparables al final del entrenamiento, con el modelo de precios estabilizándose en torno a 0.075–0.085 y el de residuos alrededor de 0.100–0.115, confirmando empíricamente la observación de Zhu et al. (2025) de que DyT iguala el rendimiento de LayerNorm sin ajuste adicional de hiperparámetros. Al igual que con TFT_{LN} , ambos modelos alcanzan su mejor desempeño en épocas avanzadas, cercanas a las épocas 97–99, sin activación prematura del early stopping.

3.6.2. Análisis del parámetro α aprendido

La Figura 3.7 presenta los valores del parámetro α aprendido por cada capa DyT del TFT_{DyT} , agrupados por módulo de la arquitectura. La línea roja punteada indica el valor de inicialización $\alpha_0 = 0,5$.

El resultado central de este análisis es que los valores de α se dispersaron significativamente desde el valor de inicialización $\alpha_0 = 0,5$, cubriendo un rango de 0,10 a 1,57 al final del entrenamiento. Esto confirma que DyT efectivamente aprendió a normalizar de manera adaptativa durante el entrenamiento, en lugar de mantener una compresión fija, tal como predice la teoría de Zhu et al. (2025). Los módulos de selección de variables, Encoder VSN, Decoder VSN y Static VSN, presentan mayor dispersión entre capas que los módulos de más alto nivel como Feed-Forward y Post-LSTM, lo que refleja la heterogeneidad entre las features procesadas en cada módulo.

3.7. Conformal Prediction

La Predicción Conforme se aplica sobre las predicciones puntuales producidas por el Stacking Optimization de las Secciones 3.5 y 3.6, con el objetivo de construir intervalos de cobertura garantizada para cada barra y arquitectura. En esta sección se describe la configuración del esquema de calibración y las cuatro variantes implementadas; los resultados se presentan en el Capítulo 4.




Figura 3.6: Curvas de aprendizaje del TFT con DyT para las barras Atacama, Cardones y Charrúa. Se muestran la pérdida cuantílica de entrenamiento y validación para los modelos de precios y residuos. Las líneas verticales indican la época de mejor desempeño en validación.




Figura 3.7: Valores del parámetro α aprendido por las capas DyT del TFT_{DyT} para la barra Atacama, agrupados por módulo de la arquitectura. Las barras muestran la media por módulo, las líneas de error la desviación estándar, y los marcadores rojos el mínimo y máximo. La línea roja punteada indica el valor de inicialización $\alpha_0 = 0,5$.

3.7.1. Configuración general

Todas las variantes se evalúan con nivel de cobertura nominal $1 - \alpha = 0,95$ y operan sobre la escala original de los costos marginales en USD/MWh. El conjunto de calibración es el conjunto de validación descrito en la Tabla 3.3, que cubre el período junio 2024–mayo 2025 con $n_{\text{cal}} = 8\,245$ observaciones por barra; el conjunto de evaluación es el conjunto de prueba, con $n_{\text{test}} = 8\,301$ observaciones horarias por barra, cubriendo mayo 2025–abril 2026.

Los *scores* de no conformidad utilizados en todas las variantes son los residuos absolutos del modelo de predicción puntual:

$$s_t = |y_t - \hat{y}_t|, \quad (3.2)$$

donde $\hat{y}_t$ es la predicción de la mejor estrategia de Stacking Optimization para la barra correspondiente. Los intervalos resultantes son simétricos alrededor de $\hat{y}_t$:

$$C_t = [\hat{y}_t - q_t, \hat{y}_t + q_t], \quad (3.3)$$

donde q_t es el cuantil adaptado por cada método en el instante t . Las métricas de evaluación son la cobertura empírica (*Coverage*), el ancho medio del intervalo (*Width*) y el MAE de la predicción puntual subyacente.

Para las variantes que requieren un modelo de *meta-aprendizaje* (EnbPI, ACI *offline* y ACI *online*), se entrena una Regresión Ridge con $\alpha_{\text{Ridge}} = 1,0$ usando como *features* las predicciones de los cinco modelos base del ensamble: Prophet solo, TFT precios solo, Prophet + TFT precios, TFT residuos solo y Prophet + residuos optimizado. Esto permite que el cuantil de calibración se ajuste a la distribución de errores del ensamble completo en lugar de depender únicamente de la mejor estrategia individual.

Cabe señalar una limitación metodológica del esquema de calibración adoptado. El conjunto de validación cumple un doble rol: primero, sirve para seleccionar la mejor estrategia de Stacking Optimization mediante comparación de MAE entre estrategias (Sección 3.5); segundo, se utiliza como conjunto de calibración para estimar el cuantil de no conformidad. Dado que la selección se realizó minimizando los residuos absolutos sobre ese mismo conjunto, el modelo elegido es aquel cuyos residuos en validación son más pequeños de entre todas las estrategias candidatas, lo que puede producir un cuantil q ligeramente subestimado respecto al que se obtendría sobre datos completamente independientes. La solución ideal sería un tercer conjunto dedicado exclusivamente a calibración, pero con datos de series de tiempo esto reduce el tamaño de calibración disponible. Con $n_{\text{cal}} = 8\,245$ observaciones el sesgo es probablemente pequeño dado el tamaño del conjunto, y se reporta como limitación del diseño experimental.

3.7.2. Split CP clásico

El Split CP clásico, descrito en la Sección 2.6.1, calcula un cuantil fijo q a partir del conjunto de calibración y lo aplica sin cambios a todo el período de prueba. Formalmente, dados los *scores* de calibración $\{s_i\}_{i=1}^{n_{\text{cal}}}$ definidos en (3.2), el cuantil se obtiene como

$$q = \hat{Q}_{1-\alpha}(\{s_i\}_{i=1}^{n_{\text{cal}}}), \quad \text{con nivel ajustado } \frac{\lceil (1-\alpha)(n_{\text{cal}}+1) \rceil}{n_{\text{cal}}+1}, \quad (3.4)$$

garantizando cobertura marginal finita cuando las observaciones son intercambiables (Vovk et al., 2005).

3.7.3. EnbPI V2

El *Ensemble Bootstrap Prediction Interval* V2 (EnbPI, Xu y Xie, 2021), descrito en la Sección 2.6.2, extiende el Split CP incorporando *bootstrap* sobre el conjunto de validación y actualización en línea de los *scores* de residuos a medida que avanza el período de prueba. En lugar de un cuantil global fijo, EnbPI mantiene una ventana deslizante de residuos pasados que se actualiza en cada paso con el error observado, permitiendo que el ancho del intervalo se adapte a cambios en la volatilidad de la serie. La implementación utiliza el modelo de Regresión Ridge descrito en la Sección 3.7.1 como modelo base del ensamble y $B = 30$ réplicas *bootstrap* con *stride* 1.

3.7.4. ACI *offline*

La *Adaptive Conformal Inference* (ACI), propuesta por Gibbs y Candès (2021) y descrita en la Sección 2.6.3, adapta el nivel de cobertura efectivo α_t en cada instante según la historia de errores de cobertura. En la variante *offline*, el modelo de predicción puntual se entrena una única vez sobre el conjunto de validación y no se reajusta durante la prueba; solo el nivel de cobertura α_t evoluciona en el tiempo según la regla de actualización

$$\alpha_{t+1} = \alpha_t + \gamma(\alpha - \mathbf{1}_{\{y_t \notin C_t\}}), \quad (3.5)$$

donde $\gamma > 0$ es la velocidad de adaptación y $\alpha = 0,05$ es el nivel nominal. Se evalúan tres valores de $\gamma \in \{0,01, 0,05, 0,1\}$ para estudiar el *trade-off* entre estabilidad y velocidad de respuesta del nivel α_t .

3.7.5. ACI *online*

La variante *online* de ACI combina la actualización adaptativa del nivel α_t descrita en (3.5) con el reentrenamiento del modelo de predicción en cada instante t . A diferencia de la

variante *offline*, la variante *online* reajusta el modelo Ridge en cada paso t sobre la unión del conjunto de validación y todos los pares $(\mathbf{x}_s, y_s)_{s=1}^t$ observados en prueba hasta ese instante. Formalmente, en cada paso t :

1. Se reajusta el modelo sobre $\mathcal{D}_t = \mathcal{D}_{\text{val}} \cup \{(\mathbf{x}_s, y_s)\}_{s=1}^t$.
2. Se obtiene la predicción $\hat{y}_t = f_t(\mathbf{x}_t)$.
3. Se calculan los residuos de calibración sobre $\mathcal{D}_t$ y se obtiene q_t con nivel $1 - \alpha_t$.
4. Se construye $C_t = [\hat{y}_t - q_t, \hat{y}_t + q_t]$.
5. Se observa y_t , se calcula el error de cobertura $\mathbf{1}_{\{y_t \notin C_t\}}$ y se actualiza α_{t+1} según (3.5).

Este procedimiento maximiza la adaptación del modelo a los cambios distribucionales recientes, pero tiene un costo computacional del orden $\mathcal{O}(n_{\text{test}} \times T_{\text{train}})$, donde T_{train} es el tiempo de ajuste del modelo base. Con el modelo Ridge implementado, el tiempo total de ejecución por barra oscila entre 57 y 61 segundos.

Capítulo 4

Resultados y Análisis

Este capítulo presenta los resultados de evaluación del modelo híbrido propuesto, organizados siguiendo el orden de la arquitectura descrita en el Capítulo 3: primero los modelos base individuales (Prophet y TFT), luego el Stacking Optimization, y finalmente los intervalos de Conformal Prediction. Para cada componente se reportan las métricas en los conjuntos de validación y prueba, y se identifican los patrones transversales entre barras. Las comparativas entre arquitecturas (TFT_{LN} vs. TFT_{DyT}) y entre métodos de CP se presentan al final de cada sección correspondiente.

4.1. Modelo Prophet

4.1.1. Desempeño por barra

La Figura 4.1 presenta la comparativa entre los valores reales y las predicciones de Prophet para las ocho barras sobre el período completo de estudio.

La figura ilustra visualmente el comportamiento característico de Prophet como modelo de descomposición: captura adecuadamente la envolvente de la serie, siguiendo la tendencia de largo plazo y los ciclos estacionales, pero suaviza los spikes de alta magnitud que corresponden a eventos extremos del mercado. Este comportamiento es esperable dado que Prophet modela la estructura sistemática de la serie y no está diseñado para capturar fluctuaciones no lineales de corto plazo, rol que corresponde al TFT en la arquitectura híbrida propuesta. Puerto Montt exhibe el mayor desajuste visual, con la predicción incapaz de seguir la alta variabilidad de la serie real durante el período 2022–2023.

La Tabla 4.1 presenta los resultados numéricos de evaluación de Prophet en los conjuntos de entrenamiento, validación y prueba para las ocho barras. El MAPE no se reporta dado que las series presentan valores iguales a cero, para los cuales esta métrica no está definida.

Los resultados muestran un desempeño heterogéneo entre barras. Las barras del norte presentan los mejores indicadores, con R^2 en el conjunto de prueba entre 0.44 y 0.51, lo que




Figura 4.1: Comparativa entre valores reales (azul) y predicciones de Prophet (rojo) para las ocho barras del SEN, período 2020–2026.

Barra	Conjunto	MAE	RMSE	MSE	R ²
Atacama	Train	31.00	41.42	1715.45	0.5141
	Val	21.54	32.28	1042.33	0.5265
	Test	19.53	27.80	772.81	0.5185
Cardones	Train	30.98	41.30	1705.90	0.5226
	Val	21.89	31.15	970.43	0.5257
	Test	21.22	29.20	852.79	0.4748
Charrúa	Train	31.81	43.72	1911.15	0.4662
	Val	24.29	32.63	1064.51	0.3739
	Test	25.10	35.94	1291.43	0.3023
Crucero	Train	31.17	41.68	1737.04	0.5404
	Val	22.25	32.33	1045.24	0.5382
	Test	22.76	30.36	921.78	0.4385
Pan de Azúcar	Train	31.34	42.29	1788.21	0.5067
	Val	22.66	31.84	1013.81	0.4834
	Test	22.97	31.06	964.98	0.4202
Puerto Montt	Train	50.82	67.81	4597.88	0.5491
	Val	46.01	61.13	3736.29	0.2149
	Test	48.15	61.89	3830.46	-0.0164
Quillota	Train	31.49	43.01	1850.16	0.4794
	Val	23.77	32.64	1065.54	0.3971
	Test	23.97	35.40	1253.11	0.3333
Tarapacá	Train	31.99	42.71	1823.84	0.5461
	Val	23.09	34.21	1170.36	0.5499
	Test	22.85	31.14	969.53	0.4862

Tabla 4.1: Resultados de evaluación de Prophet por barra y conjunto. MAE y RMSE en USD/MWh, MSE en (USD/MWh)².

refleja que Prophet captura adecuadamente la estructura estacional y la tendencia decreciente asociada a la incorporación solar. Quillota y Charrúa muestran un desempeño moderado con R^2 de 0.33 y 0.30 respectivamente en prueba, sugiriendo que sus dinámicas de corto plazo son más difíciles de capturar con un modelo de descomposición aditiva. El caso más notable es Puerto Montt, que presenta un R^2 negativo de $-0,016$ en el conjunto de prueba, indicando que Prophet es peor que un predictor constante igual a la media para esta barra en el período 2025–2026. Este resultado es consistente con la naturaleza de la generación hidroeléctrica del sur, cuya variabilidad está determinada por ciclos de precipitaciones de baja frecuencia que no siguen patrones estacionales regulares. Este resultado motiva directamente la incorporación del TFT como componente complementario en el ensamble.

Se observa además una degradación consistente del R^2 entre entrenamiento y prueba en todas las barras, lo que es esperable dado el cambio estructural en el mercado eléctrico chileno durante el período de prueba 2025–2026, caracterizado por una mayor penetración renovable y episodios de curtailment más frecuentes que los observados durante el entrenamiento.

4.2. Temporal Fusion Transformer con LayerNorm

4.2.1. Desempeño por barra

Las Tablas 4.2 y 4.3 presentan los resultados de evaluación del TFT_{LN} para todas las barras, separados por modelo de precios y de residuos respectivamente.

Los resultados muestran una mejora sustancial respecto a Prophet en todas las barras y métricas. En el TFT_{LN} de precios, el R^2 en test oscila entre 0,814 (Puerto Montt) y 0,890 (Tarapacá), frente a valores de Prophet que iban de $-0,016$ a 0,519. Para Atacama, el R^2 sube de 0,519 con Prophet a 0,887 con el modelo de precios, lo que representa una reducción del error sistemático de aproximadamente el 74 % en términos de varianza explicada. El salto es especialmente pronunciado en Charrúa, de 0,302 con Prophet a 0,869 con el TFT_{LN} de precios, y en Puerto Montt, de $-0,016$ a 0,814, las dos barras con peor desempeño de Prophet, lo que confirma que el TFT es capaz de capturar las dinámicas no lineales de corto plazo que la descomposición aditiva de Prophet no puede representar.

Siete de las ocho barras presentan un MAE en test inferior a 9 USD/MWh en el modelo de precios, con valores entre 6.66 USD/MWh (Crucero) y 8.61 USD/MWh (Charrúa). Puerto Montt es la excepción, con un MAE de 14.32 USD/MWh en test, consistente con la mayor variabilidad estructural de la generación hidroeléctrica del sur que ya se observaba en los resultados de Prophet. Aun así, el R^2 de 0,814 en prueba indica que el TFT_{LN} logra capturar una fracción importante de la dinámica de esta barra, a diferencia de Prophet que resultaba peor que un predictor constante.

El modelo de residuos presenta un R^2 sistemáticamente inferior al de precios en todas las barras, lo que es esperable: al operar sobre los residuos de Prophet, TFT_{LN} modela una señal de menor amplitud y mayor irregularidad relativa. Sin embargo, las métricas de error absoluto son comparables entre ambos modelos, con diferencias en MAE menores a 1.5 USD/MWh

Barra	Conjunto	MAE	RMSE	R ²
Atacama	Train	7.21	14.41	0.941
	Val	7.49	16.06	0.883
	Test	6.67	13.48	0.887
Cardones	Train	6.98	13.52	0.949
	Val	7.57	16.32	0.870
	Test	6.86	14.48	0.871
Charrúa	Train	7.32	13.67	0.948
	Val	8.32	16.00	0.849
	Test	8.61	15.58	0.869
Crucero	Train	7.16	14.02	0.948
	Val	7.55	16.39	0.881
	Test	6.66	13.54	0.888
Pan de Azúcar	Train	6.95	13.31	0.951
	Val	7.81	15.88	0.872
	Test	7.15	14.44	0.875
Puerto Montt	Train	10.33	23.35	0.947
	Val	15.54	30.57	0.805
	Test	14.32	26.44	0.814
Quillota	Train	7.14	13.74	0.947
	Val	8.20	15.91	0.857
	Test	8.34	15.39	0.874
Tarapacá	Train	7.30	14.34	0.949
	Val	7.81	17.53	0.882
	Test	7.05	14.38	0.890

Tabla 4.2: Resultados de evaluación del TFT_{LN}, modelo de precios, por barra y conjunto. MAE y RMSE en USD/MWh.

Barra	Conjunto	MAE	RMSE	R ²
Atacama	Train	7.15	13.55	0.893
	Val	7.89	16.13	0.747
	Test	7.77	14.17	0.734
Cardones	Train	7.17	13.49	0.894
	Val	7.75	15.61	0.749
	Test	7.13	13.71	0.769
Charrúa	Train	7.53	14.03	0.897
	Val	8.52	16.01	0.759
	Test	8.66	15.57	0.810
Crucero	Train	7.17	13.33	0.898
	Val	8.24	16.55	0.735
	Test	7.70	14.55	0.730
Pan de Azúcar	Train	7.28	13.73	0.895
	Val	8.00	15.90	0.749
	Test	7.07	14.04	0.771
Puerto Montt	Train	10.39	22.53	0.890
	Val	16.52	31.70	0.729
	Test	14.62	26.15	0.821
Quillota	Train	7.36	13.36	0.904
	Val	8.73	16.11	0.757
	Test	8.69	15.29	0.807
Tarapacá	Train	7.25	13.38	0.902
	Val	8.13	17.29	0.744
	Test	7.39	14.99	0.742

Tabla 4.3: Resultados de evaluación del TFF_{LN}, modelo de residuos, por barra y conjunto. MAE y RMSE en USD/MWh.

en la mayoría de las barras, lo que indica que ambas instancias del Transformer aportan información complementaria al ensamble y justifica su inclusión conjunta en el Stacking Optimization.

4.3. Stacking Optimization

4.3.1. Selección del mejor método de optimización

Se evaluaron ocho métodos de optimización para la búsqueda de los pesos del ensamble en cada estrategia y barra: *Grid Search* con 21, 41 y 101 puntos, *Differential Evolution*, L-BFGS-B, Nelder-Mead, Ridge, *Random Search* con 1 000 muestras, y SLSQP. La Tabla 4.4 presenta el método con mejor MAE en el conjunto de prueba para cada combinación de barra y estrategia.

Barra	Estrategia	Mejor método	Pesos	MAE	R ²
Atacama	Prophet + TFT precios	Diff. Evol.	$w_1=0,000, w_2=1,000$	6.67	0.887
	Prophet + residuos (opt)	Grid.101	$w_1=0,790, w_2=0,210$	16.18	0.613
	(P+R) + TFT precios	Grid.41	$w_1=0,525, w_2=0,475$	6.94	0.892
Cardones	Prophet + TFT precios	Diff. Evol.	$w_1=0,000, w_2=1,000$	6.86	0.871
	Prophet + residuos (opt)	Grid.41	$w_1=0,775, w_2=0,225$	14.82	0.655
	(P+R) + TFT precios	Grid.21	$w_1=0,400, w_2=0,600$	6.71	0.887
Charrúa	Prophet + TFT precios	Grid.21	$w_1=0,000, w_2=1,000$	8.61	0.869
	Prophet + residuos (opt)	Nelder-Mead	$w_1=0,797, w_2=0,203$	20.81	0.462
	(P+R) + TFT precios	Grid.21	$w_1=0,450, w_2=0,550$	8.30	0.879
Crucero	Prophet + TFT precios	SLSQP	$w_1=0,002, w_2=0,998$	6.66	0.889
	Prophet + residuos (opt)	Grid.41	$w_1=0,775, w_2=0,225$	13.95	0.693
	(P+R) + TFT precios	Grid.101	$w_1=0,490, w_2=0,510$	6.92	0.891
Pan de Azúcar	Prophet + TFT precios	Random.1000	$w_1=0,005, w_2=0,995$	7.14	0.875
	Prophet + residuos (opt)	SLSQP	$w_1=0,789, w_2=0,211$	15.44	0.645
	(P+R) + TFT precios	Ridge	$w_1=0,405, w_2=0,595$	6.84	0.888
Puerto Montt	Prophet + TFT precios	Grid.21	$w_1=0,000, w_2=1,000$	14.32	0.814
	Prophet + residuos (opt)	Grid.21	$w_1=0,750, w_2=0,250$	35.61	0.350
	(P+R) + TFT precios	Grid.41	$w_1=0,475, w_2=0,525$	13.98	0.828
Quillota	Prophet + TFT precios	Diff. Evol.	$w_1=0,000, w_2=1,000$	8.34	0.874
	Prophet + residuos (opt)	Grid.21	$w_1=0,800, w_2=0,200$	20.62	0.457
	(P+R) + TFT precios	Grid.21	$w_1=0,400, w_2=0,600$	8.16	0.883
Tarapacá	Prophet + TFT precios	Grid.21	$w_1=0,000, w_2=1,000$	7.05	0.890
	Prophet + residuos (opt)	Nelder-Mead	$w_1=0,788, w_2=0,212$	14.89	0.687
	(P+R) + TFT precios	Grid.21	$w_1=0,500, w_2=0,500$	6.94	0.895

Tabla 4.4: Mejor método de optimización por barra y estrategia según MAE en prueba. P: Prophet, R: TFT_{LN} residuos, TFT precios: TFT_{LN} precios. MAE en USD/MWh.

Respecto a los métodos de optimización, no se observan diferencias sustanciales en el MAE final entre los distintos métodos para una misma estrategia y barra: las diferencias son inferiores al 0.1 % en todos los casos evaluados. Esto es consistente con la naturaleza unidimensional del problema — con un solo grado de libertad w_1 , dado que $w_2 = 1 - w_1$ —, donde la función objetivo MAE resulta convexa y unimodal, de modo que cualquier método de optimización razonable converge al mismo mínimo global. La diferencia relevante entre métodos es el tiempo de cómputo: *Random Search* es consistentemente el más lento (0.6–1.2s), mientras que SLSQP y Ridge resuelven el problema en menos de 0.05s en la mayoría de las barras. Dado que la calidad del ensamble no se ve afectada por la elección del método, los resultados reportados en el resto de esta sección emplean indistintamente el método con menor MAE de la Tabla 4.4 para cada barra y estrategia.

4.3.2. Selección de la mejor estrategia

La Tabla 4.5 presenta la mejor estrategia por barra según el MAE en el conjunto de prueba, incluyendo la mejora porcentual respecto a Prophet solo y al TFT_{LN} de precios solo.

Barra	Mejor estrategia	MAE	RMSE	R ²	Δ Prophet	Δ TFT
Atacama	TFT _{LN} precios solo	6.67	13.48	0.887	−65.83 %	0.00 %
Cardones	(P+R) + TFT precios	6.71	13.49	0.888	−68.35 %	−2.13 %
Charrúa	(P+R) + TFT precios	8.30	15.00	0.878	−66.91 %	−3.53 %
Crucero	TFT _{LN} precios solo	6.66	13.54	0.888	−70.74 %	0.00 %
Pan de Azúcar	(P+R) + TFT precios	6.85	13.70	0.887	−70.17 %	−4.13 %
Puerto Montt	(P+R) + TFT precios	13.98	25.46	0.828	−70.96 %	−2.40 %
Quillota	(P+R) + TFT precios	8.16	14.84	0.883	−65.94 %	−2.08 %
Tarapacá	(P+R) + TFT precios	6.94	14.10	0.895	−69.60 %	−1.50 %

Tabla 4.5: Mejor estrategia de ensamblaje con TFT_{LN} por barra. MAE y RMSE en USD/MWh. Δ Prophet y Δ TFT indican la mejora porcentual en MAE respecto a Prophet solo y al TFT_{LN} de precios solo respectivamente.

Los resultados revelan tres patrones relevantes. Primero, el ensamble supera a Prophet en las ocho barras con mejoras de entre el 65.8 % (Atacama) y el 71.0 % (Puerto Montt) en MAE, confirmando que la combinación de modelos aporta valor significativo respecto a la descomposición temporal por sí sola. Segundo, en Atacama y Crucero la mejor estrategia es el TFT_{LN} de precios solo, con peso nulo asignado a Prophet, lo que indica que en estas dos barras del norte el TFT captura suficientemente la estructura de la serie sin necesidad de la descomposición de Prophet. Tercero, en las seis barras restantes la estrategia (Prophet+residuos)+TFT precios supera al TFT solo, con mejoras entre el 1.5 % (Tarapacá) y el 4.1 % (Pan de Azúcar), lo que confirma que la complementariedad entre la descomposición de Prophet y el modelado de dependencias del TFT produce ganancias medibles en el ensamble, tal como se argumentó en la Sección 2.5.

Cabe destacar que la estrategia Prophet+residuos optimizada presenta un MAE significativamente mayor que las demás estrategias en todas las barras (14–36 USD/MWh frente a 6–14 USD/MWh), lo que sugiere que los residuos del TFT por sí solos, sin el anclaje del

TFT de precios, no constituyen una señal suficientemente informativa para el ensamble. Esta observación refuerza el rol del TFT_{LN} de precios como componente dominante del modelo híbrido.

4.4. Temporal Fusion Transformer con Dynamic Tanh

4.4.1. Desempeño por barra

Las Tablas 4.6 y 4.7 presentan los resultados de evaluación del TFT_{DyT} para todas las barras, separados por modelo de precios y de residuos respectivamente.

Barra	Conjunto	MAE	RMSE	R^2
Atacama	Train	7.37	14.51	0.941
	Val	7.59	16.02	0.883
	Test	6.84	13.90	0.880
Cardones	Train	7.51	14.83	0.939
	Val	7.18	15.23	0.887
	Test	6.74	13.59	0.886
Charrúa	Train	7.80	15.19	0.936
	Val	8.32	15.91	0.851
	Test	8.30	15.20	0.875
Crucero	Train	7.36	14.36	0.946
	Val	7.59	16.26	0.883
	Test	6.87	14.03	0.880
Pan de Azúcar	Train	7.69	14.85	0.939
	Val	7.70	15.62	0.876
	Test	6.92	13.98	0.883
Puerto Montt	Train	10.89	24.34	0.942
	Val	15.75	29.99	0.812
	Test	14.02	25.32	0.830
Quillota	Train	7.76	15.14	0.936
	Val	8.49	16.14	0.853
	Test	8.59	15.51	0.872
Tarapacá	Train	7.40	14.68	0.947
	Val	7.97	17.25	0.886
	Test	7.52	14.99	0.881

Tabla 4.6: Resultados de evaluación del TFT_{DyT} , modelo de precios, por barra y conjunto. MAE y RMSE en USD/MWh.

Los resultados del TFT_{DyT} son cualitativamente equivalentes a los del TFT_{LN} en todas las barras y métricas. En el modelo de precios, el R^2 en test oscila entre 0,830 (Puerto Montt) y

Barra	Conjunto	MAE	RMSE	R ²
Atacama	Train	7.06	13.20	0.899
	Val	7.87	15.89	0.754
	Test	7.72	14.03	0.739
Cardones	Train	7.34	13.86	0.888
	Val	7.82	15.66	0.748
	Test	7.39	14.33	0.748
Charrúa	Train	8.04	14.95	0.883
	Val	8.60	15.81	0.765
	Test	8.56	15.27	0.817
Crucero	Train	7.48	14.27	0.883
	Val	7.82	16.26	0.744
	Test	7.09	14.03	0.748
Pan de Azúcar	Train	7.59	14.24	0.887
	Val	8.11	15.93	0.749
	Test	7.23	14.30	0.762
Puerto Montt	Train	10.74	23.30	0.882
	Val	16.03	30.87	0.743
	Test	14.33	25.78	0.826
Quillota	Train	7.84	14.64	0.885
	Val	8.52	15.90	0.763
	Test	8.47	15.18	0.810
Tarapacá	Train	7.58	14.61	0.883
	Val	8.34	17.39	0.741
	Test	7.44	14.48	0.760

Tabla 4.7: Resultados de evaluación del TFT_{DyT}, modelo de residuos, por barra y conjunto. MAE y RMSE en USD/MWh.

0,886 (Cardones), rango comparable al de 0,814–0,890 obtenido por TFT_{LN} . Siete de las ocho barras presentan un MAE en test inferior a 9 USD/MWh en el modelo de precios, con valores entre 6,74 USD/MWh (Cardones) y 8,59 USD/MWh (Quillota). Puerto Montt sigue siendo la excepción con un MAE de 14,02 USD/MWh en test, consistente con la mayor variabilidad estructural de la generación hidroeléctrica del sur.

El modelo de residuos presenta, al igual que con TFT_{LN} , un R^2 sistemáticamente inferior al de precios en todas las barras, con valores en test entre 0,739 (Atacama) y 0,826 (Puerto Montt). Las diferencias en MAE entre el modelo de precios y el de residuos son menores a 1,5 USD/MWh en la mayoría de las barras, lo que confirma que ambas instancias del TFT aportan información complementaria al ensamble independientemente del mecanismo de normalización utilizado.

No se observa un patrón sistemático respecto a qué modelo, precios o residuos, se desempeña mejor con TFT_{DyT} en comparación con TFT_{LN} . En algunas barras DyT supera a LN en el modelo de precios pero no en el de residuos, y en otras ocurre lo contrario. Esta ausencia de patrón es consistente con la hipótesis de diversidad estructural planteada en la Sección 2.4.5: las diferencias entre ambas arquitecturas no reflejan una ventaja predictiva media sistemática sino patrones de error cualitativamente distintos ante eventos extremos, que es lo que el Stacking Optimization puede explotar para mejorar la predicción conjunta.

4.4.2. Stacking Optimization con TFT_{DyT}

El procedimiento de Stacking Optimization descrito en la Sección 3.5 se repite íntegramente para TFT_{DyT} , evaluando las mismas seis estrategias de ensamblaje y los mismos ocho métodos de optimización de pesos utilizados para TFT_{LN} . La Tabla 4.8 presenta la mejor estrategia por barra según el MAE en el conjunto de prueba.

Barra	Mejor estrategia	Pesos	MAE	RMSE	R^2	ΔTFT
Atacama	TFT_{DyT} precios solo	—	6.84	13.90	0.880	0.00 %
Cardones	TFT_{DyT} precios solo	—	6.74	13.59	0.886	0.00 %
Charrúa	(P+R) + TFT_{DyT} P	$w_1=0,400, w_2=0,600$	8.10	14.71	0.883	2.39 %
Crucero	(P+R) + TFT_{DyT} P	$w_1=0,450, w_2=0,550$	6.71	13.50	0.889	2.28 %
Pan de Azúcar	(P+R) + TFT_{DyT} P	$w_1=0,525, w_2=0,475$	6.84	13.66	0.888	1.21 %
Puerto Montt	(P+R) + TFT_{DyT} P	$w_1=0,550, w_2=0,450$	13.80	24.92	0.835	1.57 %
Quillota	(P+R) + TFT_{DyT} P	$w_1=0,450, w_2=0,550$	8.23	14.83	0.883	4.17 %
Tarapacá	(P+R) + TFT_{DyT} P	$w_1=0,425, w_2=0,575$	7.17	14.23	0.893	4.67 %

Tabla 4.8: Mejor estrategia de ensamblaje con TFT_{DyT} por barra según MAE en prueba. P+R: Prophet + Residuos; TFT_{DyT} P: TFT_{DyT} precios. MAE y RMSE en USD/MWh. ΔTFT indica la mejora porcentual en MAE respecto al TFT_{DyT} de precios solo. La mejora respecto a Prophet solo se omite por brevedad: oscila entre 64.96 % (Atacama) y 71.34 % (Puerto Montt), en línea con TFT_{LN} .

Los resultados revelan tres patrones relevantes. Primero, la estrategia (Prophet+residuos)+ TFT_{DyT} precios domina en 6 de las 8 barras, el mismo patrón observado con TFT_{LN} , lo que confir-

ma que la complementariedad entre la descomposición de Prophet y el TFT de precios es robusta al mecanismo de normalización. Las barras donde el TFT solo gana coinciden exactamente entre arquitecturas: tanto con LN como con DyT son Atacama y Cardones ¹, lo que refuerza que en estas dos barras del norte el TFT captura por sí solo la estructura predecible de la serie, sin que la componente de residuos de Prophet aporte información adicional, independientemente de la arquitectura de normalización empleada.

Segundo, la mejora respecto a Prophet es consistente y grande en todas las barras, entre 64,96 % (Atacama) y 71,34 % (Puerto Montt) en MAE, magnitud prácticamente idéntica a la obtenida con TFT_{LN} (65.83 %–70.96 %), confirmando que el ensamble aporta valor significativo independientemente de la arquitectura de normalización.

Tercero, la mejora respecto al TFT solo es de magnitud comparable entre arquitecturas, con DyT mostrando mejoras levemente superiores en Tarapacá (4,67 % frente a 1,50 % de LN) y Quillota (4,17 % frente a 2,08 %), mientras que en Charrúa y Pan de Azúcar las mejoras son similares o levemente menores que con LN. Esta variabilidad menor entre barras es consistente con la ausencia de un patrón sistemático de superioridad entre TFT_{LN} y TFT_{DyT} ya discutida en la Sección 4.3, y refuerza que ambas arquitecturas aportan diversidad complementaria al ensamble sin que una domine uniformemente a la otra.

Respecto a los métodos de optimización, el patrón es idéntico al observado con TFT_{LN} : las diferencias en MAE entre métodos para una misma estrategia y barra son inferiores al 0.1 %, con *Random Search* consistentemente como el método más lento (0.5–1.1 s) y Ridge/SLSQP entre los más rápidos. Esto confirma que la elección del método de optimización no constituye un grado de libertad relevante para los resultados del Stacking, independientemente de la arquitectura del TFT utilizada como componente del ensamble.

4.4.3. Comparativa TFT_{LN} vs TFT_{DyT}

La Tabla 4.9 presenta la comparativa directa entre ambas arquitecturas en el conjunto de prueba para el modelo de precios, que es el modelo base dominante en el Stacking Optimization de ambas variantes.

La comparativa revela que ninguna arquitectura domina sistemáticamente a la otra. TFT_{LN} presenta menor MAE en Atacama, Crucero, Quillota y Tarapacá, mientras que TFT_{DyT} supera a TFT_{LN} en Cardones, Charrúa y Pan de Azúcar, con diferencias absolutas inferiores a 0,79 USD/MWh en todos los casos. Puerto Montt es la única barra donde DyT presenta un R^2 ligeramente superior (0,820 vs 0,814), posiblemente porque la comprensión uniforme de la función tanh maneja mejor los spikes de la generación hidroeléctrica del sur, consistente con la motivación teórica de la Sección 2.4.5.

Estas diferencias son pequeñas en términos absolutos y consistentes con los resultados de Zhu et al. (2025), quienes reportan que DyT iguala o supera a LayerNorm en la mayoría de las tareas sin ajuste adicional de hiperparámetros. Desde la perspectiva del modelo híbrido,

¹Nota de actualización: en una versión preliminar de este análisis, basada en una corrida de entrenamiento distinta de TFT_{DyT} , las barras ganadoras con TFT solo eran Atacama y Crucero. Los resultados aquí reportados corresponden a la corrida definitiva.

Barra	TFT _{LN}			TFT _{DyT}		
	MAE	RMSE	R ²	MAE	RMSE	R ²
Atacama	6.67	13.48	0.887	6.95	13.92	0.879
Cardones	6.86	14.48	0.871	6.74	13.59	0.886
Charrúa	8.61	15.58	0.869	8.30	15.20	0.875
Crucero	6.66	13.54	0.888	7.37	14.39	0.874
Pan de Azúcar	7.15	14.44	0.875	6.92	13.98	0.883
Puerto Montt	14.32	26.44	0.814	14.39	26.04	0.820
Quillota	8.34	15.39	0.874	8.95	16.03	0.863
Tarapacá	7.05	14.38	0.890	7.73	15.06	0.880
Promedio	8.21	15.97	0.871	8.43	16.03	0.873

Tabla 4.9: Comparativa entre TFT_{LN} y TFT_{DyT} en el conjunto de prueba, modelo de precios. MAE y RMSE en USD/MWh.

la similitud en el desempeño predictivo medio entre ambas variantes es precisamente lo que se busca: la diversidad estructural entre TFT_{LN} y TFT_{DyT} no proviene de una diferencia en la calidad predictiva promedio sino de diferencias en los patrones de error ante eventos extremos.

4.4.4. Comparativa TFT_{LN} vs. TFT_{DyT}

Esta subsección sintetiza la comparación entre ambas arquitecturas de normalización en dos niveles: primero a nivel de los transformers individuales (precios y residuos por separado), y luego a nivel del Stacking Optimization final, que es la comparación relevante para la elección de arquitectura del modelo híbrido propuesto.

Transformers puros

La Tabla 4.10 presenta el ganador por métrica (MAE, RMSE, R²) entre TFT_{LN} y TFT_{DyT} para cada combinación de barra y modelo (precios o residuos), evaluados de forma independiente antes del ensamblaje.

El resultado más relevante de esta comparación es la ausencia de un ganador dominante: de las 16 combinaciones de barra y modelo, TFT_{LN} gana en 7 y TFT_{DyT} en 9. Desagregando por tipo de modelo, en el modelo de precios el resultado es un empate exacto (4 barras para cada arquitectura), y en el modelo de residuos TFT_{DyT} gana en 5 de las 8 barras. Las diferencias de MAE entre arquitecturas en estas comparaciones son además pequeñas: la mayor diferencia observada es de 0.59 USD/MWh (Quillota, residuos) y la mayoría de los casos presentan diferencias inferiores a 0.3 USD/MWh. Esta distribución de resultados es consistente con la variabilidad de inicialización documentada en la Sección 4.3 y con la hipótesis de Zhu et al. (2025) de que DyT iguala el desempeño de LayerNorm sin requerir ajuste adicional de hiperparámetros, antes que con la existencia de una ventaja sistemática

Barra	Modelo	MAE _{LN}	MAE _{DyT}	R _{LN} ²	R _{DyT} ²	Ganador
Atacama	Precios	6.67	6.84	0.887	0.880	LN
	Residuos	7.77	7.72	0.734	0.739	DyT
Cardones	Precios	6.86	6.74	0.871	0.886	DyT
	Residuos	7.13	7.39	0.769	0.748	LN
Charrúa	Precios	8.61	8.30	0.869	0.875	DyT
	Residuos	8.66	8.56	0.810	0.817	DyT
Crucero	Precios	6.66	6.87	0.888	0.880	LN
	Residuos	7.70	7.09	0.730	0.748	DyT
Pan de Azúcar	Precios	7.15	6.92	0.875	0.883	DyT
	Residuos	7.07	7.23	0.771	0.762	LN
Puerto Montt	Precios	14.32	14.02	0.814	0.830	DyT
	Residuos	14.62	14.33	0.821	0.826	DyT
Quillota	Precios	8.34	8.59	0.874	0.872	LN
	Residuos	8.69	8.47	0.807	0.810	DyT
Tarapacá	Precios	7.05	7.52	0.890	0.881	LN
	Residuos	7.39	7.44	0.742	0.760	DyT

Tabla 4.10: Ganador por MAE entre TFT_{LN} y TFT_{DyT} , evaluados de forma independiente (sin ensamblaje), para cada barra y modelo. MAE en USD/MWh en conjunto de prueba.

de una arquitectura sobre la otra.

Comparativa tras el Stacking Optimization

La Tabla 4.11 presenta la comparación al nivel relevante para el modelo híbrido final: el MAE de la mejor estrategia de Stacking obtenida para cada arquitectura.

Barra	MAE Stacking LN	MAE Stacking DyT	Diferencia	Ganador
Atacama	6.67	6.84	0.17	LN
Cardones	6.71	6.74	0.03	LN
Charrúa	8.30	8.10	0.20	DyT
Crucero	6.66	6.71	0.05	LN
Pan de Azúcar	6.85	6.84	0.01	DyT
Puerto Montt	13.98	13.80	0.18	DyT
Quillota	8.16	8.23	0.07	LN
Tarapacá	6.94	7.17	0.23	LN

Tabla 4.11: MAE en prueba de la mejor estrategia de Stacking Optimization para cada arquitectura, por barra. MAE en USD/MWh.

A nivel del ensamble final, TFT_{LN} resulta ganador en 5 de las 8 barras y TFT_{DyT} en las 3 restantes (Charrúa, Pan de Azúcar y Puerto Montt). Sin embargo, las diferencias son nuevamente pequeñas: oscilan entre 0.01 USD/MWh (Pan de Azúcar, esencialmente un empate técnico) y 0.23 USD/MWh (Tarapacá), con una diferencia promedio de 0.13 USD/MWh

sobre un MAE típico de 6–9 USD/MWh, es decir, del orden del 1–2 % del error base. Estas diferencias son comparables en magnitud a la variabilidad de inicialización observada al re-entrenar el mismo modelo con la misma arquitectura (Sección 4.3), por lo que no constituyen evidencia suficiente para afirmar que una arquitectura de normalización sea sistemáticamente superior a la otra en el contexto de este problema.

La conclusión metodológica relevante no es, por tanto, cuál arquitectura "gana", sino que ambas producen modelos de calidad predictiva estadísticamente equivalente, mientras exhiben patrones de error suficientemente distintos como para que su combinación en un ensamble más amplio (Stacking entre TFT_{LN} y TFT_{DyT} , no explorado en este trabajo) podría constituir una dirección de trabajo futuro. La elección entre una u otra arquitectura para el modelo final puede entonces basarse en criterios secundarios como el tiempo de entrenamiento, la estabilidad numérica observada durante la optimización, o la simplicidad de implementación, antes que en una diferencia de desempeño predictivo robusta.

4.5. Conformal Prediction

4.5.1. Split CP clásico

Los resultados del Split CP clásico se presentan en la Tabla 4.12.

Arq.	Barra	Estrategia	Coverage	Width	MAE	q
TFT_{LN}	Atacama	TFT_LN precios solo	0.9648	68.04	6.67	34.02
	Cardones	(P+R) + TFT_LN precios	0.9611	65.14	6.71	32.57
	Charrúa	(P+R) + TFT_LN precios	0.9504	68.89	8.30	34.44
TFT_{DyT}	Atacama	TFT_DyT precios solo	0.9629	67.49	6.95	33.74
	Cardones	TFT_DyT precios solo	0.9590	65.98	6.74	32.99
	Charrúa	(P+R) + TFT_DyT precios	0.9552	69.74	8.28	34.87

Tabla 4.12: Resultados del Split CP clásico para TFT_{LN} y TFT_{DyT} . Coverage nominal: 0.95. Width, MAE y q en USD/MWh. Resultados parciales.

Los resultados muestran cobertura empírica por encima del nominal en todas las barras y ambas arquitecturas. Para TFT_{LN} , la cobertura oscila entre 0.9504 (Charrúa) y 0.9648 (Atacama), con anchos medios entre 65.1 y 68.9 USD/MWh. El caso de Charrúa es especialmente relevante: es la única barra que se aproxima al nominal exacto con una diferencia de cobertura de apenas 0.04 puntos porcentuales, consistente con que su mejor estrategia de ensamble incluye la componente de residuos de Prophet, que introduce mayor variabilidad y produce *scores* de calibración más representativos del comportamiento en prueba.

La sobrecobertura observada en Atacama y Cardones, de hasta 1.5 puntos porcentuales sobre el nominal, es el efecto esperado de un cuantil fijo calculado sobre el período de validación: si la distribución de errores en prueba es más concentrada que en calibración, el intervalo resulta conservadoramente ancho. Esta limitación motiva las variantes adaptativas.

4.5.2. EnbPI V2

Los resultados de EnbPI V2 se presentan en la Tabla 4.13.

Arq.	Barra	Coverage	Width	MAE	RMSE
TFT _{LN}	Atacama	0.9659	67.46	7.13	13.13
	Cardones	0.9653	69.17	7.02	13.37
	Charrúa	0.9594	74.61	8.64	14.89
TFT _{DyT}	Atacama	0.9645	68.17	7.08	13.33
	Cardones	0.9619	68.28	7.11	13.37
	Charrúa	0.9617	73.60	8.39	14.73

Tabla 4.13: Resultados de EnbPI V2 para TFT_{LN} y TFT_{DyT}. Coverage nominal: 0.95. Width, MAE y RMSE en USD/MWh. Resultados parciales.

EnbPI mantiene cobertura robustamente por encima del nominal en todas las barras, pero a costa de anchos medios superiores a los del Split CP en la mayoría de los casos: Charrúa LN alcanza 74.6 USD/MWh frente a los 68.9 USD/MWh del Split CP, un incremento del 8.3 %. Este ensanchamiento es consecuencia del mecanismo de actualización de la ventana de residuos: cuando el modelo comete errores grandes en instantes recientes, asociados a spikes de costo marginal, EnbPI amplía el intervalo preventivamente en los instantes siguientes, incrementando la cobertura pero reduciendo la eficiencia del intervalo.

4.5.3. ACI *offline*

Los resultados de ACI *offline* para tres valores de γ se presentan en la Tabla 4.14.

Tres patrones emergen de los resultados. Primero, $\gamma = 0,01$ produce la cobertura más cercana al nominal en todas las barras y ambas arquitecturas, con errores de cobertura menores a 0.05 puntos porcentuales para Atacama y Charrúa LN, aproximando la garantía finito-muestral de ACI descrita en la Sección 2.6.3. Segundo, los anchos son consistentemente menores que los del Split CP y EnbPI: para Atacama LN, ACI *offline* con $\gamma = 0,01$ produce un ancho de 55.4 USD/MWh frente a 68.0 y 67.5 USD/MWh del Split CP y EnbPI respectivamente, una reducción de alrededor del 18 %. Tercero, a medida que γ crece, la cobertura empírica cae por debajo del nominal en las barras con mayor variabilidad estructural, como Charrúa LN con $\gamma = 0,10$ (coverage = 0,9389). El valor promedio $\bar{\alpha}_t > \alpha$ observado en todos los casos confirma que el algoritmo identifica *drift* distribucional y compensa ampliando el nivel nominal efectivo.

4.5.4. ACI *online*

Los resultados de ACI *online* con $\gamma = 0,05$ se presentan en la Tabla 4.15.

La variante *online* produce la cobertura más cercana al nominal entre todos los métodos

Arq.	Barra	γ	Coverage	Width	MAE	$\bar{\alpha}_t$
TFT _{LN}	Atacama	0.01	0.9504	55.37	7.13	0.0799
		0.05	0.9470	58.24	7.13	0.0847
		0.10	0.9424	58.99	7.13	0.0908
	Cardones	0.01	0.9502	55.52	7.02	0.0830
		0.05	0.9469	57.36	7.02	0.0885
		0.10	0.9412	57.91	7.02	0.0940
	Charrúa	0.01	0.9501	62.92	8.64	0.0739
		0.05	0.9454	62.45	8.64	0.0833
		0.10	0.9389	62.35	8.64	0.0903
TFT _{DyT}	Atacama	0.01	0.9502	56.06	7.08	0.0784
		0.05	0.9465	57.52	7.08	0.0874
		0.10	0.9417	58.49	7.08	0.0936
	Cardones	0.01	0.9499	55.51	7.11	0.0801
		0.05	0.9466	57.65	7.11	0.0844
		0.10	0.9409	58.06	7.11	0.0921
	Charrúa	0.01	0.9500	63.68	8.39	0.0718
		0.05	0.9454	63.73	8.39	0.0808
		0.10	0.9392	62.22	8.39	0.0920

Tabla 4.14: Resultados de ACI *offline* para tres valores de γ . Coverage nominal: 0.95. Width y MAE en USD/MWh. $\bar{\alpha}_t$: media temporal del nivel adaptado. Resultados parciales.

Arq.	Barra	Coverage	Width	MAE	$\bar{\alpha}_t$	T (s)
TFT _{LN}	Atacama	0.9469	57.22	7.05	0.0864	57.4
	Cardones	0.9466	56.88	6.94	0.0904	60.6
	Charrúa	0.9454	63.66	8.63	0.0851	59.3
TFT _{DyT}	Atacama	0.9460	57.72	7.03	0.0875	58.6
	Cardones	0.9463	56.78	7.05	0.0875	59.4
	Charrúa	0.9454	64.05	8.41	0.0829	58.5

Tabla 4.15: Resultados de ACI *online* con $\gamma = 0,05$ para TFT_{LN} y TFT_{DyT}. Coverage nominal: 0.95. Width y MAE en USD/MWh. $\bar{\alpha}_t$: media temporal del nivel adaptado. T: tiempo de ejecución en segundos. Resultados parciales.

adaptativos, con errores máximos de 0.55 puntos porcentuales para Charrúa en ambas arquitecturas. Los anchos son comparables a los de ACI *offline* con $\gamma = 0,05$: 57.2 USD/MWh para Atacama LN frente a 58.2 USD/MWh de la variante *offline*, una reducción marginal del 1.7 %. El reentrenamiento continuo del modelo tiene por tanto un efecto moderado sobre la eficiencia del intervalo, lo que sugiere que el modelo Ridge con el conjunto de *features* de Stacking converge rápidamente y las observaciones adicionales de prueba aportan información incremental limitada para el ajuste del cuantil.

4.5.5. Comparativa de métodos

La Tabla 4.16 presenta la comparativa de los cuatro métodos para la barra Atacama.

Método	Cov. LN	Cov. DyT	Width LN	Width DyT	MAE LN	MAE DyT
Split CP	0.9648	0.9629	67.76	67.74	6.81	7.30
EnbPI	0.9659	0.9645	67.82	68.17	7.10	7.08
ACI <i>off</i>	0.9424	0.9417	58.74	59.59	7.10	7.08
ACI <i>on</i>	0.9469	0.9460	57.47	57.72	7.04	7.03

Tabla 4.16: Comparativa de los cuatro métodos de CP para la barra Atacama. Coverage nominal: 0.95. Width y MAE en USD/MWh.

La comparativa revela un *trade-off* claro entre cobertura y eficiencia del intervalo. Split CP y EnbPI logran las coberturas más altas (0.96–0.97), pero a costa de anchos medios de alrededor de 68 USD/MWh, un 18 % más amplios que los intervalos de los métodos ACI. Los métodos ACI, por su parte, reducen el ancho a 57–59 USD/MWh con una cobertura empírica más próxima al nominal, siendo ACI *online* el que mejor equilibra ambas dimensiones: produce los intervalos más estrechos manteniendo una diferencia de cobertura de 0.54 puntos porcentuales respecto al nominal para LN y 0.40 para DyT.

Desde la perspectiva del uso operacional de los intervalos en el SEN, el costo de un intervalo excesivamente ancho es real: sobreestimar la incertidumbre impone márgenes de reserva innecesarios. En ese contexto, ACI *online* emerge como el método más adecuado para la aplicación propuesta. Adicionalmente, los resultados de ACI con $\gamma = 0,01$ confirman que es posible aproximar la cobertura nominal exacta (diferencias inferiores a 0.05 puntos porcentuales) a costa de un leve ensanchamiento respecto a $\gamma = 0,05$.

4.5.6. Comparación con regresión cuantílica

La Tabla 4.17 presenta la comparación entre el Split CP y la regresión cuantílica para la barra Atacama con TFT_{LN} .

La regresión cuantílica produce intervalos más estrechos (54.3 vs. 68.0 USD/MWh) con una cobertura de 0.9558, inferior a la del Split CP pero aún por encima del nominal. La diferencia de ancho de 13.7 USD/MWh sugiere que la QR aprovecha la estructura condicional de la distribución del error para construir intervalos más eficientes al costo de garantías de

Método	Coverage	Width	MAE	RMSE
Split CP	0.9648	68.04	6.67	13.48
Regresión Cuantílica	0.9558	54.34	6.67	13.48

Tabla 4.17: Comparación entre Split CP y regresión cuantílica para la barra Atacama (TFT_{LN}). Coverage nominal: 0.95. Width, MAE y RMSE en USD/MWh.

cobertura distribucionales más débiles: a diferencia del Split CP, la QR no ofrece garantías de cobertura marginal finita sin supuestos sobre la distribución. Este resultado es consistente con la literatura de comparación entre CP y QR (Angelopoulos y Bates, 2023): CP es más conservador pero ofrece garantías más sólidas, especialmente relevantes en el contexto de cambio distribucional continuo del SEN.

4.5.7. Síntesis

La aplicación de las cuatro variantes de CP al modelo híbrido propuesto permite extraer cuatro conclusiones. Primero, todos los métodos evaluados satisfacen la cobertura nominal del 95 % o se aproximan a ella con errores menores a 0.6 puntos porcentuales, lo que confirma que el Stacking Optimization produce residuos suficientemente calibrables para construir intervalos válidos. Segundo, los métodos ACI reducen el ancho del intervalo en aproximadamente el 18 % respecto al Split CP clásico sin comprometer la cobertura nominal, lo que los hace preferibles para el uso operacional en el mercado eléctrico. Tercero, el comportamiento es consistente entre TFT_{LN} y TFT_{DyT}, con diferencias de cobertura y ancho menores a 1 USD/MWh entre arquitecturas en todos los métodos, lo que sugiere que la calidad de los intervalos conformes no es sensible al mecanismo de normalización del TFT sino a la distribución de los errores de predicción puntual del ensamble. Cuarto, el esquema de calibración presenta una limitación metodológica inherente al diseño del experimento: el conjunto de validación cumple simultáneamente el rol de selección del mejor ensamble y de calibración del CP, lo que introduce un sesgo optimista en el cuantil de no conformidad. Este sesgo es esperablemente pequeño dado el tamaño del conjunto de calibración ($n_{\text{cal}} = 8245$) y la estabilidad de los residuos del ensamble, y se reporta como limitación del diseño para transparencia metodológica.

4.6. Análisis de interpretabilidad del TFT

Una ventaja distintiva del TFT respecto a otros modelos de aprendizaje profundo es que su arquitectura produce medidas de importancia de variables de manera nativa a través de la Variable Selection Network (VSN) descrita en la Sección 2.3.4. En esta sección se analiza la importancia relativa de cada *feature* en el encoder y el decoder del TFT_{LN} para las ocho barras del SEN, comparando los modelos de precios y de residuos. La importancia se reporta como el porcentaje del peso total asignado por la VSN a cada variable, promediado sobre todas las muestras del conjunto de prueba. Los resultados individuales por barra se encuentran en el

Anexo. Esta sección presenta los patrones transversales a través de los mapas de calor de las Figuras 4.2–4.5.

4.6.1. Importancia en el encoder

El encoder procesa la ventana de historia de 168 horas y sus pesos de selección reflejan qué información del pasado reciente es más relevante para construir la representación interna del modelo.




Figura 4.2: Importancia de variables en el encoder de TFFT_{LN} precios para las ocho barras del SEN. Importancias en %, promediadas sobre el conjunto de prueba.




Figura 4.3: Importancia de variables en el encoder de TFFT_{LN} residuos para las ocho barras del SEN. Importancias en %, promediadas sobre el conjunto de prueba.

Cuatro patrones emergen de las Figuras 4.2 y 4.3.

Primero, la serie objetivo domina el encoder de forma universal. **y_real** lidera en el modelo de precios en todas las barras, con importancias que van desde el 24.1 % en Charrúa hasta el 67.0 % en Puerto Montt. El mismo patrón se observa en el modelo de residuos, donde **residuo** lidera con importancias entre el 16.3 % (Crucero) y el 46.8 % (Puerto Montt). La concentración particularmente alta en Puerto Montt en ambos modelos es consistente con la mayor volatilidad estructural de esta barra: en un mercado con mayor variabilidad intrínseca, la historia reciente de la propia serie es relativamente más informativa al resto de las covariables.

Segundo, existe un gradiente norte-sur en el peso de las variables climáticas en el encoder de precios. Las barras del norte solar (Atacama, Cardones, Crucero, Pan de Azúcar, Tarapacá) presentan pesos climáticos totales moderados, mientras que Charrúa, con un total climático de aproximadamente 27 %, refleja la influencia de la precipitación y la temperatura sobre la generación hidroeléctrica y la demanda de calefacción en la zona sur. Puerto Montt es la excepción al patrón: a pesar de ser la barra más austral, presenta los pesos climáticos más bajos del grupo, probablemente porque su alta variabilidad es impulsada por factores de despacho no meteorológicos que no están representados en las covariables disponibles.

Tercero, la componente `daily` de Prophet adquiere significativamente más peso en el modelo de residuos que en el de precios en prácticamente todas las barras, pasando de importancias de entre 2 % y 12 % en precios a entre 8 % y 15 % en residuos. Esto indica que una vez eliminada la señal cruda de la serie objetivo, el ciclo diario capturado por Prophet se convierte en la referencia estructural más importante del encoder, probablemente porque el patrón horario del residuo no es completamente absorbido por los lags del residuo mismo.

Cuarto, los lags de la variable objetivo presentan importancias moderadas en ambos modelos: `y_lag24` e `y_lag168` contribuyen entre el 2 % y el 6 % en el encoder de precios, mientras que `resid_lag24` y `resid_lag168` aporta entre el 1.5 % y el 7.5 % en el encoder de residuos. En ambos casos, estos lags quedan muy por debajo de la variable objetivo contemporánea (`y_real` o `residuo`), lo que indica que la historia inmediata de la serie aporta información complementaria pero no dominante: una vez que el encoder dispone del valor más reciente de la serie, los rezagos adicionales tienen un rol marginal en la representación interna del modelo.

4.6.2. Importancia en el decoder

El decoder utiliza únicamente covariables futuras conocidas: las componentes de Prophet (`trend`, `yearly`, `weekly`, `daily`), el indicador de feriado (`is_holiday`) y el índice temporal relativo (`relative_time_idx`).




Figura 4.4: Importancia de variables en el decoder del modelo de precios (TFT_{LN}) para las ocho barras del SEN. Importancias en %, promediadas sobre el conjunto de prueba.




Figura 4.5: Importancia de variables en el decoder del modelo de residuos (TFT_{LN}) para las ocho barras del SEN. Importancias en %, promediadas sobre el conjunto de prueba.

Tres patrones destacan en las Figuras 4.4 y 4.5.

Primero, `is_holiday` lidera el decoder de precios en cuatro de las ocho barras: Atacama (36.0 %), Cardones (23.8 %), Charrúa (32.4 %) y Puerto Montt (19.2 %). En las cuatro barras restantes el liderazgo recae en otras variables: `relative_time_idx` en Crucero (29.7 %), `daily` en Pan de Azúcar (44.5 %) y Tarapacá (25.6 %, por apenas 0.1 puntos sobre `is_holiday`), y `trend` en Quillota (25.7 %). Crucero y Quillota presentan además los valores más bajos de `is_holiday` en el decoder (4.3 % y 3.2 % respectivamente), lo que sugiere que en estas barras el efecto feriado sobre el costo marginal es menos sistemático y el modelo recurre a otras señales temporales para estructurar su pronóstico. El caso de Pan de Azúcar es especialmente llamativo: el peso de `daily` de 44.5 % es el más alto del grupo y refleja que para esta barra el ciclo horario de Prophet es la señal futura más determinante, consistente

con una barra dominada por generación solar con ciclos diarios muy regulares.

Segundo, en el decoder de residuos no existe un liderazgo tan claro como el de `is_holiday` en el modelo de precios. `daily` lidera en tres barras (Pan de Azúcar, Quillota y Tarapacá), `relative_time_idx` en otras tres (Cardones, Crucero y Puerto Montt), `trend` en Atacama (32.6 %) e `is_holiday` en Charrúa (33.6 %). Este mayor fraccionamiento del liderazgo indica que la estructura del residuo, la componente no capturada por Prophet, responde a dinámicas distintas según la zona geográfica y el tipo de generación dominante, sin un factor futuro universalmente más informativo. La persistencia de `is_holiday` como variable dominante en Charrúa residuos (33.6 %) sugiere que los feriados generan residuos sistemáticos en la zona sur, posiblemente asociados a cambios en el despacho hidroeléctrico durante días de menor demanda industrial.

Tercero, Pan de Azúcar presenta en el decoder de precios un valor de `daily` de 44.5 %, muy por encima del resto de las barras (17.4–25.8 %). Esta anomalía refleja que para Pan de Azúcar el ciclo intradiario de Prophet es la señal futura más determinante, lo que es consistente con una barra dominada por generación solar con ciclos diarios muy regulares y poca influencia de factores de demanda o despacho adicionales.

4.6.3. Atención temporal

La Figura 4.6 presenta los perfiles de atención temporal del TFT_{LN} para las ocho barras en ambos modelos. El patrón es estructuralmente consistente: en todas las barras y ambos modelos existe un pico pronunciado en el índice -168 , correspondiente al instante de exactamente una semana atrás, seguido de una caída abrupta a valores cercanos a cero para el resto de la ventana de 168 horas. La universalidad de este patrón confirma que la dependencia semanal es la estructura de memoria dominante del TFT para el *forecasting* horario del costo marginal en el SEN, independientemente de la barra o del tipo de modelo.

Dos variaciones destacan respecto al patrón general. Primero, los modelos de residuos presentan picos de mayor magnitud que los de precios en la mayoría de las barras: la atención en -168 alcanza valores de hasta 0.25 en residuos frente a 0.11–0.17 en precios, lo que sugiere que la dependencia semanal es más pronunciada en la señal de residuo una vez eliminada la estructura sistemática de Prophet. Segundo, Puerto Montt es el único caso atípico: el pico en -168 es notablemente más bajo que en el resto del grupo, con valores de aproximadamente 0.025 en el modelo de precios y 0.09 en el de residuos. Esta atenuación es consistente con la mayor volatilidad estructural de esta barra, donde el patrón semanal de despacho es menos regular debido a la dependencia de la generación hidroeléctrica de factores hidrológicos que no siguen ciclos semanales estrictos.

4.6.4. Síntesis

El análisis de interpretabilidad sobre las ocho barras permite extraer cuatro conclusiones sobre el comportamiento del TFT_{LN} en el contexto del SEN.




Figura 4.6: Perfiles de atención temporal del TFT_{LN} para las ocho barras del SEN. A la izquierda el modelo de precios y la derecha el modelo de residuos. El eje horizontal corresponde al índice temporal relativo dentro de la ventana de encoder de 168 horas ($-168 =$ una semana atrás, $0 =$ instante más reciente). La línea vertical punteada marca el instante 0.

Primero, la serie objetivo (y_{real} o residuo) domina el encoder de forma universal, con Puerto Montt como caso extremo donde la alta volatilidad estructural concentra aún más peso en la historia reciente de la propia serie.

Segundo, existe un gradiente norte-sur en el peso de las variables climáticas en el encoder de precios, con Charrúa como barra con mayor peso climático total ($\approx 27\%$), validando la inclusión de covariables meteorológicas y reflejando el rol de la precipitación y la temperatura en la dinámica del costo marginal de la zona sur.

Tercero, `is_holiday` lidera el decoder de precios en seis de las ocho barras, confirmando que la anticipación de feriados es la señal futura más disruptiva del patrón de despacho, con la excepción de Crucero donde `relative_time_idx` toma el primer lugar de forma atípica.

Cuarto, la atención temporal se concentra universalmente en el lag -168 , confirmando que la dependencia semanal es la estructura de memoria dominante del TFT para el *forecasting* horario del costo marginal en el SEN, independientemente de la barra o del tipo de modelo.

4.6.5. Análisis de errores extremos

La brecha entre el MAE promedio del modelo (X) USD/MWh en validación y la amplitud media de los intervalos de Conformal Prediction (Y) USD/MWh,

equivalente a un cuantil de calibración $q = 34,02$ USD/MWh, sugiere que la distribución de errores del modelo no es simétrica ni de cola ligera. Para comprender el origen de esta brecha, se examina la distribución completa de errores absolutos en el conjunto de validación

de Atacama.

La Figura 4.7 muestra la distribución de errores absolutos del TFT_{LN} en validación. La distribución presenta una forma exponencial decreciente fuertemente concentrada: más del 90 % de las predicciones tienen un error menor a 21.4 USD/MWh, y el percentil 95 es de 33.9 USD/MWh. Sin embargo, la distribución exhibe una cola derecha extendida con valores que alcanzan los 169.7 USD/MWh, con un percentil 99 de 68.1 USD/MWh. Es precisamente esta cola la que determina el cuantil de calibración del Split CP: $q = 34,02 \text{ USD/MWh}$ corresponde al percentil 95 de la distribución de errores de validación, de modo que el ancho del intervalo queda dominado por el 5 % de los errores más grandes.



Figura 4.7: Distribución de errores absolutos del TFT_{LN} en el conjunto de validación para la barra Atacama ($n = 8\,245$ observaciones). Las líneas verticales indican el MAE (rojo), el percentil 90 (naranja claro) y el percentil 95 (naranja oscuro). La distribución exhibe una forma exponencial decreciente con una cola derecha extendida que alcanza los 169.7 USD/MWh.

Una primera hipótesis ante una cola de este tipo es que los errores extremos correspondan a eventos inusuales de la propia serie temporal: spikes de costo marginal asociados a indisponibilidades, eventos climáticos o cambios regulatorios que el modelo no puede anticipar por construcción, dado que no dispone de información futura sobre dichos eventos. Bajo esa hipótesis, los errores grandes serían inherentes a la naturaleza del problema y no reflejarían una deficiencia del modelo. Para evaluar esta hipótesis, se examinan en detalle los 10 errores absolutos más grandes del conjunto de validación.

La Tabla 4.18 presenta los 10 mayores errores absolutos, junto con la clasificación del mecanismo identificado mediante inspección visual de la ventana de ± 48 h alrededor de cada instante.

Rank	Fecha	Hora	Error abs. (USD/MWh)	Tipo
1	2024-09-04	20:00	169.66	Desfase de fase
2	2025-04-07	19:00	166.11	Desfase de fase
3	2024-09-03	21:00	161.45	Desfase de fase
4	2025-04-09	08:00	160.78	Desfase de fase
5	2024-09-04	19:00	156.38	Desfase de fase
6	2024-08-09	08:00	155.00	Evento estructural
7	2025-04-07	20:00	141.79	Desfase de fase
8	2024-11-25	07:00	136.31	Desfase de fase
9	2025-02-11	02:00	130.78	Desfase de fase
10	2025-02-11	05:00	126.19	Desfase de fase
11	2024-10-04	07:00	125.17	Desfase de fase
12	2025-04-07	08:00	125.05	Desfase de fase
13	2024-09-10	08:00	116.97	Desfase de fase
14	2024-12-27	00:00	110.24	Desfase de fase
15	2024-10-03	21:00	109.25	Desfase de fase
16	2024-10-04	00:00	107.88	Desfase de fase
17	2025-03-14	23:00	106.49	Desfase de fase
18	2025-04-10	07:00	106.43	Desfase de fase
19	2025-04-06	07:00	105.26	Desfase de fase
20	2025-04-01	20:00	105.04	Desfase de fase

Tabla 4.18: Los 20 mayores errores absolutos del TFT_{LN} en validación para la barra Atacama. La columna *Tipo* clasifica el mecanismo identificado mediante inspección visual de la ventana de ± 48 h alrededor de cada instante.

El análisis visual descarta en gran medida la hipótesis de eventos inusuales en la serie: 19 de los 20 errores no corresponden a spikes anómalos del costo marginal sino a un fenómeno de distinta naturaleza. En cada uno de estos casos, el modelo predice correctamente la magnitud del ciclo diario del CMg, pero con un desfase temporal de aproximadamente una hora respecto a la transición solar real. Este *desfase de fase* se manifiesta de forma simétrica en las dos ventanas de transición del ciclo fotovoltaico de Atacama: en las horas de amanecer (07:00–08:00), el modelo anticipa en una hora el descenso del costo marginal asociado a la inyección solar, prediciendo valores bajos cuando el real aún permanece elevado; en las horas de atardecer (19:00–21:00), ocurre el fenómeno inverso, con el modelo prediciendo el ascenso vespertino una hora antes de que efectivamente ocurra. En ambos casos, un desplazamiento

de una hora en la curva predicha produce una alineación prácticamente perfecta con la curva real, confirmando que el error es puramente de fase y no de amplitud.

La Figura 4.8 ilustra cuatro casos representativos. Los errores #1 y #2 corresponden a desfases en la transición de atardecer; el error #4 es un desfase de amanecer en dirección opuesta. Para contraste, el error #6 corresponde al único evento de naturaleza distinta en el top-20: un spike abrupto en la serie real que el modelo suaviza, consistente con un evento de indisponibilidad o redespacho no capturado por las covariables disponibles.

La concentración temporal de los errores extremos no es casual: 13 de los 20 ocurren en el rango 07:00–08:00 o 19:00–21:00, que corresponde precisamente a las ventanas de transición solar de la barra Atacama. El mecanismo subyacente es estructural: la generación fotovoltaica en el Desierto de Atacama produce transiciones abruptas en el costo marginal —de valores elevados nocturnos a valores bajos diurnos y viceversa— cuya temporización exacta varía cada día según las condiciones de nubosidad y la disponibilidad de las unidades de respaldo. El modelo captura la magnitud de estas transiciones, que son sistemáticas y están representadas en los lags temporales y en la componente **daily** de Prophet, pero no puede anticipar con precisión de hora el momento exacto de la transición cuando este se desvía del patrón promedio aprendido durante el entrenamiento.

Esta caracterización tiene una implicancia directa para la Conformal Prediction: los errores de desfase de fase son, por construcción, de gran amplitud instantánea pero muy localizados en el tiempo. Un cuantil de calibración calculado sobre el percentil 95 de todos los errores de validación necesariamente incorpora estos eventos extremos, resultando en un ancho medio de 68 USD/MWh que sobreestima la incertidumbre en el 95 % restante de las horas donde el modelo opera sin desfase. Esta es la causa fundamental de la brecha entre el MAE de 7.49 USD/MWh y el semiancho del intervalo de 34.02 USD/MWh: ambas métricas son estadísticamente correctas, pero describen regímenes distintos de la misma distribución de errores.

imagenes/fig_phase_shift_panel_2x2.pdf

Figura 4.8: Casos extremos de error del TFT_{LN} para la barra Atacama en validación. Cada panel muestra una ventana de ± 48 h alrededor del instante de error máximo (línea vertical punteada naranja). La curva azul corresponde al CMg real y la curva roja punteada a la predicción. En los tres primeros paneles (desfase de fase), la predicción reproduce correctamente la forma del ciclo diario pero con un adelanto de aproximadamente una hora en la transición solar. El cuarto panel (error #6, evento estructural) muestra un spike en la serie real que el modelo suaviza.

Bibliografía

- [1] Paula Acuña. Volatilidad del precio spot. sector eléctrico - chile. Technical report, Humphreys Calsificadora de Riesgo, 2025.
- [2] Jimmy Lei Ba et al. Layer normalization. *Stats Machine Learning*, 2016.
- [3] Thomas G. Dietterich. Ensemble methods in machine learning. *Neural Networks*, 2000.
- [4] I. Gibbs et al. Adaptive conformal inference under distribution shift. *NeurIPS*, 2021.
- [5] Victor Guillou. Aporte de las ernc a la generación eléctrica toca nuevo máximo histórico tras superar el 40 *La Tercera*, 2024.
- [6] Victor Guillou. Pérdidas de energía renovable alcanzan máximo histórico en el 2024. *La Tercera*, 2025.
- [7] Víctor Guillou. Curtailment: Vertimientos de energía eólica y fotovoltaica aumentan 219 *La Tercera*, 2024.
- [8] Cheng Huang et al. Artificial intelligence-based power market price prediction in smart renewable energy systems: Combining prophet and transformer models. *Heliyon*, 2024.
- [9] J. Lei et al. Distribution-free predictive inference for regression. *JASA*, 2005.
- [10] Bryan Lim et al. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting.*, 2021.
- [11] Coordinador Eléctrico Nacional. Reporte anual de desempeño del sistema eléctrico nacional. Technical report, Coordinador Eléctrico Nacional, 2025.
- [12] Sean Taylor et al. Forecasting at scale. *Facebook Open Source*, 2018.
- [13] Ashish Vaswani et al. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017.
- [14] V. Vovk et al. Algorithmic learning in a random world. *Springer*, 2005.
- [15] Rafal Weron. Electricity price forecasting: A review of the state-of-the-art with a look into the future. *International Journal of Forecasting*, 2014.
- [16] D.H. Wolpert. Stacked generalization. *Neural Networks*, 1992.

- [17] Ruibin Xiong et al. On layer normalization in the transformer architecture. *Proceedings of Machine Learning Research*, 2020.
- [18] C. Xu et al. Conformal prediction interval for dynamic time series. *ICML*, 2021.
- [19] Margaux Zaffran. *Post-hoc predictive uncertainty quantification: methods with applications to electricity price forecasting*. PhD thesis, Institut Polytechnique de Paris, 2024.
- [20] Haoyi Zhou et al. Informer: Beyond efficient transformer for long sequence time-series forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence*, 2021.
- [21] Jiachen Zhu et al. Transformers without normalization. *Conference on Computer Vision and Pattern Recognition*, 2025.

Apéndice A

Anexo

Quisque facilisis auctor sapien. Pellentesque gravida hendrerit lectus. Mauris rutrum sodales sapien. Fusce hendrerit sem vel lorem. Integer pellentesque massa vel augue. Integer elit tortor, feugiat quis, sagittis et, ornare non, lacus. Vestibulum posuere pellentesque eros. Quisque venenatis ipsum dictum nulla. Aliquam quis quam non metus eleifend interdum. Nam eget sapien ac mauris malesuada adipiscing. Etiam eleifend neque sed quam. Nulla facilisi. Proin a ligula. Sed id dui eu nibh egestas tincidunt. Suspendisse arcu.

Maecenas dui. Aliquam volutpat auctor lorem. Cras placerat est vitae lectus. Curabitur massa lectus, rutrum euismod, dignissim ut, dapibus a, odio. Ut eros erat, vulputate ut, interdum non, porta eu, erat. Cras fermentum, felis in porta congue, velit leo facilisis odio, vitae consectetur lorem quam vitae orci. Sed ultrices, pede eu placerat auctor, ante ligula rutrum tellus, vel posuere nibh lacus nec nibh. Maecenas laoreet dolor at enim. Donec molestie dolor nec metus. Vestibulum libero. Sed quis erat. Sed tristique. Duis pede leo, fermentum quis, consectetur eget, vulputate sit amet, erat.

Donec vitae velit. Suspendisse porta fermentum mauris. Ut vel nunc non mauris pharetra varius. Duis consequat libero quis urna. Maecenas at ante. Vivamus varius, wisi sed egestas tristique, odio wisi luctus nulla, lobortis dictum dolor ligula in lacus. Vivamus aliquam, urna sed interdum porttitor, metus orci interdum odio, sit amet euismod lectus felis et leo. Praesent ac wisi. Nam suscipit vestibulum sem. Praesent eu ipsum vitae pede cursus venenatis. Duis sed odio. Vestibulum eleifend. Nulla ut massa. Proin rutrum mattis sapien. Curabitur dictum gravida ante.

Phasellus placerat vulputate quam. Maecenas at tellus. Pellentesque neque diam, dignissim ac, venenatis vitae, consequat ut, lacus. Nam nibh. Vestibulum fringilla arcu mollis arcu. Sed et turpis. Donec sem tellus, volutpat et, varius eu, commodo sed, lectus. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Quisque enim arcu, suscipit nec, tempus at, imperdiet vel, metus. Morbi volutpat purus at erat. Donec dignissim, sem id semper tempus, nibh massa eleifend turpis, sed pellentesque wisi purus sed libero. Nullam lobortis tortor vel risus. Pellentesque consequat nulla eu tellus. Donec velit. Aliquam fermentum, wisi ac rhoncus iaculis, tellus nunc malesuada orci, quis volutpat dui magna id mi. Nunc vel ante. Duis vitae lacus. Cras nec ipsum.

Morbi nunc. Aliquam consectetur varius nulla. Phasellus eros. Cras dapibus porttitor risus. Maecenas ultrices mi sed diam. Praesent gravida velit at elit vehicula porttitor. Phasellus nisl mi, sagittis ac, pulvinar id, gravida sit amet, erat. Vestibulum est. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Curabitur id sem elementum leo rutrum hendrerit. Ut at mi. Donec tincidunt faucibus massa. Sed turpis quam, sollicitudin a, hendrerit eget, pretium ut, nisl. Duis hendrerit ligula. Nunc pulvinar congue urna.

Nunc velit. Nullam elit sapien, eleifend eu, commodo nec, semper sit amet, elit. Nulla lectus risus, condimentum ut, laoreet eget, viverra nec, odio. Proin lobortis. Curabitur dictum arcu vel wisi. Cras id nulla venenatis tortor congue ultrices. Pellentesque eget pede. Sed eleifend sagittis elit. Nam sed tellus sit amet lectus ullamcorper tristique. Mauris enim sem, tristique eu, accumsan at, scelerisque vulputate, neque. Quisque lacus. Donec et ipsum sit amet elit nonummy aliquet. Sed viverra nisl at sem. Nam diam. Mauris ut dolor. Curabitur ornare tortor cursus velit.

Morbi tincidunt posuere arcu. Cras venenatis est vitae dolor. Vivamus scelerisque semper mi. Donec ipsum arcu, consequat scelerisque, viverra id, dictum at, metus. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut pede sem, tempus ut, porttitor bibendum, molestie eu, elit. Suspendisse potenti. Sed id lectus sit amet purus faucibus vehicula. Praesent sed sem non dui pharetra interdum. Nam viverra ultrices magna.

Aenean laoreet aliquam orci. Nunc interdum elementum urna. Quisque erat. Nullam tempor neque. Maecenas velit nibh, scelerisque a, consequat ut, viverra in, enim. Duis magna. Donec odio neque, tristique et, tincidunt eu, rhoncus ac, nunc. Mauris malesuada malesuada elit. Etiam lacus mauris, pretium vel, blandit in, ultricies id, libero. Phasellus bibendum erat ut diam. In congue imperdiet lectus.

Aenean scelerisque. Fusce pretium porttitor lorem. In hac habitasse platea dictumst. Nulla sit amet nisl at sapien egestas pretium. Nunc non tellus. Vivamus aliquet. Nam adipiscing euismod dolor. Aliquam erat volutpat. Nulla ut ipsum. Quisque tincidunt auctor augue. Nunc imperdiet ipsum eget elit. Aliquam quam leo, consectetur non, ornare sit amet, tristique quis, felis. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque interdum quam sit amet mi. Pellentesque mauris dui, dictum a, adipiscing ac, fermentum sit amet, lorem.

Ut quis wisi. Praesent quis massa. Vivamus egestas risus eget lacus. Nunc tincidunt, risus quis bibendum facilisis, lorem purus rutrum neque, nec porta tortor urna quis orci. Aenean aliquet, libero semper volutpat luctus, pede erat lacinia augue, quis rutrum sem ipsum sit amet pede. Vestibulum aliquet, nibh sed iaculis sagittis, odio dolor blandit augue, eget mollis urna tellus id tellus. Aenean aliquet aliquam nunc. Nulla ultricies justo eget orci. Phasellus tristique fermentum leo. Sed massa metus, sagittis ut, semper ut, pharetra vel, erat. Aliquam quam turpis, egestas vel, elementum in, egestas sit amet, lorem. Duis convallis, wisi sit amet mollis molestie, libero mauris porta dui, vitae aliquam arcu turpis ac sem. Aliquam aliquet dapibus metus.

Vivamus commodo eros eleifend dui. Vestibulum in leo eu erat tristique mattis. Cras at elit. Cras pellentesque. Nullam id lacus sit amet libero aliquet hendrerit. Proin placerat, mi non elementum laoreet, eros elit tincidunt magna, a rhoncus sem arcu id odio. Nulla eget leo a

leo egestas facilisis. Curabitur quis velit. Phasellus aliquam, tortor nec ornare rhoncus, purus urna posuere velit, et commodo risus tellus quis tellus. Vivamus leo turpis, tempus sit amet, tristique vitae, laoreet quis, odio. Proin scelerisque bibendum ipsum. Etiam nisl. Praesent vel dolor. Pellentesque vel magna. Curabitur urna. Vivamus congue urna in velit. Etiam ullamcorper elementum dui. Praesent non urna. Sed placerat quam non mi. Pellentesque diam magna, ultricies eget, ultrices placerat, adipiscing rutrum, sem.